



UNIVERSIDAD NACIONAL DE LUJÁN

Algoritmos de Clasificación Multi-etiquetas en Ambientes de *Streaming* de Datos

Tesina de grado presentada para optar al título de
Licenciado en Sistemas de Información

Juan Cruz Cardona

Director: Santiago Banchero

2022

ALGORITMOS DE CLASIFICACIÓN MULTI-ETIQUETAS EN AMBIENTES DE *STREAMING* DE DATOS

La clasificación multi-etiquetas es un paradigma de aprendizaje supervisado que generaliza las técnicas clásicas de clasificación para abordar problemas en donde cada instancia de una colección se encuentra asociada a múltiples etiquetas. La mayor parte de los trabajos de investigación han sido realizados en contextos de aprendizaje por *batch*. Los ambientes de flujo continuo de datos (o *streaming*) presentan nuevos desafíos a esta área debido a las limitaciones de tiempo de respuesta y almacenamiento que acarrearán. En la presente investigación se aplican algoritmos de clasificación multi-etiquetas a colecciones estructuradas y no estructuradas. Los experimentos se llevaron a cabo en ambientes simulados de *streaming* de datos para conocer el impacto que produce este contexto sobre los resultados de la clasificación y acoplar el modelo a escenarios del mundo real. A su vez, se partió de estas colecciones de datos para generar instancias sintéticas y así producir flujos potencialmente infinitos. A este fin se presenta un método de generación de instancias sintéticas que busca replicar fenómenos particulares de colecciones multi-etiquetadas. Por último, se diseña una estrategia de ensambles de algoritmos, llamada Ensamble Fijo por Mayoría Ponderada, en búsqueda de una mejora en la calidad de la tarea de predicción de objetos no observados por el modelo. De esta manera, se provee a la comunidad de nuevos estudios experimentales sobre algoritmos y colecciones ya conocidos del área de clasificación multi-etiquetas, de manera tal de extender el conocimiento sobre su rendimiento bajo escenarios evolutivos y de naturaleza variable.

Palabras claves: clasificación, multi-etiquetas, *streaming*, algoritmos, flujos.

AGRADECIMIENTOS

En el tiempo que llevó realizar esta tesis he recibido el apoyo y asistencia de mucha gente y quiero aprovechar este espacio para reconocerlo.

Me gustaría agradecer en primer lugar a mi director, Santiago Banchero, quien con su conocimiento y experiencia me ha guiado por cada una de las etapas de este proceso. Su perseverancia y compromiso desde el inicio ha sido esencial para encauzar este proyecto y ha logrado sacar lo mejor de mí en el proceso.

Además, agradezco al Centro de Investigación, Docencia y Extensión en TIC de la Universidad Nacional de Luján (CIDETIC) por proveer los recursos humanos y computacionales necesarios para este proyecto. No hubiese podido arribar a estos resultados de no haber sido por el soporte por ellos recibido.

También quiero agradecer especialmente a mi familia, por el sostén emocional a lo largo de este proceso y por confiar en mí, en las buenas y en las malas. Gracias a mis padres, a mis hermanas y a mi abuela Lucía. Finalmente, este objetivo no se hubiera cumplido sin el apoyo incondicional de mis amigos, quienes estuvieron junto a mí y supieron entender mis ausencias. Incluso se han tomado el tiempo de leer los esbozos del escrito, participar en exposiciones o compartir charlas conmigo, y eso es un privilegio. Por eso gracias Lucas, Luz, Vicky, Mica, Torne y Alan.

A L. C.

Índice general

1..	Introducción	1
1.1.	Fundamentos	1
1.2.	Descripción del Tema de Estudio	2
1.2.1.	Clasificación Multi-etiquetas	2
1.2.2.	Flujos Continuos de Datos	4
1.3.	Motivación	5
1.4.	Objetivos	6
1.5.	Aportes	7
1.6.	Organización del Trabajo	8
2..	Preliminares	10
2.1.	Taxonomía del Campo de Estudio	10
2.2.	Clasificación Multi-etiquetas	10
2.2.1.	Definición	11
2.2.2.	Algoritmos	12
2.2.3.	Evaluación	14
2.3.	Clasificación de Flujos Continuos de Datos	17
2.3.1.	Definición	17
2.3.2.	Evaluación	18
2.3.3.	Datos Sintéticos	19
3..	Metodología	22
3.1.	Técnicas Propuestas	23
3.1.1.	Generación de Flujos Sintéticos	24
3.1.2.	Algoritmo de Ensamble	26
3.2.	Materiales y Métodos	28
3.2.1.	Colecciones	28
3.2.2.	Software	29
3.2.3.	Hardware	30
3.2.4.	Algoritmos	30
3.2.5.	Métricas de Evaluación	31
4..	Experimentos y Resultados	32
4.1.	Configuración Experimental	32
4.2.	Resultados	33
4.2.1.	Flujos Continuos Sintéticos	33
4.2.2.	Clasificaciones	44
5..	Conclusiones	51
5.1.	Trabajos Futuros	52

Apéndice	54
A.. Clasificación Tradicional	55
A.1. Aprendizaje Automático	55
A.2. Clasificación	55
A.2.1. Definición	55
A.2.2. Algoritmos	57
A.2.3. Evaluación	61
B.. Publicaciones Realizadas en el Marco de la Tesis	65

Índice de figuras

1.1. Categorización de los algoritmos de MLL más representativos.	4
2.1. Taxonomía del campo de estudio.	10
3.1. Los 101 conceptos semánticos asociados a la colección Mediamill.	29
4.1. Sesgo de etiquetas de los <i>streams</i> generados sobre la colección 20ng.	34
4.2. Distribución de etiquetas de los <i>streams</i> generados sobre la colección 20ng.	35
(a). Distribución de etiquetas para 20ng	35
(b). Distribución de etiquetas para 20ng - <i>MAE</i>	35
4.3. Relación entre etiquetas para cada <i>stream</i> generado sobre la colección 20ng.	36
(a). Relación entre etiquetas para 20ng - <i>Stream</i> original.	36
(b). Relación entre etiquetas para 20ng - <i>Stream</i> JC.	36
(c). Relación entre etiquetas para 20ng - <i>Stream</i> JC_BIG.	36
(d). Relación entre etiquetas para 20ng - <i>Stream</i> MOA.	36
4.4. Sesgo de etiquetas de los <i>streams</i> generados sobre la colección Enron.	38
4.5. Distribución de etiquetas de los <i>streams</i> generados sobre la colección Enron.	39
(a). Distribución de etiquetas para Enron	39
(b). Distribución de etiquetas para Enron - <i>MAE</i>	39
4.6. Relación entre etiquetas para cada <i>stream</i> generado sobre la colección Enron.	40
(a). Relación entre etiquetas para Enron - <i>Stream</i> original.	40
(b). Relación entre etiquetas para Enron - <i>Stream</i> JC.	40
(c). Relación entre etiquetas para Enron - <i>Stream</i> JC_BIG.	40
(d). Relación entre etiquetas para Enron - <i>Stream</i> MOA.	40
4.7. Sesgo de etiquetas de los <i>streams</i> generados sobre la colección Mediamill.	41
4.8. Distribución de etiquetas de los <i>streams</i> generados sobre la colección Mediamill.	42
(a). Distribución de etiquetas para Mediamill	42
(b). Distribución de etiquetas para Mediamill - <i>MAE</i>	42
4.9. Relación entre etiquetas para cada <i>stream</i> generado sobre la colección Mediamill.	43
(a). Relación entre etiquetas para Mediamill - <i>Stream</i> original.	43
(b). Relación entre etiquetas para Mediamill - <i>Stream</i> JC.	43
(c). Relación entre etiquetas para Mediamill - <i>Stream</i> JC_BIG.	43
(d). Relación entre etiquetas para Mediamill - <i>Stream</i> MOA.	43

4.10. Comparativa de modelos bajo la métrica $f1$ basada en ejemplos.	45
4.11. Comparativa de modelos bajo la métrica $f1$ con promedio macro, basada en etiquetas.	47
4.12. Comparativa de modelos bajo la métrica $f1$ con promedio micro, basada en etiquetas.	47
A.1. Dígitos escritos a mano.	55

Índice de cuadros

3.1. Colecciones multi-etiquetas y sus características.	28
3.2. Métodos de clasificación multi-etiquetas seleccionados para ambientes de flujos continuos de datos.	31
4.1. Características de los <i>streams</i> sintéticos generados sobre la colección 20ng. .	34
4.2. Sesgo de etiquetas: Principales combinaciones de los <i>streams</i> generados sobre la colección 20ng.	36
4.3. Espacio de atributos para <i>streams</i> 20ng.	37
4.4. Características de los <i>streams</i> sintéticos generados sobre la colección Enron. .	37
4.5. Sesgo de etiquetas: Principales combinaciones de los <i>streams</i> generados sobre la colección Enron.	38
4.6. Espacio de atributos para <i>streams</i> Enron.	40
4.7. Características de los <i>streams</i> sintéticos generados sobre la colección Mediamill.	41
4.8. Sesgo de etiquetas: Principales combinaciones de los <i>streams</i> generados sobre la colección Mediamill.	43
4.9. Espacio de atributos para <i>streams</i> Mediamill.	44
4.10. Resultados de métricas basadas en ejemplos sobre los <i>streams</i> seleccionados para cada algoritmo evaluado.	45
4.11. Resultados de métricas basadas en etiquetas sobre los <i>streams</i> seleccionados para cada algoritmo evaluado.	46
4.12. Resultados de métricas de eficiencia sobre los <i>streams</i> seleccionados para cada algoritmo evaluado.	48

ÍNDICE DE ALGORITMOS

1. Algoritmo de generación del conjunto de etiquetas para una instancia sintética. .	25
2. Algoritmo de generación del conjunto de atributos para una instancia sintética. .	26
3. Algoritmo de entrenamiento y ajuste de pesos para Ensamble Fijo por Mayoría Ponderada (EFMP)	27

1. INTRODUCCIÓN

1.1. Fundamentos

Ante el incremento explosivo de datos en los últimos años, existe un asiduo interés en el potencial valor que puede ser extraído de ellos, y el crecimiento continuo de los datos generados y capturados por las organizaciones se produce a una velocidad sin precedentes. Por ejemplo, *Google* procesa 40.000 registros de búsqueda promedio cada segundo y 3.5 miles de millones de búsquedas diarias, siendo valores que crecen año tras año [17]. Otro ejemplo es el de *Twitter*, cuya comunidad genera 12 terabytes de datos por día [39]. Los avances en el área de Tecnología de la Información (TI) han contribuido a una incesante producción de datos y expansión del campo digital, y esto se ve reflejado en redes sociales tales como *Facebook*, la cual recibe cada hora un flujo de 10 millones de fotos que publican sus usuarios [27]. A estas grandes colecciones de datos se las conoce como *big data* y acarrearán nuevas oportunidades y desafíos al campo de las ciencias de la computación. En cuestiones económicas, un análisis a gran escala en búsqueda de tendencias en el comportamiento de los usuarios o clientes de un sistema puede dar una ventaja competitiva en el mercado y, en adición, proveer de un servicio valioso a la comunidad. Potencialmente, la *big data* puede ser una fuente que proporcione a la comunidad de conocimiento nuevo sobre el mundo en el que habita, o como ha mencionado Fayyad, Piatetsky-Shapiro y Smyth en su escrito sobre el descubrimiento de conocimiento:

“Los datos que percibimos de nuestro ambiente son la evidencia básica que usamos para construir teorías y modelos sobre el universo en el que vivimos”¹

Sin embargo, volúmenes masivos de datos tornan obsoletos los tradicionales métodos manuales de análisis de datos y surge la necesidad de desarrollar técnicas automatizadas para extraer patrones en los datos y obtener conocimiento. Con este fin, se han desarrollado técnicas en las áreas de minería de datos y aprendizaje de máquinas que abordan estas colecciones en búsqueda de conocimiento válido y útil. Dichas técnicas se han enfocado en el aprendizaje por *batch* [13], lo que significa que el algoritmo dispone de la colección completa, almacenada en disco, y con la cual genera un modelo a partir de una o múltiples iteraciones sobre todos los datos. No obstante, el aprendizaje por *batch* trae aparejada una dificultad en su misma definición: requiere de todos los datos de la colección presentes y accesibles en todo momento, lo cual no siempre es posible. Además, se suma una limitante que es clave en el contexto actual de alta disponibilidad de datos: hoy en día una buena parte de los datos generados proviene de flujos continuos o “*streamings*” de datos [2]. Estos flujos son potencialmente ilimitados, arriban de a una instancia por vez, y son analizados con restricciones altas de tiempo de procesamiento y de memoria. Tal es el caso para aplicaciones de sensores, monitoreo de redes y administración de tráfico, flujo de clics de un usuario en la web, redes sociales, entre otros. Los algoritmos de aprendizaje que actúen en este entorno dinámico deben contar con mecanismos que permitan manejar cambios en la naturaleza o distribución de los datos, tanto para incorporar datos nuevos, como para descartar los datos antiguos. Por estas razones, se torna necesario que las aplicaciones basadas en clasificación en tiempo real adapten sus operaciones de entrenamiento y predicción para lograr mejores resultados [41].

¹ “Data we capture about our environment are the basic evidence we use to build theories and models of the universe we live in” [12, p. 2]. Traducción propia.

Dentro del área de minería de datos, una de las principales tareas es la de clasificación, la cual consiste en entrenar un modelo que sea capaz de asignar una única etiqueta a una instancia desconocida. No obstante, existen problemas de clasificación en donde múltiples etiquetas son necesarias para caracterizar una instancia. Por ejemplo, una noticia de diario referida al accidente aéreo que sufrió el plantel de fútbol del club Chapecoense puede ser clasificado en la categoría de “Fútbol” tanto como en la de “Tragedias”. Del mismo modo, un video documental sobre la vida de Borges puede anotarse como “Biografía”, “Literatura” o incluso “Buenos Aires” si se mostraran imágenes de la ciudad. Este tipo de problemas es llamado Clasificación multi-etiquetas (MLL)² y es un paradigma de aprendizaje automático que presenta muchos desafíos. La existencia de múltiples etiquetas en los datos hace que la complejidad algorítmica sea comparativamente mayor y se traduce también en un costo computacional alto. Por esto, es un campo que aún no ha sido suficientemente explorado en proyectos de investigación.

Una clasificación multi-etiqueta permite conocer el grado de correlación entre una instancia de la colección y una o más etiquetas. Esta cualidad significa un mayor poder de generalización con respecto a la clasificación tradicional de única etiqueta, ya que puede abarcar esos mismos problemas y otros de mayor número de etiquetas. Además, existen algoritmos que aprovechan la correlación entre etiquetas para mejorar la eficiencia de la clasificación y la calidad de la predicción.

El campo de MLL se ha desarrollado considerablemente en los últimos años, pero hasta el momento muchos de estos trabajos se han llevado a cabo en ambientes estáticos de aprendizaje por *batch* [36], en consecuencia, se hace necesario encarar nuevos proyectos que aborden clasificaciones MLL en contextos de *streaming* de datos. El desafío entonces consiste en crear clasificadores que sean capaces de manejar un inmenso número de instancias y adaptarse al cambio, a la vez que estar preparados para hacer tareas de predicción en cualquier momento, y todo esto en un contexto de altas restricciones de tiempo de respuesta y memoria.

1.2. Descripción del Tema de Estudio

1.2.1. Clasificación Multi-etiquetas

Tradicionalmente, el aprendizaje supervisado ha consistido en asociar una instancia o ejemplo a una única etiqueta. Dicho ejemplo es una representación de un objeto del mundo real, y por lo tanto, consta de características o atributos particulares. La etiqueta corresponde a un significado semántico o concepto que lo caracteriza. La tarea de clasificación entonces, reside en aprender una función que permita enlazar ejemplos no observados con una etiqueta. Es preciso notar aquí que dicha definición encubre la restricción de que cada instancia pertenece a una única etiqueta, o dicho de otra manera, cada objeto del mundo real se asocia a un único concepto y ningún otro. Sin embargo, existen problemas de clasificación donde más de una etiqueta puede ser asignada a un ejemplo. La anterior presunción no se amolda a problemas complejos donde un objeto pueda tener más de un significado simultáneamente.

Tareas de este tipo pueden surgir en áreas como las de categorización de texto, recuperación de información musical, clasificación semántica de escenas, anotación automática de videos o clasificación de genes y funciones proteicas. A modo de ejemplo, en el campo mencionado de clasificación semántica de escenas, la foto de un paisaje que ilustra una montaña y una playa puede asociarse a las categorías de ‘playa’ y ‘montaña’, simultánea-

² Siglas provenientes de su abreviación en inglés, Multi-label learning

mente [16]; en bioinformática, cada gen puede ser asociado a clases según su función, tales como ‘metabolismo’, ‘transcripción’ o ‘síntesis proteica’ [48]; por último, en recuperación de información musical una pieza sinfónica puede tener *tags* como ‘Mozart’, ‘piano’ o ‘clásica’.

Este paradigma es llamado ‘Clasificación multi-etiquetas’ y ataca problemas con las siguientes características [16]:

- El conjunto de etiquetas es previamente definido y tiene un significado interpretable por un humano.
- El número de etiquetas es limitado y no mayor que el número de atributos.
- En caso de que el número de atributos sea grande, se debe poder aplicar estrategias de reducción de atributos.
- El número de ejemplos puede ser grande.
- Las etiquetas pueden estar correlacionadas. Esto significa que se pueden aplicar técnicas que exploten estas relaciones con el objetivo de reducir los tiempos de procesamiento de los algoritmos.
- La distribución de los datos puede estar desbalanceada, es decir, que una etiqueta puede tener un mayor número de ejemplos que otras.

Asimismo, surge un desafío a superar: el conjunto de etiquetas posible crece exponencialmente ante cada nueva adición de una etiqueta. Por ejemplo, si se tuvieran 20 etiquetas, la cantidad posible de conjuntos de etiquetas distintos excedería el millón (2^{20}). Esto implica un tamaño exorbitante del espacio de salida y, en consecuencia, costos computacionales altos. En ese sentido, se ha buscado desarrollar algoritmos que aprovechan las correlaciones o dependencias entre etiquetas. Por ejemplo, la probabilidad de que una noticia que contiene los términos ‘pelota’ y ‘gol’ sea anotada con la etiqueta ‘fútbol’ sería mayor que si se etiquetara con la etiqueta ‘tenis’. Zhang y Zhang clasifican estos algoritmos en tres grupos según la estrategia de correlación aplicada [48]:

Estrategia de primer orden La tarea de MLL es dividida en q tareas de clasificación binarias, siendo q el número de etiquetas de la colección.

Estrategia de segundo orden La tarea de MLL se basa en la generación de relaciones de pares de etiquetas ya sea por *rankings* entre clases relevantes y no relevantes o por interacción entre pares de etiquetas.

Estrategia de alto orden La tarea de MLL considera relaciones de alto orden entre etiquetas.

Las estrategias de primer orden son conceptualmente simples y eficientes pero logran resultados de menor calidad porque no consideran correlaciones. Las estrategias de segundo orden tienen un mayor poder de generalización pero no todos los problemas de MLL pueden ser abarcados. El último grupo, por su parte, modela las correlaciones más potentes, pero conlleva un costo computacional alto.

En el último tiempo, muchos son los algoritmos que han sido desarrollados para atacar el problema de la clasificación MLL. La comunidad de investigación ha aceptado la taxonomía definida por Tsoumakas y Katakis, para estudiar y clasificar los distintos algoritmos de la literatura [16]. La misma propone dos grandes grupos:

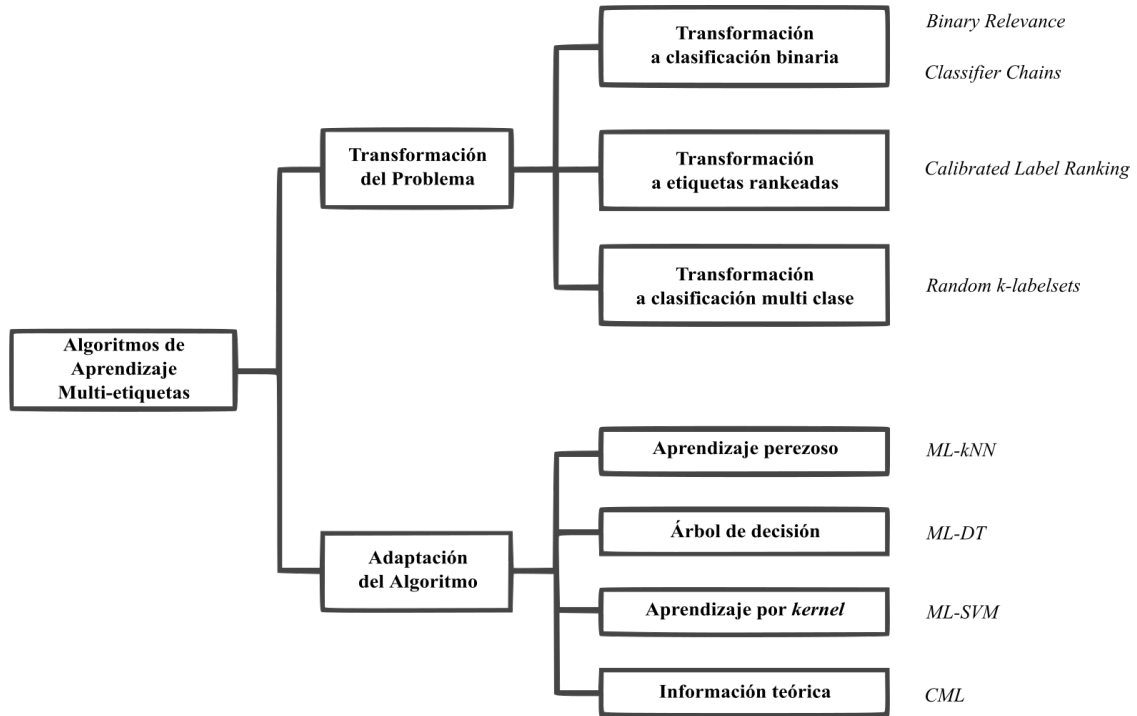


Fig. 1.1: Categorización de los algoritmos de MLL más representativos.

Métodos de transformación del problema Este tipo de algoritmos transforman el problema de clasificación MLL en uno o más problemas de clasificación de etiqueta única tradicional. Ejemplos típicos de este grupo son Binary Relevance (BR) [43] y Classifier Chains (CC) [36]. Ambos convierten la tarea en una de clasificación binaria.

Métodos de adaptación del algoritmo Son algoritmos que toman métodos tradicionales de aprendizaje, como árboles de decisión o *naive bayes*, y los adaptan a la tarea de clasificación MLL, procesando los datos multi-etiquetados directamente.

A modo ilustrativo, la figura 1.1 es un diagrama de la taxonomía de algoritmos confeccionado por Zhang y Zhou [49]. Nótese que, a diferencia de problemas de multi-clase, en donde las clases son mutuamente excluyentes, en MLL cada etiqueta representa una categoría diferente y pueden estar relacionadas entre sí, para lo que resultaría beneficioso aplicar un algoritmo de MLL capaz de extraer esta inter-dependencia en los datos.

1.2.2. Flujos Continuos de Datos

Hoy en día, los datos pueden ser generados por elementos de continuo monitoreo del medio, tales como sensores o archivos de registro. La clasificación de flujos continuos de datos o *streamings* se enfoca en problemas de este tipo, en donde objetos del mundo real son analizados en tiempo real. Un *stream* se considera como una secuencia ordenada de datos que fluye a alta velocidad y es teóricamente infinita. A continuación se describe brevemente las características de este tipo de datos y los requisitos que debe cumplir un algoritmo para poder tratar con ellos.

1.2.2.1. Características

En escenarios de *streamings*, los datos deben cumplir con las siguientes características [13]:

- Los datos están disponibles a través de flujos continuos e ilimitados en el tiempo, a diferencia del aprendizaje por *batch* donde los datos son acotados.
- Las regularidades subyacentes de los datos no son estacionarias, sino que pueden evolucionar. En otras palabras, la distribución de los datos es susceptible a cambios en el tiempo.
- Los datos ya no son considerados independientes e idénticamente distribuidos.
- Los datos están situados tanto en el espacio como en el tiempo. La lectura y procesamiento de los mismos debe ser lo suficientemente veloz como para procesar el siguiente dato, de otro modo, el dato ya no podrá ser procesado en el futuro.

1.2.2.2. Requisitos de los algoritmos

Para hacer frente a estas características de los datos, los sistemas o algoritmos deben contar con los siguientes requisitos [20]:

- El tiempo para procesar cada registro debe ser constante y pequeño.
- Debe usar un tamaño fijo de memoria principal y no dependiente de la cantidad de registros ya procesados.
- El modelo es generado a partir de una única pasada sobre los datos.
- Debe contar con un modelo listo para realizar predicciones en cualquier momento.
- Idealmente, deberá producir un modelo equivalente o casi idéntico al que hubiera sido producido en un ambiente de *batch*.
- Debe mantenerse actualizado ante evoluciones o derivas de concepto en los datos.

Los algoritmos que cumplen con estas cualidades son llamados algoritmos de aprendizaje adaptativo y, aplicados a tareas de clasificación como el de multi-etiquetas, pueden aprovecharse para entrenar un mayor número de objetos y predecir en cualquier instante.

1.3. Motivación

Ante la necesidad de hacer frente a un contexto global de generación masiva de datos y a ritmo acelerado, se hace preciso fortalecer las técnicas de aprendizaje automático actualmente presentes en el campo. En este escenario ya no es posible contar con todos los datos almacenados físicamente y la idea de generar un modelo completo para luego evaluarlo en una fase posterior debe ser reemplazada por una en donde el modelo esté siempre listo para realizar predicciones y al mismo tiempo ser capaz de reentrenarse y recalculer las métricas de evaluación ante cada nueva instancia abordada. Todo esto en un contexto cambiante, de alta disponibilidad y de limitación en el espacio de almacenamiento. Si bien existen métodos de clasificación para flujos continuos que han dado resultados satisfactorios, aún es un campo conveniente de ser abordado. Asimismo, reproducir los experimentos realizados y fortalecer las técnicas y herramientas actuales puede ser beneficioso para lograr

estudios precisos y pormenorizados que sean valiosos tanto para la comunidad científica en sí misma, como también para la sociedad en general.

Por otro lado, si bien existen en el mundo real infinidad de datos multi-etiquetados aún no es posible hallar colecciones disponibles al público que cuenten con todas las características de un flujo continuo de datos. Uno de los enfoques abordados es convertir las colecciones existentes en flujos tales que arriben en conjuntos predefinidos y a lo largo del tiempo. De esta manera los algoritmos pueden ser utilizados para realizar clasificaciones en un ambiente similar al de un escenario de *streaming*. Sin embargo, estas colecciones tienen un número limitado de instancias y, por lo tanto, no cumplen con la condición de ser teóricamente infinitos. Es entonces aquí donde surgen las técnicas de generación sintética de instancias, que buscan reproducir la distribución subyacente de los datos para simular colecciones de datos del mundo real. La contracara de este enfoque es que, si bien existen técnicas y herramientas para generar datos etiquetados, buena parte de ellos son solo aplicables para instancias de una única etiqueta y los que logran generar datos multi-etiquetados no han sido lo suficientemente explorados en el área. Hasta el momento, los generadores de instancias multi-etiquetadas son capaces de generar datos cercanos a los de colecciones del mundo real [33] y brindan la posibilidad de realizar estudios relativamente certeros de algoritmos de clasificación [37]. No obstante, debe notarse también que si bien se han obtenido colecciones sintéticas en sí mismas aún no han logrado generar instancias para una colección en concreto, respetando sus cualidades particulares y que las distinguen de otras, tales como la co-ocurrencia de etiquetas, la densidad y cardinalidad de las etiquetas y la relación entre las etiquetas y sus atributos, por mencionar algunas. De lograr esta aproximación se podrán realizar estudios sobre el impacto de los algoritmos sobre flujos de datos de naturaleza distintiva, o en otras palabras, entender en qué medida un algoritmo es más apropiado que otro para un conjunto de datos en un determinado contexto.

Esta última idea mencionada, es decir, el ser capaz de hallar las fortalezas y debilidades de un algoritmo de MLL en un contexto determinado es clave para evaluar la clasificación y entender los resultados obtenidos. Estudios como el de Sousa y Gama [41] o el de Read y col. [37] se han topado con que algoritmos de menor complejidad pueden ser competitivos o incluso superar las métricas de otros algoritmos más complejos. Esta variabilidad en los resultados no solo contrae la necesidad antes mencionada de realizar más estudios al respecto, sino que también abre las puertas a incursionar en soluciones de ensambles de algoritmos. Estos ensambles han dado probada muestra de potenciarse ante la diversidad de resultados obtenidos por sus estimadores base [32], ya que son capaces de disminuir el error total mediante estrategias combinativas. De cualquier manera, las estrategias de ensamble existentes para flujos continuos no han recibido la misma atención que aquellas aplicadas sobre ambientes de *batch* y queda mucho camino por recorrer.

1.4. Objetivos

El objetivo principal es estudiar el impacto de distintos algoritmos de clasificación sobre datos multi-etiquetados en ambientes de *streaming* y provenientes de fuentes de distinto origen y naturaleza, en particular se seleccionan colecciones de datos que son puntos de referencia en la literatura y que poseen características distintivas entre sí, tales como el número de etiquetas, el número de atributos, o la cantidad de instancias. A su vez, es necesario convertir estos datos a flujos continuos. A este fin se generan instancias sintéticas que sean fieles a estas características mencionadas, aplicando técnicas existentes pero también extendiéndolas para detectar co-ocurrencias entre etiquetas. De esta manera, se

buscan obtener representaciones óptimas de las colecciones. Por otro lado, se llevarán a cabo clasificaciones con algoritmos clásicos y con soluciones de ensambles, en búsqueda de maximizar los valores de las métricas de evaluación en cada escenario. En este sentido, se diseñan distintas configuraciones de ensambles, variando los estimadores base y probando distintas implementaciones. A este fin, se diseña y desarrolla una nueva versión de algoritmo de votación por mayoría, llamado EFMP, y se compara su rendimiento contra otros algoritmos de MLL bien conocidos.

En resumen, se listan a continuación los objetivos particulares del trabajo:

- Generar flujos continuos de datos a partir de la colección proporcionada buscando replicar su número de etiquetas, atributos e instancias, su cardinalidad y densidad de etiquetas y la co-ocurrencia entre dos etiquetas. Aplicar técnicas conocidas de generación de instancias sintéticas, proponer una técnica nueva y comparar los resultados.
- Evaluar la capacidad predictiva de los principales algoritmos de MLL sobre diferentes escenarios de flujos continuos.
- Desarrollar y evaluar una solución de MLL basada en ensamble a partir de algoritmos clásicos del área de estudio.

1.5. Aportes

El presente trabajo de investigación aborda el campo de aprendizaje por multi-etiquetas a partir de la experimentación y evaluación de técnicas y algoritmos de la literatura sobre colecciones de naturaleza cambiante. MLL es un paradigma emergente de aprendizaje supervisado cuyas características implícitas abren paso a nuevos desafíos que derivan del crecimiento exponencial de etiquetas y sus combinaciones, y del costo computacional de entrenar y consultar el modelo. También suelen presentarse otras propiedades como la alta dimensionalidad, data evolutiva y desbalanceada o dependencia entre etiquetas, las cuales implican una resignificación de las técnicas y métodos tradicionales del área de minería de datos.

El paradigma de MLL ha dado muestras de su eficiencia en términos de tiempos de configuración y ejecución de las tareas, bajo diversos campos de aplicación tales como los de categorización de texto, diagnósticos médicos, minería de redes sociales o análisis de datos químicos, y se mantiene en constante expansión hacia nuevos dominios de aplicación. Asimismo, su continua integración a problemas de diversa naturaleza ha contribuido a alimentar esta tendencia.

Adicionalmente, la tarea de clasificación de *streaming* de datos se enfoca en problemas donde objetos del mundo real son generados y procesados en tiempo real. Datos de este tipo, y que además poseen múltiples etiquetas, son frecuentes en escenarios del mundo real tal como sitios de publicación de imágenes, correos electrónicos o portales de noticias. Abordar este tipo de problemas implica que los algoritmos sean capaces de identificar cambios de concepto en los datos y adaptarse al nuevo contexto. De lograr esto, se podrá generar modelos más sólidos, ya que se cuenta con un mayor número de objetos, y que se encontrarán aptos para predecir en cualquier momento. Surge entonces el reto de crear clasificadores que actúen en ambientes de altas restricciones computacionales y sean capaces de manejar un inmenso número de instancias, lidiar con evoluciones en los datos y estar listos para resolver tareas de predicción en tiempo real.

A diferencia de otros trabajos de investigación recientes, este trabajo final lleva a cabo estudios experimentales sobre el tema de clasificaciones multi-etiquetas, para hallar las

fortalezas y debilidades de distintos algoritmos de aprendizaje sobre distintos tipos de colecciones. A ello le sumamos el diseño y desarrollo del algoritmo EFMP que utiliza estrategias de ensambles para combinar estimadores bien conocidos del campo. Todo ello con miras a aportar de un mayor conocimiento empírico sobre el tema a la comunidad científica especializada en tareas de clasificación de flujos de datos multi-etiquetados.

El otro aporte aquí presentado consiste en un generador de flujos sintéticos que dada una colección multi-etiquetada retorna instancias nuevas y con un grado de similitud con las instancias de la colección original. De esta manera, se podrá obtener flujos continuos potencialmente infinitos, generados a partir de una colección del mundo real y que la comunidad podrá utilizar para simular escenarios de *streaming* durante el entrenamiento de los algoritmos MLL.

En definitiva, el presente trabajo espera contribuir al estudio de métodos y técnicas asentadas, ofrecer una alternativa de ensamble de clasificadores competitiva, a la vez que fortalecer futuros trabajos de investigación en el campo con un generador de instancias sintéticas para entrenar algoritmos en escenarios más cercanos a los del mundo real.

1.6. Organización del Trabajo

El presente escrito de tesis sigue la estructura clásica de proyecto de investigación aplicado. Para comenzar, se brinda el marco teórico en el que se sitúa el trabajo (capítulo 2), luego se describe la metodología a seguir (capítulo 3), se presentan los experimentos y sus resultados (capítulo 4), y finalmente, se trazan las conclusiones arribadas y las futuras líneas de investigación (capítulo 5). A continuación, se describe con más detalle cada capítulo del escrito:

Capítulo 2. Preliminares: En este capítulo se sitúa el trabajo dentro del campo de estudio general y se introducen los conceptos claves, tanto de la tarea de clasificación multi-etiquetas como también de los ambientes de flujos continuos, para comprender los subsecuentes capítulos. La sección de clasificación MLL cuenta con una definición formal de la tarea, presenta los tipos de algoritmos existentes, junto con algunos de sus principales exponentes y describe métricas de evaluación utilizadas para evaluar los resultados de la clasificación. Posteriormente, se da una descripción detallada del concepto de flujo continuo y se extienden los conceptos presentados de MLL para contextos de este tipo.

Capítulo 3. Metodología: En este capítulo se describe la metodología aplicada para entrenar y clasificar modelos de MLL en ambientes de *streaming* así como también la generación y análisis de datos sintéticos. A su vez, se exponen las técnicas propuestas que son propias y originarias de este trabajo, lo que incluye, por un lado, un método que provee una serie de parámetros para generar datos sintéticos a partir de una colección dada y, por otro, una nueva solución de ensambles de votación por mayoría. Por último, se listan los materiales seleccionados para la realización de las pruebas, lo que incluye las colecciones, los algoritmos, los métodos de evaluación, el software y el hardware utilizado.

Capítulo 4. Experimentos y Resultados: En este capítulo se emprende la definición de los experimentos y la configuración de las pruebas, para luego exponer los resultados obtenidos. Los mismos incluyen tablas y gráficos que facilitan la observación y comparación entre escenarios. Para los experimentos concernientes a la generación sintética, se estudian los fenómenos de colecciones multi-etiquetas y su aparición en

los nuevos datos. Para los experimentos de evaluación de algoritmos, se analizan los resultados de cada métrica de evaluación para las pruebas ejecutadas en nuestro ambiente y luego se comparan contra los resultados de otros autores de la literatura en sus respectivos escritos.

Capítulo 5. Conclusiones: En este capítulo se abordan las conclusiones obtenidas una vez desarrollados los objetivos y presentado los resultados, y se definen las líneas de investigación futuras.

2. PRELIMINARES

En este capítulo se presenta el marco teórico de este trabajo, dando un panorama general de cada una de las disciplinas abordadas e introduciendo los conceptos básicos y fundamentales para entender el proyecto. Se comienza con la definición de la taxonomía del campo de estudio y luego se abordan los conceptos claves de la tarea de clasificación multi-etiquetas y su aplicación en ambientes de flujos continuos. Muchos de los algoritmos y métricas de evaluación son parte de la configuración experimental, y, por tanto, serán mencionados nuevamente en capítulos posteriores.

2.1. Taxonomía del Campo de Estudio

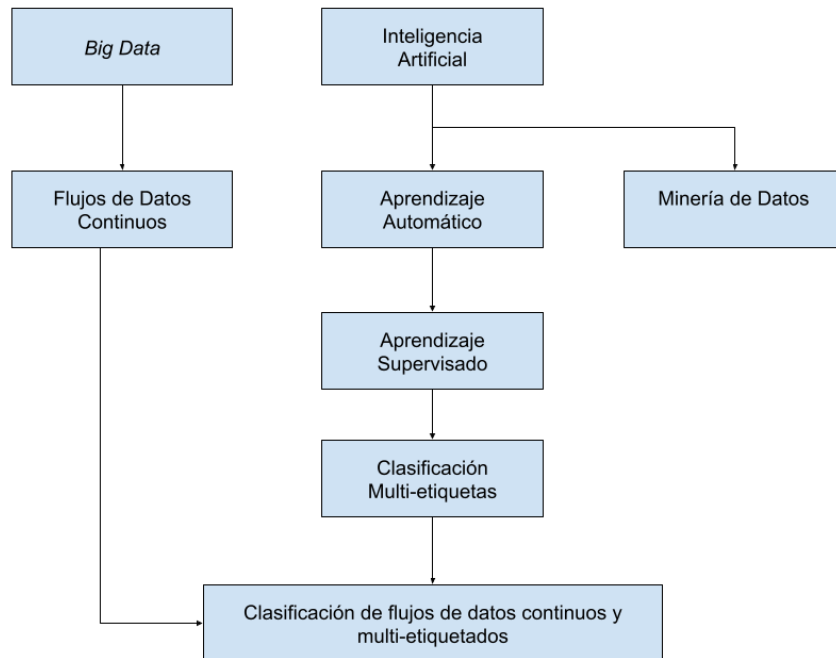


Fig. 2.1: Taxonomía del campo de estudio.

El presente trabajo de investigación se enmarca en las áreas de *big data* y minería de datos, con aplicación en escenarios de *streaming* o flujos continuos de datos y abordando clasificaciones multi-etiquetas. La figura 2.1 es un esquema que ilustra la taxonomía del campo de estudio y la interrelación entre las áreas de investigación involucradas.

2.2. Clasificación Multi-etiquetas

A diferencia del aprendizaje automático tradicional (ver anexo A), que usa datos de etiqueta única para representar objetos del mundo real, cada instancia en el aprendizaje multi-etiquetas representa un único objeto, pero puede contener más de una etiqueta. Por

consiguiente, la tarea de clasificación consiste en hallar una función que logre asignar a cada objeto, nuevo y desconocido, el conjunto de etiquetas que lo caracteriza.

En este apartado se da una definición formal, se detallan las características de un conjunto de datos multi-etiquetados y se describen algunos métodos tradicionales de clasificación multi-etiquetas junto con sus ventajas, desventajas, aplicaciones y motivaciones.

2.2.1. Definición

Asumiendo que $X = \mathbb{R}^d$ denota el espacio de instancias d dimensional, y que $Y = \{y_1, y_2, \dots, y_q\}$ denota el espacio de etiquetas con q etiquetas posibles, la tarea de clasificación multi-etiquetas consiste en entrenar un conjunto $D = \{(x_i, Y_i) \mid 1 \leq i \leq m\}$ para hallar una función h tal que $h : X \rightarrow 2^Y$. A su vez, X_i es un vector de atributos d dimensional definido como $(x_{i1}, x_{i2}, \dots, x_{id})$. Y_i , por su parte, es el conjunto de etiquetas asociadas a la instancia X_i . Luego, para cada instancia desconocida $x \in X$ el clasificador h predice $h(x) \subseteq Y$ que representa el conjunto de etiquetas hallado para x .

A su vez, se definen un conjunto de métricas que describen el grado de multi-etiquetado que tiene un conjunto de datos dado, o en otras palabras, hasta qué punto cada ejemplo posee más de una etiqueta. Algunas de ellas son:

Cardinalidad de etiquetas: Es el promedio de etiquetas por instancia del conjunto de datos. Se define como:

$$CardE(D) = \frac{1}{m} \sum_{i=1}^m \|Y_i\| \quad (2.1)$$

Por lo tanto, a mayor el valor de cardinalidad, mayor es el número de etiquetas de una instancia. Por ejemplo, si $CardE = 1$, entonces la mayoría de ejemplos tiene una única etiqueta y, por consiguiente, se puede decir que la colección tiene un grado bajo de multi-etiquetado.

Densidad de etiquetas: Es la cardinalidad de etiquetas normalizada al número total de etiquetas de D y se define como:

$$DenE(D) = \frac{CardE(D)}{\|Y\|} \quad (2.2)$$

Así pues, un valor alto de densidad significaría que cada instancia puede ser una buena representación de las etiquetas del conjunto. De la misma manera, un valor bajo suele implicar dispersión, esto es, que la mayoría de las instancias tienen un subconjunto acotado de las etiquetas.

Diversidad de etiquetas: Es el número de conjuntos de etiquetas unívocos que aparecen en instancias de D . Se define como:

$$DivE(D) = \|\{Y \mid \exists x : (x, Y) \in D\}\| \quad (2.3)$$

Aquí la interpretación es que, a mayor el valor de diversidad, menor es la constancia con la que las etiquetas aparecen en las instancias. De manera similar a la cardinalidad, el valor de diversidad también puede normalizarse por el número de instancias del conjunto de datos:

$$DivEProm(D) = \frac{DivE(D)}{\|D\|} \quad (2.4)$$

2.2.2. Algoritmos

Como se había anticipado en la sección 1.2.1, la tarea de aprendizaje sobre datos multi-etiquetados puede ser encarada siguiendo dos grandes enfoques, llamados “Transformación del Problema” y “Adaptación del Algoritmo”, o a través de soluciones de ensamble que combinan este tipo de modelos. A continuación se describen ambos enfoques y algunos de sus algoritmos más representativos.

2.2.2.1. Transformación del Problema

Esta categoría engloba al conjunto de algoritmos que abordan el problema de clasificación multi-etiquetas transformándolo en múltiples problemas de clasificación de única etiqueta, lo cual permite aplicar algoritmos de clasificación convencionales. Tres de estos métodos son particularmente relevantes para este trabajo: “Binary Relevance (BR)”, “Classifier Chains (CC)” y “Label Powerset (LP)”.

Binary Relevance (BR) El algoritmo de Relevancia Binaria, conocido como *Binary Relevance* en la literatura, es un enfoque que consiste en descomponer la tarea de clasificación MLL en $\|q\|$ clasificadores binarios, independientes y de etiqueta única. A partir de esta transformación se puede seleccionar cualquier algoritmo de clasificación tradicional como clasificador base del problema (ver los algoritmos presentados en A.2.2). Cada clasificador binario g_j es entrenado con todas las instancias de la colección, pero incluyendo solo la etiqueta j , la cual se activa o desactiva de acuerdo a si es relevante a la instancia. Luego la predicción de una instancia desconocida se realiza combinando las salidas de cada clasificador individual, esto es:

$$Y = y_j \mid g_j(x) > 0, 1 \leq j \leq q \quad (2.5)$$

Llegado el caso en que ninguno de los clasificadores retornen etiquetas activas, el conjunto Y será vacío.

Este enfoque se dice que es de primer orden (ver sección 1.2.1) y no tiene en cuenta las correlaciones o interdependencias entre etiquetas. Este es uno de los principales inconvenientes de este algoritmo porque, en este tipo de problemas de MLL, es usual hallar que determinadas etiquetas se activan en conjunto con mayor probabilidad. Pese a ello, BR es un enfoque muy utilizado [49] ya que es simple de implementar, intuitivo y computacionalmente poco costoso en comparación con algoritmos que sí tienen en cuenta la relación entre etiquetas.

Classifier Chains (CC) Las cadenas de clasificadores o *Classifier Chains* [36] es una técnica que convierte el problema de MLL en una “cadena” de problemas de clasificación binaria, tal que el siguiente clasificador de la cadena posee las predicciones de los anteriores. En principio, la división del conjunto de datos es similar a la que se hace en el enfoque anterior, designando un clasificador por cada etiqueta. Durante el entrenamiento, el clasificador inicial, seleccionado aleatoriamente, usa de entrada los atributos originales, tal como el clasificador BR. Luego la salida de este clasificador es añadida al espacio de atributos como un atributo más de cada instancia, para que posteriormente, estos atributos sean la entrada del siguiente clasificador, el cual también es seleccionado al azar. Este proceso es repetido hasta completar todos los clasificadores. Como se puede observar, lo que se produce es un “encadenamiento” de clasificadores, el cual no es accidental y tiene como fin conservar la dependencia entre etiquetas: en el entrenamiento se van acumulando las

salidas de los clasificadores anteriores de tal manera que el siguiente clasificador absorbe la correlación entre las etiquetas de los anteriores.

Cabe notar que en esta técnica cobra especial importancia el ordenamiento de los clasificadores, ya que este orden tiene un impacto directo sobre el resultado de la predicción. En otras palabras, si el ordenamiento se modifica, el modelo final otorgará resultados diferentes. Para salvar esta dificultad se han propuesto modelos como Ensamble de Classifier Chains (ECC). El mismo genera un conjunto de modelos de CC con distintos ordenamientos y entrenados con diversos subconjuntos de datos, generados con reemplazo o no. Durante la predicción, cada cadena produce un conjunto de etiquetas, que son los votos, y la salida final será computada por un algoritmo que combine cada salida individual.

Label Powerset (LP) El conjunto de potencias de etiquetas o *Label Powerset* [44] es una técnica que se encarga de transformar el problema de MLL en uno de clasificación multi-clase y así poder abordarlo con algoritmos de este tipo. La clasificación multi-clase es un enfoque usado para tratar con ejemplos en donde la etiqueta es única, pero cuenta con más de dos clases. Un ejemplo de este tipo de problemas es el de análisis de sentimiento de texto, en donde las clases pueden ser “positivo”, “negativo” y “neutral”. En LP cada etiqueta indica el subconjunto de etiquetas de la instancia. Esto es beneficioso en cuanto a que se logra preservar la dependencia entre etiquetas. Sin embargo, el modelo tiene algunas dificultades. En primer lugar, el espacio de clases posibles es exponencial y su cantidad de clases puede llegar a ser de $2^{|q|}$ como máximo. A su vez, pueden llegar a arribar ejemplos con una combinación de etiquetas que el modelo no recibió durante el entrenamiento, por lo cual no logra generalizar lo suficiente y se lo considera un modelo incompleto. A fin de sobrepasar estas complicaciones se desarrolló la técnica de “Conjuntos Podados” o “Pruned Set (PS)”. La misma consiste en preservar para la clasificación aquellos subconjuntos de etiquetas que son más frecuentes en la colección, y eliminar los demás. Con esto se logra disminuir considerablemente el espacio de clases y disminuye la complejidad computacional, tanto durante el entrenamiento como durante la predicción.

2.2.2.2. Adaptación del Algoritmo

Además del enfoque de transformación del problema, algunos autores abordan la clasificación multi-etiquetas a partir de la adaptación de algoritmos clásicos y bien conocidos a este tipo de escenarios. La categoría engloba al conjunto de algoritmos que acometen el problema de MLL mediante la modificación de algoritmos de etiqueta única para que sean capaces de manejar la nueva naturaleza de los datos en estas tareas. Las modificaciones que se introducen pueden variar en complejidad según el algoritmo tratado y las características de la colección. Se han adaptado una diversa cantidad de algoritmos incluyendo aquellos basados en redes neuronales, árboles, métodos probabilísticos, entre otros [19]. Por mencionar algunos ejemplos, Gargiulo, Silvestri y Ciampi usan redes neuronales profundas para clasificar documentos de texto libre y comparan su funcionamiento variando el número de etiquetas y aprovechando su estructura jerárquica [15]. Asimismo, Tanaka y col. agregan al algoritmo de BR la capacidad de capturar relaciones entre etiquetas a través del uso de árboles de decisión y lo aplican en el área de la genómica [42].

En lo que confiere a ambientes de flujos continuos de datos una de las técnicas más populares en la literatura es la de Árbol de Hoeffding o *Hoeffding Tree (HT)* [10], que a diferencia de los algoritmos convencionales de árboles de decisión, aborda los datos de manera incremental. Así pues, en lugar de realizar decisiones de corte de acuerdo a los datos previamente almacenados, el algoritmo de HT espera a tener una cantidad suficiente de instancias para realizar el corte, con un cierto grado de confianza. Esto significa que

ya no es necesario guardar todos los datos de la colección y que mantener una serie de estadísticas es suficiente para realizar la clasificación. Otra de las propiedades a destacar de este método es que, en la teoría, se puede entrenar un árbol cuyo rendimiento se aproxime al generado en un ambiente de *batch*, con la suficiente cantidad de datos [3].

A partir de esto, y buscando sacar provecho de las ventajas mencionadas, Read y col. decidieron adaptar este algoritmo a problemas de multi-etiquetas y desarrollaron el algoritmo llamado Árbol de Hoeffding Multi-etiquetado o *Multi-label Hoeffding Tree (MLHT)* [37]. Esto lo consiguen a partir de rediseñar la fórmula de ganancia de información (ver fórmula A.7) de tal manera de reflejar en el cálculo de la entropía el impacto de todas las clases a las cuales el ejemplo no pertenece. Desde que fue introducido en el año 2012, MLHT ha sido usado como modelo de comparación en reiteradas oportunidades [41] y es uno de los métodos más populares para atacar problemas de MLL en ambientes de flujo continuo de datos.

Otro algoritmo muy popular para abordar este tipo de problemas y que también se basa en árboles de decisión incrementales es el llamado iSoup-Tree (siglas del inglés *Incremental Structured Output Prediction Tree*) [29]. El mismo fue desarrollado inicialmente para hacer regresión de múltiples objetivos y luego fue adaptado a tareas de MLL. Una de las novedades que introduce es el uso de un perceptrón adaptativo en las hojas del árbol, lo cual le da la versatilidad de poder trabajar tanto con problemas de clasificación como de regresión.

2.2.2.3. Ensamblados de Clasificadores

El enfoque de ensambles se presenta en el anexo A.2.2.3. En resumidas cuentas, se trata de una técnica que busca mejorar el rendimiento de clasificadores individuales, valiéndose de la existencia de sesgos o *bias* en ellos, y explora esta diversidad en los modelos para amplificar los valores de las métricas de evaluación. En lo que respecta a la tarea de MLL, es uno de los enfoques más utilizados [19] y vale la pena mencionar algunos de ellos. Oza introdujo los modelos de *Oza bagging* [30], los cuales extienden la técnica de *bagging* para ser utilizada en ambientes de *streamings*. Esto lo consiguen a partir de asignar a cada clasificador base la instancia arribada, pero en una cantidad de veces determinada por una distribución de *poisson*, con $\lambda = 1$. Cada miembro del ensamble, entonces, recibirá una cantidad de copias distinta y esto es lo que determina la diversidad entre los miembros. Ejemplos de este tipo son los de Ensamble de Binary Relevance (EBR) y Ensamble de Classifier Chains (ECC) [36]. Kolter y Maloof, por su parte, presentaron el modelo Dynamic Weighted Majority (DWM) [24], el cual genera n clasificadores base a partir de un mismo algoritmo, los pondera en base a su rendimiento previo y aplica mayoría de voto como técnica de selección de etiquetas. Otra de sus cualidades es la de eliminar a los clasificadores menos performantes de manera dinámica, lo cual hace que sea una solución robusta en ambientes cambiantes, como los de *streamings*. El algoritmo fue diseñado inicialmente para problemas de etiqueta única, pero puede ser adaptado a tareas de MLL. Por último, cabe destacar el modelo GOOWE-ML [7], que usa modelos espaciales para asignar un coeficiente de confianza a cada clasificador base del ensamble y así lograr una ponderación dinámica en cada clasificación.

2.2.3. Evaluación

En escenarios de clasificación tradicionales el poder de generalización de un modelo es evaluado a partir de métricas tales como la exactitud o la exhaustividad las cuales trabajan con una única etiqueta. Una predicción multi-etiquetada, por el contrario, carga con la

complejidad de que cada ejemplo puede ser asociado a más de una o dos etiquetas. Esto implica que ya no se puede trabajar con la presunción de que una clasificación solo puede ser correcta o incorrecta. De lo contrario, se incursionaría en una evaluación excesivamente rigurosa. Por este motivo, en el campo de MLL se han diseñado una serie de métricas nuevas y específicas para abordar este tipo de problemas, y se clasifican en dos grupos: existen las métricas “basadas en ejemplos”, que son computadas por cada instancia y luego promediadas; y las métricas “basadas en etiquetas”, las cuales son calculadas para cada etiqueta por separado y devuelven el promedio micro o el promedio macro.

A continuación se describe en detalle ambas categorías, incluyendo métricas presentadas por cada enfoque, junto con su definición formal y una interpretación de la evaluación que proveen. Para más información sobre la tarea de evaluación en escenarios tradicionales consultar el anexo A.2.3, donde se describen algunas de las métricas y estrategias utilizadas en el área y que son relevantes al presente trabajo final.

2.2.3.1. Métricas basadas en Ejemplos

En esta categoría se hallan las métricas que evalúan la calidad de la clasificación ejemplo por ejemplo y determinan qué tan buena es la clasificación sobre los distintos ejemplos. Tienen en común que comparan las etiquetas de la predicción contra las etiquetas reales para cada instancia y luego combinan la salida aplicando la media sobre el total de instancias. Entre ellas se encuentran las siguientes:

Hamming Loss Esta es una de las métricas más populares en la literatura y se encarga de evaluar la proporción de pares instancia-etiqueta incorrectamente clasificados, es decir, toma en cuenta para el conteo tanto si se marcó como irrelevante una etiqueta relevante o si, por el contrario, se activó una etiqueta que no era relevante. Se define como:

$$HLoss = \frac{1}{m} \sum_{i=1}^m \|h(x_i) \Delta Y_i\| \quad (2.6)$$

Aquí el símbolo “ Δ ” es la diferencia simétrica entre conjuntos. Tener en cuenta también que cuanto menor es el valor de *hamming loss* mejor es el rendimiento del clasificador.

De manera complementaria, algunos autores de la literatura han decidido usar la métrica “*hamming score*” que es un derivado del *hamming loss* y se calcula como:

$$HScore = 1 - HLoss \quad (2.7)$$

Exactitud del Subconjunto Se la conoce también como *exact-match* en la literatura y es la métrica equivalente a la exactitud en clasificaciones de etiqueta única (ver “Exactitud” en anexo A.2.3.1). El cómputo toma en cuenta la proporción de instancias que fueron clasificadas de manera exacta, es decir, que todas sus etiquetas fueron correctamente clasificadas o, en otras palabras, que el subconjunto de etiquetas de la predicción es idéntico al subconjunto de etiquetas reales. En términos formales, se calcula como:

$$exactitudSubconjunto = \frac{1}{m} \sum_{i=1}^m \|h(x_i) = Y_i\| \quad (2.8)$$

Es considerada una métrica excesivamente rigurosa, especialmente para colecciones donde el número de etiquetas es alto.

Exactitud basada en ejemplos La exactitud basada en ejemplos también es conocida como “Índice de Jaccard” y consiste en tomar la proporción de etiquetas activas y correctamente clasificadas con respecto al total de etiquetas activas.

$$exactitudEj = \frac{1}{m} \sum_{i=1}^m \frac{\|Y_i \cap h(x_i)\|}{\|Y_i \cup h(x_i)\|} \quad (2.9)$$

Precisión, Exhaustividad y Medida-F1 (basadas en ejemplos) Las métricas de precisión, exhaustividad y medida-F1 introducidas en A.2.3.1 también tienen sus equivalentes para datos multi-etiquetados y se definen de la siguiente manera:

$$precisionEj = \frac{1}{m} \sum_{i=1}^m \frac{\|Y_i \cap h(x_i)\|}{\|h(x_i)\|} \quad (2.10)$$

$$exhaustividadEj = \frac{1}{m} \sum_{i=1}^m \frac{\|Y_i \cap h(x_i)\|}{\|Y_i\|} \quad (2.11)$$

$$medidaF1Ej = \frac{2 \times precisionEj \times exhaustividadEj}{precisionEj + exhaustividadEj} \quad (2.12)$$

2.2.3.2. Métricas basadas en Etiquetas

Hasta aquí, todas las métricas mencionadas son calculadas individualmente para cada instancia y luego promediadas por el total de instancias. No obstante, también existen otros tipos de métricas, las basadas en etiquetas, que se encargan de evaluar la calidad de la clasificación etiqueta por etiqueta y determinan qué tan buena es la clasificación sobre las distintas etiquetas. En síntesis, comparan las etiquetas de la predicción contra las etiquetas reales, cada una por separado y luego combinan el rendimiento entre todas las etiquetas. Dicha combinación se realiza aplicando el promedio micro o el promedio macro. Más adelante se explicará en qué consiste cada una de ellas.

De manera similar a lo que sucedía con las métricas tradicionales de evaluación (ver anexo A.2.3.1), donde para definirlas fue necesario introducir el concepto de verdaderos positivos, verdaderos negativos, falsos negativos y falsos positivos, las métricas basadas en etiquetas también se fundamentan en esos conceptos, pero su fórmula varía para adaptarse al escenario de MLL.

$$VP_j = \|\{x_i \mid y_j \in Y_i \wedge y_j \in h(x_i), 1 \leq i \leq m\}\| \quad (2.13)$$

$$FP_j = \|\{x_i \mid y_j \notin Y_i \wedge y_j \in h(x_i), 1 \leq i \leq m\}\| \quad (2.14)$$

$$VN_j = \|\{x_i \mid y_j \notin Y_i \wedge y_j \notin h(x_i), 1 \leq i \leq m\}\| \quad (2.15)$$

$$FN_j = \|\{x_i \mid y_j \in Y_i \wedge y_j \notin h(x_i), 1 \leq i \leq m\}\| \quad (2.16)$$

Tal como sucede con el aprendizaje tradicional, bajo esta definición las evaluaciones basadas en etiquetas logran satisfacer la condición:

$$VP + FP + VN + FN = m \quad (2.17)$$

A partir de estos cuatro conceptos se pueden derivar cualquiera de las métricas definidas en A.2.3.1. O dicho en términos formales, sea $B(VP_j, FP_j, VN_j, FN_j)$ una función cuyo dominio es $B \in \{exactitud, precision, exhaustividad, medidaF1\}$, las métricas pueden ser obtenidas siguiendo dos estrategias:

Promedio Macro

$$B_{macro}(h) = \frac{1}{q} \sum_{j=1}^q B(VP_j, FP_j, VN_j, FN_j) \quad (2.18)$$

Promedio Micro

$$B_{micro}(h) = B\left(\sum_{j=1}^q VP_j, \sum_{j=1}^q FP_j, \sum_{j=1}^q VN_j, \sum_{j=1}^q FN_j\right) \quad (2.19)$$

El enfoque de promedio macro tiene una semejanza al enfoque basado en ejemplos en cuanto a que ambas estrategias promedian por el mismo valor a todas sus etiquetas/ejemplos, siendo en este caso el número total de etiquetas. Esto se traduce en que esta categoría de métricas le asigna a cada etiqueta el mismo peso, sin importar la frecuencia de la misma.

Por el contrario, el enfoque de promedio micro sí provoca una ponderación en las etiquetas y la contribución de cada etiqueta al valor final no será el mismo. Esto sucede porque la métrica se computa solo una vez, habiendo ya calculado la cantidad de etiquetas para cada uno de los cuatro conceptos, lo que hace que aquellas etiquetas que se activan en escasas ocasiones vayan a tener una menor injerencia y, por tanto, serán sobrepasadas por aquellas etiquetas más frecuentes.

2.3. Clasificación de Flujos Continuos de Datos

En esta sección se profundiza sobre algunos conceptos referidos a flujos continuos de datos y su tratamiento, de forma tal de llevar a cabo tareas de clasificación de manera exitosa. Como se describió en la sección 1.2.2, un flujo continuo cuenta con características específicas que obligan a los algoritmos de aprendizaje a adaptarse a nuevos requerimientos. A continuación, se define formalmente el concepto de flujo, se extiende el análisis sobre la tarea de evaluación para dar cuenta de su aplicación en este escenario, se describe el concepto de dato sintético y se presentan algunos algoritmos y técnicas para generar datos sintéticos útiles para clasificaciones de etiqueta única y de multi-etiquetas.

2.3.1. Definición

Un flujo continuo de datos o *data stream* es un conjunto de datos ordenados, que arriban en el tiempo y son potencialmente infinitos. Un *stream* se define como:

$$S = \{s_0, s_1, \dots, s_t, \dots, s_N\} \quad (2.20)$$

Donde s_t es la instancia presente en el tiempo t y s_N es el último dato avistado en el *stream*, pero que no necesariamente representa el final del flujo. Cada instancia d_t posee un conjunto de atributos y etiquetas y se puede definir tal como se hace en el anexo A.2.1 de tratarse de datos uni-etiquetados o como en la sección 2.2.1 de tratarse de datos multi-etiquetados.

El objetivo de la tarea de clasificación en este escenario es el mismo que para escenarios de *batch*, esto es, hallar una función capaz de enlazar instancias nuevas con sus etiquetas correspondientes, con la salvedad de que se debe lograr bajo restricciones de tiempo y espacio de almacenamiento, además de otras vicisitudes presentadas por las características mismas de un flujo continuo de datos (ver sección 1.2.2.1). Del mismo modo, deben ser capaces de afrontar los desafíos algorítmicos que presenta este escenario (ver sección 1.2.2.2), siendo de principal relevancia la capacidad de extraer información en tiempo real de datos que son voluminosos, arriban a altas velocidades, y puede cambiar su distribución en el tiempo. Estas características implican que obtener soluciones exactas es poco probable y es necesario aplicar técnicas y metodologías especiales de evaluación sobre los modelos, para reducir el error posible. El campo de la minería de *streamings* no solo abarca algoritmos de clasificación, sino que también ha sido exitosamente aplicado para tareas de regresión, *clustering* y minería de patrones frecuentes, entre otros [3].

2.3.2. Evaluación

Como se describe en el anexo A.2.3, la tarea de evaluación para aprendizaje en ambientes de *batch* consiste en dividir al conjunto de datos en uno o más subconjuntos de entrenamiento y pruebas. El ambiente de *stream*, por su parte, presenta un desafío extra y es que no permite llevar a cabo esta división debido a que no se cuenta con los datos previamente almacenados. Además, se debe tener en consideración la naturaleza incremental y evolutiva de los datos: a medida que el tiempo transcurre pueden surgir nuevas etiquetas, ciertos atributos pueden dejar de tener peso en la predicción o incluso puede suceder que algunas de las reglas de decisión en el modelo pierdan relevancia. Por lo tanto, se han presentado dos enfoques nuevos, similares a las estrategias definidas en A.2.3.2 pero acondicionados a los escenarios de flujos continuos de datos.

Evaluación holdout La evaluación por retención o *holdout* es un método derivado de la técnica de validación cruzada pero adaptado a ambientes de flujos continuos. Consiste en usar una parte del *stream* como conjunto de entrenamiento y, periódicamente, extraer una serie de conjuntos de prueba, llamados conjuntos de *holdout*, que son usados para computar las métricas de evaluación y que, por tanto, no deben haber sido observados por el modelo previamente. *Holdout* es un método que requiere contar con flujos continuos lo suficientemente grandes para que la evaluación sea precisa, lo cual no siempre es posible y es uno de los impedimentos que hacen que esta estrategia tenga menor trascendencia que otras.

Evaluación Prequential La técnica de evaluación *Prequential* o *test-then-train* consiste en realizar la evaluación de cada instancia primero y luego usarla para actualizar el modelo. En consecuencia, ya no hay una división en subconjuntos de datos independientes, sino que todas las instancias son usadas para evaluar y luego clasificar, en un mismo instante de tiempo. A diferencia del enfoque de *holdout*, no es necesario que el conjunto de datos sea grande y la evaluación *prequential* permite alimentar al modelo con todos los datos de la colección, lo que se traduce en un aprovechamiento máximo del *stream*. Por estas razones, el enfoque *prequential* tiende a ser el más usado en este campo de estudio.

En cuanto a las métricas de rendimiento utilizadas, en el ámbito de clasificaciones de flujos continuos se usan las mismas métricas de clasificaciones por *batch* con la salvedad que el cómputo se hace de manera incremental. En otras palabras, a diferencia de los métodos clásicos de validación cruzada donde la evaluación se hace en una única pasada,

una vez generado el modelo final, aquí se debe calcular la métrica en cada nueva instancia y los resultados se van acumulando. En definitiva, las métricas son las mismas que fueron introducidas en el anexo A.2.3.1 para datos de etiqueta única y en la sección 2.2.3 para datos multi-etiquetados.

En términos generales, los algoritmos de evaluación en ambientes de *streaming* deben cumplir con el siguiente ciclo [3]:

- Obtener una instancia no etiquetada x .
- Realizar una predicción $y = h(x)$ para hallar las etiquetas de x dado el modelo h .
- Obtener la o las etiquetas reales Y de la instancia x .
- Usar el par (x, y) para entrenar el modelo h , y el par (y, Y) para actualizar las métricas de evaluación que dan cuenta del rendimiento del clasificador.
- Proceder con la siguiente instancia.

2.3.3. Datos Sintéticos

Los datos sintéticos son datos generados artificialmente, es decir, que en lugar de surgir a partir de procesos o eventos del mundo real, proceden de métodos algorítmicos diseñados a ese fin. Su objetivo es aproximar datos del mundo real y son una alternativa viable cuando los datos existentes no son suficientes para conducir experimentos adecuados.

Generar datos sintéticos es una práctica frecuente en la literatura para simular ambientes de flujos continuos de datos, el principal motivo es la falta de colecciones de *streams* del mundo real que sean lo suficientemente grandes y que al mismo tiempo cumplan con todos los requisitos necesarios para evaluar algoritmos en este escenario [22]. Pese a esta restricción, se han hallado ventajas comparativas en la aplicación de flujos sintéticos en el análisis y evaluación de algoritmos, entre ellas se encuentran las siguientes [33]:

- Tienen un costo de almacenamiento relativamente menor.
- Cumplen con el requisito de ser teóricamente infinitos.
- Su generación es automatizable lo cual facilita su reproducibilidad entre experimentos.
- Es posible introducir cambios de concepto artificiales para realizar un análisis incisivo de los algoritmos de clasificación bajo escenarios dinámicos y cambiantes.
- Ayudan en el ámbito académico y científico a realizar estudios y experimentos más abarcativos.

En la actualidad existen varios generadores de flujos sintéticos que logran cumplir con los requisitos necesarios, aquí se describen dos de ellos: “Generador de Árbol Aleatorio (RTG)” y “Generador de Función Radial Base (RBF)”.

Generador de Árbol Aleatorio (RTG) El generador se basa en la técnica presentada por Domingos y Hulten [10] y consiste en producir un *stream* partiendo de un árbol construido aleatoriamente. A fines de generar el árbol, el método selecciona un atributo al azar para realizar el corte y posteriormente le asigna una clase aleatoria a cada hoja. A partir de este árbol se van a generar las instancias sintéticas. Primero

se asignan valores aleatorios a los atributos, siguiendo una distribución uniforme, y luego con esos valores se atraviesa el árbol para hallar las clases de la etiqueta. Teniendo en cuenta que las instancias son generadas y clasificadas según un modelo con estructura de árbol, en teoría este método favorece a algoritmos del tipo de árboles de decisión.

Generador de Función Radial Base (RBF) El generador produce un *stream* de función de base radial aleatoria. El método actúa de la siguiente manera: se generan un número fijo de centroides y cada centro tiene una posición aleatoria, una única desviación estándar, una clase y un peso. Para generar una instancia se selecciona un centro al azar, teniendo en cuenta el peso asociado, de tal manera de favorecer a los centros con mayor peso. La clase del ejemplo es determinada por el centroide elegido. El siguiente paso es seleccionar una dirección tal que aleje los valores de atributo del punto central. La dirección es obtenida aleatoriamente, siguiendo una distribución gaussiana cuya desviación estándar es determinada por el centroide elegido. El resultado, en términos geométricos, es una hiperesfera en donde cada ejemplo rodea un punto central con densidades variables [22]. Este método surge de la necesidad de generar conceptos que no favorezcan a modelos de tipo árbol, tal como sí lo hacía la técnica RTG.

En lo que refiere a datos multi-etiquetados, las herramientas existentes son más reducidas. Read, Pfahringer y Holmes han presentado un marco general de trabajo para la generación de flujos continuos multi-etiquetados [33] con el objetivo de generar datos realistas o que se aproximen a instancias del mundo real. El procedimiento consiste en tomar la salida obtenida por los algoritmos generadores de datos de etiqueta única y transformarla en datos multi-etiquetados, y esto lo hacen obedeciendo a fenómenos, comportamientos o cualidades intrínsecas a las colecciones multi-etiquetadas del mundo real. La idea es que si estos fenómenos capturados en datos reales se cumplen en grado similar para los datos sintéticos entonces se ha logrado generar una colección de datos de valor. Los fenómenos presentados son los siguientes:

Sesgo de etiquetas Es el fenómeno por el cual existen etiquetas que se presentan en los datos más frecuentemente que otras. A diferencia de colecciones de etiqueta única, puede haber más de una etiqueta por instancia lo que lleva a que este fenómeno se magnifique en colecciones multi-etiquetadas. A su vez, en colecciones de texto es muy común encontrar unas pocas etiquetas que predominan y otras que pertenecen a subconjuntos de instancias muy específicas. Por ejemplo, una etiqueta como “Ficción” es muy probable que sea relevante en colecciones de cuentos literarios e incluso que figure junto con otras etiquetas, por ejemplo {Ficción, Drama}. No sucede lo mismo con etiquetas tales como “Elefantes”, que probablemente aparezcan de manera aislada para este conjunto de datos. Por lo tanto, si se desea generar una colección sintética de texto es posible que se quiera ajustar el valor del parámetro de sesgo de etiquetas para que sea mayor al de otro tipo de colecciones.

Distribución de etiquetas La distribución de etiquetas tiene que ver con la forma en que la cardinalidad de etiquetas se distribuye a lo largo de la colección. La cardinalidad de etiquetas, tal como fue formulada en la ecuación 2.1, es la cantidad de etiquetas promedio por instancia y es una de las métricas usadas para conocer el grado de multi-etiquetado de los datos (ver sección 2.2.1). Observar la distribución de etiquetas es útil para entender la composición de dicha cardinalidad y se calcula tomando el número de veces que se repite cada posible tamaño de subconjuntos de etiquetas.

Basándose en este fenómeno se distinguen dos tipos de colecciones, “A” y “B”. Las colecciones de tipo A son aquellas donde la cardinalidad de etiquetas es muy cercana a uno, pero resultan ser multi-etiquetadas por la existencia de ejemplos donde el etiquetado único generaría ambigüedad y se resolvió añadiendo etiquetas. Tal es el caso para colecciones de artículos periodísticos [25] o de imágenes para realizar detección de objetos [5]. Por contrapartida, las colecciones de tipo “B” son aquellas donde existe más de una etiqueta por instancia y suelen situarse en dominios abarcativos. Es el caso para colecciones de funciones genómicas, por ejemplo, en la cual se espera que los genes tengan múltiples funciones [9]. Otros ejemplos son los de correos electrónicos [23] y conceptos semánticos [40].

Relación entre etiquetas Esta cualidad tiene que ver con el concepto de interdependencia entre etiquetas, descrito en la sección 1.2.1, y se trata de capturar la aparición mutua de etiquetas en los ejemplos de tal manera de reflejar el grado de dependencia de las etiquetas en el dominio del problema. La idea es que un generador de instancias sintéticas debe ser capaz de asignar subconjuntos de etiquetas, ya no de manera aleatoria, sino respetando esta relación subyacente. Esto se puede lograr diseñando una matriz cuadrada de doble entrada que guarde las probabilidades condicionales entre pares de etiquetas.

Espacio de atributos Así como existen relaciones entre etiquetas que los algoritmos explotan para generar datos sintéticos de calidad, también puede analizarse el espacio de atributos y las interdependencias entre sí para optimizar los generadores. El estudio realizado por Read, Pfahringer y Holmes halló efectos o particularidades frecuentes en los datos: uno de ellos es el efecto “atributo-etiqueta” por el cual hay atributos que de aparecer en un ejemplo activan una etiqueta. El ejemplo dado surgió en una colección de artículos de noticias tecnológicas [36], en donde se observó que los atributos “linux” y “mobile” estaban fuertemente emparentados con las etiquetas “Linux” y “Mobile”, respectivamente. Otro efecto hallado es el denominado “atributo-combinación” por el cual la aparición de un atributo activa un subconjunto de etiquetas en simultáneo. Por ejemplo, en una colección de noticias [25] se descubrió que el atributo “arms” ocurre frecuentemente con las etiquetas {politics.guns, misc.religion}. Del mismo modo, existe el “efecto aleatorio”, el cual engloba a los atributos que no proveen información significativa sobre la presencia de etiquetas o combinaciones de etiquetas. En definitiva, los generadores pueden sacar provecho de este fenómeno otorgando parámetros que permitan ajustar el grado de presencia de los efectos mencionados y así lograr colecciones de datos sintéticos más realistas.

3. METODOLOGÍA

Conforme a los objetivos planteados en la sección 1.4 se presentan las colecciones y algoritmos que serán evaluados junto con los escenarios de flujos continuos diseñados a este fin. En la sección 3.1.1 se describen las técnicas presentadas en este trabajo: una variante a un método de generación de flujos continuos (subsección 3.1.1) y un algoritmo novedoso de clasificación MLL basada en ensambles (subsección 3.1.2). Finalmente, en la sección 3.2 se describen los materiales y métodos seleccionados para llevar a cabo los experimentos.

En primer lugar, se seleccionaron tres colecciones de datos de multi-etiquetas que han sido puntos de referencia en otros trabajos de investigación. Cada una de ellas fue transformada en un flujo continuo de datos que cumple con las características presentadas en la sección 1.2.2.1. A su vez, se generaron instancias sintéticas que sean fieles a las cualidades subyacentes de los datos originales. Para ello, se diseñó un algoritmo basado en la implementación de Read, Pfahringer y Holmes [35], y que además hace uso de un vector de probabilidades a priori de cada etiqueta, junto con una matriz de probabilidades condicionales entre pares de etiqueta, para respetar sus interdependencias subyacentes y así obtener datos más próximos a los originales. Adicionalmente, se realizó un estudio de los *streamings* sintéticos generados en búsqueda de conocer su grado de proximidad o cercanía con respecto a sus respectivas colecciones originales. El estudio incluye una comparativa entre el método de Read, Pfahringer y Holmes y la alternativa aquí presentada. En la sección 3.1.1 se entrará más en detalle al respecto.

En segundo término, se diseñó e implementó el ambiente de pruebas para realizar el entrenamiento y evaluación de los algoritmos de MLL en ambientes de *streaming*. La etapa de entrenamiento se llevó a cabo con algoritmos de clasificación multi-etiquetas que han sido adaptados a ambientes de flujos continuos para hacer frente a las cualidades incrementales inherentes a este contexto. Se seleccionaron algoritmos de la familia de “Transformación del problema” y “Adaptación del algoritmo”, junto con soluciones de ensamble, a fines explorativos y para extender el conocimiento sobre sus fortalezas y debilidades. Los experimentos se realizan con algoritmos implementados en el lenguaje de programación Python ¹. Aquellos que no soportan datos de múltiples etiquetas han sido acondicionados a ese fin de acuerdo al diseño especificado en la literatura y consultando las respectivas implementaciones en otros lenguajes de programación, de hallarse estas disponibles al público. Todos los algoritmos utilizados para las pruebas se encuentran disponibles al público [28].

De manera complementaria, se diseñó una solución de ensambles llamada Ensamble Fijo por Mayoría Ponderada (EFMP), basada en las implementaciones existentes. La misma usa como clasificadores base tres algoritmos de MLL diferentes, que se mantienen fijos, es decir, el número de clasificadores base no cambia durante el entrenamiento. La diversidad está dada por los algoritmos miembros del ensamble y también por sus rendimientos previos. Con respecto a esto, el ensamble mantiene un vector de pesos para cada clasificador base que guarda el valor de ponderación de un miembro con respecto a una etiqueta. En caso de que una instancia sea mal clasificada, se penaliza el clasificador y se reduce dicho valor de ponderación. La combinación de los votos se lleva a cabo por votación por mayoría ponderada, teniendo en cuenta la predicción realizada por cada miembro y su respectivo vector de pesos. La implementación se basa en la presentada por Kolter y Mallof [24] descrita en la sección 2.2.2.3. Los autores también ponderan los clasificadores,

¹ <https://www.python.org/>

pero usan un único algoritmo para generar los n clasificadores base, y no contemplan problemas de múltiples etiquetas. Los experimentos se realizan con dos versiones, una de ellas se entrena con todas las instancias del subconjunto de entrenamiento y la otra tomando muestreos siguiendo la distribución de *poisson*, tal como se realiza para ensambles del tipo de *Oza bagging* [30]. En la sección 3.1.2 se describirá en detalle esta solución de ensambles. La implementación del algoritmo y sus variaciones también se encuentra disponible al público ².

Para la etapa de evaluación se siguió la estrategia “*Prequential*”, descrita en la sección 2.3.2. Para cada algoritmo se genera un modelo para entrenar y predecir sobre las tres colecciones de datos seleccionadas. Cada modelo realiza primero la predicción sobre una instancia sin sus etiquetas, luego se entrena con las etiquetas reales y se actualizan las métricas con las etiquetas inferidas y reales. Se aplicaron métricas de MLL basadas en etiquetas, en ejemplos, y además se mide la eficiencia de los modelos en términos de velocidad y espacio de almacenamiento. Con los resultados obtenidos, se realizó un estudio comparativo del rendimiento por cada colección, y se analiza cuáles son los modelos que mejores resultados han obtenido para cada caso.

El marco metodológico de este proyecto se ajusta a los procedimientos efectuados previamente por otros investigadores de la literatura [29, 41, 7, 50, 37]. Con ello se ha buscado expandir el conocimiento empírico de los algoritmos al mismo tiempo que proporcionar nuevos estudios que sean contrastables con los ya existentes. Dichos estudios también incluyen el análisis de las evaluaciones realizadas por el ensamble EFMP y su comparativa de rendimiento con respecto a otros algoritmos conocidos del campo. En cuanto a la generación sintética de datos, este proyecto siguió la línea de investigación presentada por Read, Pfahringer y Holmes. A este respecto, se generaron *streams* sintéticos bajo el método presentado por dichos autores y bajo el método aquí presentado. Con dichos *streams* se realizó un análisis de las cualidades y fenómenos hallados, siguiendo las directivas presentadas en su escrito [33]. Se destaca también el trabajo de Read y col. [37], quienes analizan algoritmos multi-etiquetas con flujos reales y sintéticos, pero a diferencia de este trabajo, generan instancias sintéticas para colecciones nuevas y sin basarse en colecciones reales específicas. La implementación del generador que usaron en sus experimentos se encuentra disponible al público [34] y ha sido el punto de partida para desarrollar la técnica aquí propuesta. Büyükcakır, Bonab y Can, por su parte, no generan flujos sintéticos, pero conducen experimentos similares en lo que respecta a la evaluación de algoritmos, poniendo el foco en modelos de ensambles. La implementación de sus experimentos también ha sido liberada al público ³ y fue uno de los modelos a tener en cuenta en el análisis de rendimiento de la solución de ensambles EFMP. Otros puntos de referencia para estudiar el algoritmo aquí presentado fueron los modelos iSOUP-MT e iSOUP-RT de Osojnik, Panov y Džeroski [29] y ML-SAM-kNN de Roseberry y Cano [38].

3.1. Técnicas Propuestas

En esta sección se describen dos técnicas implementadas para este trabajo: un generador de instancias sintéticas para flujos continuos de datos y el diseño de una solución de ensambles para realizar clasificaciones.

² <https://github.com/Juancard/multi-label-classification-on-data-streamings>

³ <https://github.com/abuyukcakir/gooweml>

3.1.1. Generación de Flujos Sintéticos

El generador presentado es un algoritmo que emplea técnicas probabilísticas para hallar dependencias entre etiquetas y reproducirlas en las nuevas instancias. La existencia de interdependencias entre etiquetas ha sido explorada reiteradas veces en la literatura [43, 35] y se ha demostrado que existen dependencias condicionales e incondicionales, esto es, etiquetas que dependen entre sí dado uno o más atributos de una instancia (dependencia condicional), y etiquetas cuya dependencia existe para todo el conjunto de instancias (dependencia incondicional). Estas dos cualidades son directamente extraídas de las colecciones reales y a partir de ellas se genera el espacio de atributos y etiquetas que, al fusionarse, constituyen la instancia sintética.

La dependencia incondicional parte de la idea de que hay etiquetas que se activan en conjunto con frecuencia y otras que son mutuamente excluyentes. Véase el caso de las etiquetas “Ficción” y “No Ficción”, por ejemplo, que son excluyentes en el dominio de géneros literarios. Para capturar esta relación se acude al concepto de probabilidad a priori y probabilidad condicional de etiquetas. La probabilidad a priori de una etiqueta es obtenida a partir de observar su frecuencia relativa en la colección y normalizarla por la cardinalidad de etiquetas. La frecuencia relativa se formula de la manera tradicional:

$$FrecRelE_j = \frac{1}{m} \sum_{i=1}^m y_{i,j} \quad (3.1)$$

La normalización toma en cuenta el valor de cardinalidad de etiquetas del conjunto de datos, esto bajo la recomendación de los autores del trabajo de referencia [37].

$$NormCardE = \frac{1}{CardE} \sum_{j=1}^q FrecRelE_j \quad (3.2)$$

Donde $CardE$ se define tal como en 2.1, esto es:

$$CardE(D) = \frac{1}{m} \sum_{i=1}^m \|Y_i\| \quad (3.3)$$

Luego, la probabilidad a priori de la etiqueta j se expresa de la forma:

$$P(E_j) = \min\left(1, \frac{FrecRelE_j}{NormCardE}\right) \quad (3.4)$$

El resultado es un vector $[P(E_1), P(E_2), \dots, P(E_q)]$.

A partir de $P(E_j)$ se puede calcular la matriz condicional θ sobre los pares de etiquetas, esto es, $\theta_{j,k} = P(Y_j = 1 \mid Y_k = 1)$, donde $1 \leq j \leq L$ y $1 \leq k \leq L$ con $j \neq k$. Con el vector de probabilidades a priori y extrayendo las co-ocurrencias de cada par de etiquetas en toda la colección, es posible obtener cada valor de la matriz θ , aplicando la probabilidad condicional:

$$P(Y_j = 1 \mid Y_k = 1) = \frac{P(Y_k = 1 \cap Y_j = 1)}{P(Y_k)} \quad (3.5)$$

Luego, la dependencia entre etiquetas es modelada como la distribución conjunta:

$$p_{\theta}(y) = P(y_1) \prod_{j=2}^q P(y_j \mid y_{j-1}) \quad (3.6)$$

Posteriormente, se realiza la generación del conjunto de etiquetas para la instancia sintética. El algoritmo 1 muestra las instrucciones ejecutadas para concretar esta tarea. Cabe aclarar que *sample()* retorna un índice de etiqueta de acuerdo a una función de masa de probabilidad basada en las probabilidades a priori, y *random()* produce un número aleatorio de distribución uniforme.

Algorithm 1: Algoritmo de generación del conjunto de etiquetas para una instancia sintética.

Input: q : Número de etiquetas de la colección, p : vector de probabilidades a priori, $p_\theta(y)$: función definida en fórmula 3.6

Output: y : las etiquetas generadas.

```

 $y \leftarrow \emptyset_q$ 
 $j \leftarrow \text{sample}(p)$ 
 $y_j \leftarrow 1$ 
 $i \leftarrow 0$ 
while  $i < q$  do
    if  $i = j$  then continue
     $y' \leftarrow y$ 
     $y'_i \leftarrow 1$ 
    if  $p_\theta(y') > \text{random}()$  then  $y \leftarrow y'$ 
     $i \leftarrow i + 1$ 
end

```

Una vez generado el conjunto de etiquetas resta generar los valores de atributos para la instancia. Para ello se retoma el concepto ya mencionado de “Dependencia Condicional”, para conocer en qué medida la presencia de un atributo activa una o más etiquetas en la instancia, o expresado en términos formales, hallar el término $P(y|x)$ tal que:

$$P(y|x) = P(x|y)P(y) \quad (3.7)$$

Como el cálculo de la probabilidad conjunta es altamente complejo se define una función de mapeo $\zeta[a] \mapsto y_a$, donde y_a es la combinación de etiquetas más probable para el atributo a . La función θ se obtiene a través de muestreos sucesivos del generador de etiquetas, y guardando las A combinaciones más frecuentes, siendo el número total de atributos. Al mismo tiempo, el vector x candidato es obtenido usando un generador binario tal como los descritos en la sección 2.3.3. El algoritmo 2 muestra un pseudocódigo de cómo se completa el proceso. Notar que el generador binario g produce dos vectores de atributos candidatos, uno por cada clase, luego si la combinación de etiquetas para el atributo a es un subconjunto de las etiquetas generadas se toma el valor de esa posición de atributo en el vector de atributos positivos. Caso contrario, se toma del vector de negativos.

Finalmente, la instancia sintética se forma a partir de la salida de ambos algoritmos, siendo de la forma (x, y) . Este proceso será repetido para cada instancia que se solicite al generador a fin de generar el flujo sintético para la colección dada. El objetivo es obtener colecciones sintéticas que se asemejen a datos del mundo real, por lo tanto, la evaluación de los resultados se hará mediante un análisis de sus cualidades en relación con fenómenos hallados en datos reales (ver sección 2.3.3), y se contrastan los datos generados en este marco contra los producidos en el trabajo de referencia.

La configuración y parametrización de los flujos continuos generados en el marco de este trabajo serán descritos en detalle en el capítulo 4: “Experimentos y Resultados”.

Algorithm 2: Algoritmo de generación del conjunto de atributos para una instancia sintética.

Input: A : Número de atributos de la colección, g : Generador de atributos, ζ :

Función de mapeo.

Output: x : El vector de atributos generado.

$x \leftarrow \emptyset_A$

$positivos \leftarrow g(1)$

$negativos \leftarrow g(0)$

$i \leftarrow 0$

while $i < A$ **do**

if $\exists q : \zeta[a] \subseteq y_q$ **then**

$x_i \leftarrow positivos_i$

else

$x_i \leftarrow negativos_i$

end

$i \leftarrow i + 1$

end

3.1.2. Algoritmo de Ensamble

Ensamble Fijo por Mayoría Ponderada (EFMP) es una estrategia de ensamble en ambientes de flujos continuos que pondera a los clasificadores base de acuerdo a su rendimiento y ajusta los pesos en cada predicción, a fin de optimizar la exactitud y eficiencia de la respuesta, y al mismo tiempo mantenerse actualizado frente a los cambios de concepto. Además, es un ensamble que permite definir clasificadores base modelados a partir de algoritmos de clasificación diferentes para explotar la variabilidad en los mismos. La técnica de ponderación se basa en la presentada por Kolter y Maloof para la estrategia *Dynamic Weighted Majority* (DWM) [24] y fue ajustada para soportar datos de múltiples etiquetas. Otra de las cualidades del ensamble DWM es que agrega y elimina clasificadores base dinámicamente de acuerdo a su ponderación. Sin embargo, el costo computacional acarreado es notorio y los nuevos modelos añadidos son de un mismo tipo y no permite variarlos. En consecuencia, se presenta la estrategia EFMP como posible alternativa junto con una variación del mismo, EFMP2, que muestrea instancias según la distribución *poisson*. A continuación, se describen ambas técnicas en detalle.

EFMP mantiene un conjunto fijo de m clasificadores base, cada uno con un vector de pesos $W_k = [w_0, w_1, \dots, w_q]$, donde $1 \leq k \leq m$ y $w_{k,j}$ representa el peso del clasificador k para la etiqueta j . En el entrenamiento del modelo se reciben n instancias donde $n = \|D\|$ para la estrategia simple. Además, se definen los parámetros p , que es la cantidad de instancias observadas entre actualizaciones de los pesos, y β , que representa el factor en el que se decrece el peso $w_{k,j}$ ante cada clasificación errónea. β es un valor definido en el dominio $0 \leq \beta \leq 1$ y toma el valor 0,5 por defecto. Todos los pesos son inicializados en 1.

El proceso de aprendizaje se lleva a cabo de la siguiente manera: al arribar una instancia i , EFMP se la asigna a cada uno de los m clasificadores. En primer lugar, se realiza la actualización de pesos y si un clasificador C_k no predice correctamente una etiqueta j , su peso $w_{k,j}$ será multiplicado por el factor β . Luego, se entrena cada clasificador con la instancia nueva y se repite el procedimiento con la siguiente. El parámetro p es usado durante esta etapa y determina los períodos entre los cuales no se deben actualizar los pesos. Una vez completado un período se normalizan los pesos de manera tal que el máximo peso entre etiquetas es uno. El algoritmo 3 presenta el pseudocódigo de este proceso en

detalle.

Algorithm 3: Algoritmo de entrenamiento y ajuste de pesos para Ensamble Fijo por Mayoría Ponderada (EFMP)

Input: $\{X, Y\}$: Conjunto de entrenamiento, n : Número de instancias de entrenamiento, q : Número de etiquetas, β : Factor de decrecimiento de los pesos, p : Período entre actualizaciones de los pesos, C : Clasificadores base, W : Pesos de los clasificadores

```

 $i \leftarrow 0$ 
 $m \leftarrow \|C\|$ 
while  $i < n$  do
  if  $i \bmod p = 0$  then
     $k \leftarrow 0$ 
    while  $k < m$  do
       $y_i \leftarrow \text{prededir}(C_k, X_i)$ 
       $j \leftarrow 0$ 
      while  $j < q$  do
        if  $y_{i,j} \neq Y_{i,j}$  then
           $W_{k,j} \leftarrow \beta * W_{k,j}$ 
        end
         $j \leftarrow j + 1$ 
      end
       $k \leftarrow k + 1$ 
    end
     $W \leftarrow \text{escalarPesos}(W)$ 
  end
   $k \leftarrow 0$ 
  while  $k < m$  do
     $\text{entrenar}(C_k, X_i, Y_i)$ 
     $k \leftarrow k + 1$ 
  end
   $i \leftarrow i + 1$ 
end

```

Durante la etapa de predicción cada clasificador retorna su voto $v_{i,j,k}$ y el ensamble realiza la combinación computando la suma ponderada para cada etiqueta. La ecuación es la siguiente:

$$y_{i,j} = \frac{1}{\sum_{k=1}^m w_{j,k}} \sum_{k=1}^m v_{i,j,k} * w_{j,k} \quad (3.8)$$

Las etiquetas cuyo valor superen un umbral de 0,5 serán activadas:

$$y_{i,j} = \begin{cases} 1, & \text{si } y_{i,j} \geq 0,5 \\ 0, & \text{de otro modo.} \end{cases} \quad (3.9)$$

EFMP2 introduce una única variación, durante el entrenamiento. Cuando arriba una instancia i , cada uno de los clasificadores base entrena el modelo *Poisson*(1) veces con dicha instancia. Esta técnica es conocida como *online bagging* y se ha probado que se

aproxima a la estrategia tradicional de *bagging* en *batch*, cuando se entrena con ejemplos de distribución similar [30].

En el próximo capítulo se retoma este algoritmo para profundizar sobre la configuración experimental y el ambiente de pruebas en el que fueron llevadas a cabo las fases de entrenamiento y evaluación de este modelo, y de los demás algoritmos de referencia.

3.2. Materiales y Métodos

En esta sección se presentan y caracterizan las colecciones de datos utilizadas en las pruebas y luego se detalla el ambiente en el cual se ejecutaron los experimentos, incluyendo información sobre el hardware y software empleado. Una vez hecho esto, se listan los algoritmos seleccionados para las pruebas, junto con la bibliografía emparentada y la configuración particular de cada uno de ellos, y las métricas de evaluación adoptadas y con las cuales se comparan los modelos.

3.2.1. Colecciones

Nombre	Dominio	N	A	L	LC	LD
20ng	Texto	19300	1006	20	1,029	0,051
Enron	Texto	1702	1001	53	3,378	0,064
Mediamill	Video	43907	120	101	4,376	0,043

Tab. 3.1: Colecciones multi-etiquetas y sus características. N: número de instancias; A: número de atributos; L: número de etiquetas; LC: cardinalidad de etiquetas; LD: densidad de etiquetas.

Se seleccionan colecciones de datos multi-etiquetas del mundo real que han sido aplicados previamente en la literatura para evaluar la capacidad predictiva de los modelos de clasificación [29, 37, 7]. La tabla 3.1 enumera sus características principales, incluyendo métricas que describen su grado de multi-etiquetado (ver sección 2.2.1). Una descripción detallada de cada una se lista a continuación:

20ng: Es una colección que consta de casi 20 mil publicaciones provenientes de grupos de noticias y que abordan 20 tópicos diferentes [25]. La colección es de texto y fue preprocesada para formar 1006 atributos numéricos.

Enron: Es una colección de correos electrónicos seleccionados de entre los 500 mil generados por empleados de la compañía eléctrica *Enron* y filtrados durante una investigación por corrupción [23]. Su tamaño, que no supera los 2000 elementos, no es lo suficientemente grande para ser considerado un flujo continuo voluminoso, pero sí cuenta con otras propiedades como la inclusión de fechas y una evolución de los datos en el tiempo [37]. Las etiquetas se dividen en cuatro grupos, según su género (acuerdos laborales, correos meramente personales, etc.); según la información que incluyen, esto es, si el correo contiene enlaces externos, adjuntos, reenvíos, etc.; según el tono emocional que reflejan y según el tópico principal que abordan.

Mediamill: Es una colección generada a partir de 80 horas de video provenientes de transmisiones de noticias durante noviembre de 2004 [40]. Se seleccionaron más de 43 mil ejemplos y fue manualmente etiquetada con 101 conceptos, que pueden visualizarse en la figura 3.1.




Fig. 3.1: Los 101 conceptos semánticos asociados a la colección Mediamill.

Estas son solo tres de las colecciones usualmente abordadas en la literatura y se han seleccionado con el objetivo de diversificar el análisis. Enron es una colección de pocas instancias, pero muchas etiquetas, 20ng a la inversa, cuenta con pocas etiquetas, pero muchas instancias; y Mediamill, finalmente, es la colección con más instancias que hay disponible y cuenta también con un número relativamente alto de etiquetas.

Durante la ejecución de experimentos, cada colección será convertida a un flujo sintético. Además, se generará una versión sintética de cada una, siguiendo la técnica descrita en la sección 3.1.1.

3.2.2. Software

A continuación se describen las herramientas de software que fueron utilizadas para la implementación y ejecución de los experimentos.

scikit-multiflow Es una librería disponible para el lenguaje de programación Python que provee un *framework* para implementar y comparar algoritmos de aprendizaje automático en ambientes de flujos continuos de datos. Incluye pero no se limita a problemas de clasificación multi-etiquetas [28].

MOA Massive Online Analysis (MOA) es un *framework* para realizar minería de datos sobre flujos continuos de datos, implementada en Java y de código libre. Incluye algoritmos de evaluación y de aprendizaje automático como clasificadores, regresores, o de *clustering*, pudiendo ser aplicados a problemas de clasificación de etiqueta única o multi-etiquetas. También incluye herramientas para generar datos sintéticos. Tanto MOA como *scikit-multiflow* facilitan la reiteración de experimentos con distintas configuraciones, así como la comparación de resultados y la extensión de funcionalidad [4].

scikit-learn Es una librería del lenguaje de programación Python que brinda herramientas para realizar evaluación, visualización y análisis de resultados [31].

Mulan Es una librería del lenguaje Java especializada en aprendizaje por multi-etiquetas. *Mulan* incluye una variedad de colecciones de datos multi-etiquetas que han sido la fuente de otros trabajos de la literatura [45].

La herramienta MOA es usada para generar los flujos sintéticos y provee del marco de trabajo en el cual se implementó el algoritmo de generación descrito en 3.1.1. Los algoritmos de clasificación fueron implementados en Python y están disponibles bajo la librería *scikit-multiflow*. La solución de ensamble EFMP también fue implementada en esta librería. *Scikit-learn*, por su parte, provee la implementación de las métricas basadas en etiquetas, y las colecciones de datos fueron extraídas de *Mulan*.

3.2.3. Hardware

Se ha recibido apoyo del Centro de Investigación, Docencia y Extensión en TIC de la Universidad Nacional de Luján (CIDETIC), el cual ha proveído de equipos de altas prestaciones que han proporcionado la capacidad de cómputo necesaria para llevar a cabo este proyecto. El equipamiento facilitado cuenta con dos nodos de 12 núcleos cada uno, la CPU es un Intel Xeon X5675 de 3.07 GHz de velocidad de procesamiento, 12 MB de memoria caché y 6 núcleos. El espacio de almacenamiento disponible es de 1 TB y la memoria RAM es de 142 GB.

El Sistema Operativo instalado es Ubuntu 18.04 LTS y cuenta con la versión 3.6.9 de Python, el instalador de paquetes Pip en su versión 20.3.3 y Java 1.8.

3.2.4. Algoritmos

Se realizan los experimentos usando algoritmos multi-etiquetas disponibles en la librería *scikit-multiflow* junto con las implementaciones de ensambles presentadas en este trabajo: Ensamble Fijo por Mayoría Ponderada (EFMP) y su variación EFMP2. Entre los algoritmos del tipo de transformación del problema se seleccionan los de Binary Relevance (BR), Classifier Chains (CC) y Multi-label Hoeffding Tree (MLHT). Tanto BR como CC usan *naive* bayes como modelo de clasificación base y MLHT es ejecutado en su versión basada en Label Powerset (LP), siguiendo los procedimientos de Read y col. [37].

En lo que respecta a soluciones de ensamble, los modelos de EFMP contarán ambos con tres clasificadores base, siendo estos los mencionados en el párrafo anterior, es decir, CC, BR y MLHT. La comparación se hará contra el algoritmo Dynamic Weighted Majority (DWM), tal como ha sido definido por sus autores [24] pero adaptado a ambientes de multi-etiquetas (ver sección 3.1.2), y se suman al análisis los algoritmos de Ensamble de Binary Relevance (EBR) y Ensamble de Classifier Chains (ECC), tal como fueron definidos por Oza [30] y también han sido extendidos para soportar problemas de MLL [36]. Los tres algoritmos de ensamble extraídos de la literatura son configurados con diez clasificadores base de *naive* bayes, para imitar los experimentos conducidos por otros autores de la literatura [29, 37, 7].

La tabla 3.2 es un resumen de los algoritmos seleccionados junto con los clasificadores base configurados, la referencia bibliográfica y la clave que será usada en las tablas de resultados.

Clave	Algoritmo	Clasificadores base	Referencia
BR	Binary Relevance	<i>naive bayes</i>	Tsoumakas y Katakis [43]
CC	Classifier Chains	<i>naive bayes</i>	Read y col. [36]
MLHT	Multi-label Hoeffding Tree	Hoeffding Tree (HT)	Read y col. [37]
EFMP	Ensamble Fijo por Mayoría Ponderada	BR, CC y MLHT	Sección 3.1.2
EFMP2	Ensamble Fijo por Mayoría Ponderada 2	BR, CC y MLHT	Sección 3.1.2
DWM	Dynamic Weighted Majority	<i>naive bayes</i> (10 copias)	Kolter y Maloof [24]
EBR	Ensamble de Binary Relevance	<i>naive bayes</i> (10 copias)	Read y col. [36]
ECC	Ensamble de Classifier Chains	<i>naive bayes</i> (10 copias)	Read y col. [36]

Tab. 3.2: Métodos de clasificación multi-etiquetas seleccionados para ambientes de flujos continuos de datos.

3.2.5. Métricas de Evaluación

En la evaluación de algoritmos de clasificación se usan el conjunto de métricas que han sido utilizadas en otros trabajos de la literatura, tanto en escenarios de flujos [41, 50, 29] como en *batch* [26, 48, 16] y fueron descritas en la sección 2.2.3. Estas son:

Métricas Basadas en Ejemplos : *Hamming score*, *hamming loss*, *exact-match* (exactitud del subconjunto), *accuracy* (o exactitud, o *jaccard index*), precisión, *recall* (o exhaustividad) y *f1*.

Métricas Basadas en Etiquetas : *Accuracy* (micro), precisión (micro), *recall* (micro), *f1* (micro), *accuracy* (macro), precisión (macro), *recall* (macro) y *f1* (macro).

Métricas de Eficiencia : Velocidad y tamaño del modelo.

La medición de velocidad comienza en el momento que inicia la predicción y entrenamiento del modelo por primera vez y finaliza cuando el clasificador termina de procesar la última instancia de la colección. Por lo tanto, quedan afuera las etapas de evaluación, carga de la colección en memoria, generación del flujo y configuración del entrenamiento. El consumo de memoria también es monitoreado durante la ejecución del entrenamiento y predicción y toma en cuenta la estructura completa del modelo y todos sus componentes, incluyendo pesos e hiperparámetros propios y de sus clasificadores base.

Los flujos sintéticos son analizados teniendo en cuenta los fenómenos propios de colecciones del mundo real. A ese fin se estudia el sesgo de etiquetas, la relación entre etiquetas, la distribución de etiquetas y el espacio de atributos (ver sección 2.3.3).

4. EXPERIMENTOS Y RESULTADOS

En este capítulo se describen los experimentos llevados a cabo tanto para la generación de *streams* sintéticos como para el entrenamiento y clasificación de modelos de MLL. En la sección 4.1 se entra en detalle sobre la configuración de cada experimento, incluyendo hiperparámetros del entrenamiento, métodos de evaluación de las clasificaciones y los tipos de *streams* generados. Finalmente, en la sección 4.2 se exponen y analizan los resultados.

4.1. Configuración Experimental

En lo que respecta a modelos de aprendizaje automático, los experimentos fueron desarrollados en el lenguaje Python usando la librería *scikit-multiflow*. Los algoritmos de transformación del problema se aplican tal como han sido implementados en la librería con la salvedad del MLHT, al que debió introducirle una modificación para manipular la predicción, se usaba un arreglo disperso para representar las etiquetas activadas, lo cual producía un desbordamiento de memoria en el entrenamiento de colecciones grandes como la de Mediamill. Se lo suplantó por una estructura de representación densa. En cuanto a los modelos de ensambles, se adaptaron las implementaciones existentes de EBR, ECC y DWM para soportar múltiples etiquetas y para ello se debió modificar la etapa de combinación de votos para hacer frente a la nueva dimensionalidad de los datos. Por lo demás, la configuración de los algoritmos es la definida en la sección 3.2.4.

Para la etapa de evaluación se aplica la técnica de evaluación secuencial predictiva (*prequential*) con ventanas deslizantes, tal como se recomienda para ambientes de flujos continuos [14]. Ante cada ejemplo o ventana de ejemplos arribada el modelo primero realiza la predicción y luego el entrenamiento. Finalmente, las métricas de evaluación son calculadas una vez procesados todos los ejemplos de la colección y a partir de todas las predicciones producidas. Notar que a partir de esta técnica el modelo predice y entrena todas las instancias, y no solo un subconjunto de ellas como sucede con la estrategia de *holdout*. La ventana deslizante se configura en $w = \frac{N}{20}$, es decir, se divide el número total de instancias del flujo en 20 ventanas, siguiendo las directivas de Read y col. [37]. Los resultados de la evaluación son agrupados según los tipos de métrica usados, para facilitar el análisis.

Por otro lado, los flujos de datos sintéticos fueron generados a partir de las colecciones 20ng, Enron y Mediamill. Por cada uno de ellos se generan tres *streams* sintéticos:

MOA : Es un *stream* generado usando el método de los autores de referencia [33]. El número de instancias es el mismo de la colección original y el generador de atributos es Generador de Función Radial Base (RBF) (ver sección 2.3.3).

JC : Es un *stream* generado usando el método presentado en la sección 3.1.1. El número de instancias es el mismo de la colección original y el generador de atributos es Generador de Función Radial Base (RBF).

JC_BIG : Es un *stream* similar a JC, pero cuenta con un mayor número de instancias. La idea es poder determinar si a mayor el tamaño del *stream* mayor es la similitud con la colección original.

Una vez generados estos flujos sintéticos se realizó un análisis para determinar en qué grado se observan los fenómenos de la colección original en las colecciones sintéticas.

Estos fenómenos son el sesgo de etiquetas, la distribución de etiquetas, la relación entre etiquetas y el espacio de atributos, y se capturaron siguiendo la metodología del trabajo de referencia, esto es:

Sesgo de etiquetas : Para observar el sesgo de etiquetas se toma la frecuencia de cada etiqueta y se traza un gráfico de línea para cada *stream*, de esta manera es posible visualizar cuánto se asemeja el sesgo de los datos sintéticos al de los datos reales. Además, se adjunta una tabla que lista las 5 combinaciones principales para cada flujo continuo.

Distribución de etiquetas : El objetivo de estudiar este fenómeno es conocer de qué forma se compone la cardinalidad de etiquetas. Para ello se traza un gráfico que exhibe la frecuencia escalada de cada tamaño de etiquetas hallado en cada *stream*. A su vez, se adjunta un gráfico que aplica el *mean absolute error* de cada flujo continuo sintético sobre el de los datos originales, y así facilitar la comparativa entre *streams*. De manera complementaria, Read, Pfahringer y Holmes definen dos tipos de distribuciones de etiquetas: tipo “A” y tipo “B” (ver sección 2.3.3). En la sección de resultados se clasificarán los flujos sintéticos bajo esta taxonomía.

Relación entre Etiquetas : Este fenómeno se estudia observando la aparición mutua de etiquetas. Para ello se genera un gráfico que pone de manifiesto la matriz de co-ocurrencias de pares de etiquetas. El gráfico es un mapa de colores de dos dimensiones donde la magnitud del color está dada por la frecuencia en la que dos etiquetas han sido activadas en conjunto.

Espacio de Atributos : Se listan los atributos más frecuentes del flujo original y de los flujos sintéticos.

4.2. Resultados

A continuación se exhiben los resultados obtenidos de los experimentos. En primer lugar, en la sección 4.2.1 se estudian los flujos continuos sintéticos generados y luego, ya en la sección 4.2.2, se analizan los resultados de las evaluaciones.

4.2.1. Flujos Continuos Sintéticos

El estudio de los *streams* sintéticos generados se divide en tres secciones, una para cada una de las colecciones. Cada sección incluye una tabla con las características tanto del *stream* basado en datos reales como de los tres *streams* sintéticos. Luego se analizan los fenómenos propios de colecciones multi-etiquetadas y cómo estos se presentan en los flujos sintéticos, con las particularidades observadas en cada caso.

4.2.1.1. 20ng

La tabla 4.1 muestra las características de la colección original y de los *streams*. Allí se observa que la cardinalidad de la colección apenas sobrepasa la unidad, lo que significa que la mayoría de sus instancias tienen una única etiqueta. Esta característica logra ser capturada de manera aproximada por los *streams* JC y JC_BIG, pero no así por MOA que asocia más de tres etiquetas por instancia.

La figura 4.1 es una representación gráfica del sesgo de etiquetas, y muestra que la colección original tiene alrededor de veinte combinaciones con una frecuencia escalada

Nombre	20ng			
	N	L	LC	LD
20ng	19300	20	1,029	0,051
MOA	19300	20	3,397	0,170
JC	19300	20	1,067	0,053
JC_BIG	80000	20	1,062	0,053

Tab. 4.1: Características de los *streams* sintéticos generados sobre la colección 20ng. N: número de instancias; L: número de etiquetas; LC: cardinalidad de etiquetas; LD: densidad de etiquetas.

cercana a la máxima y luego un descenso brusco que culmina en la combinación 25, desde la cual se mantiene cercana a la frecuencia escalada mínima. Esta tendencia es bien replicada en los *streams* JC, pero no en MOA, donde el descenso es más escalonado y no alcanza la zona baja del eje y.

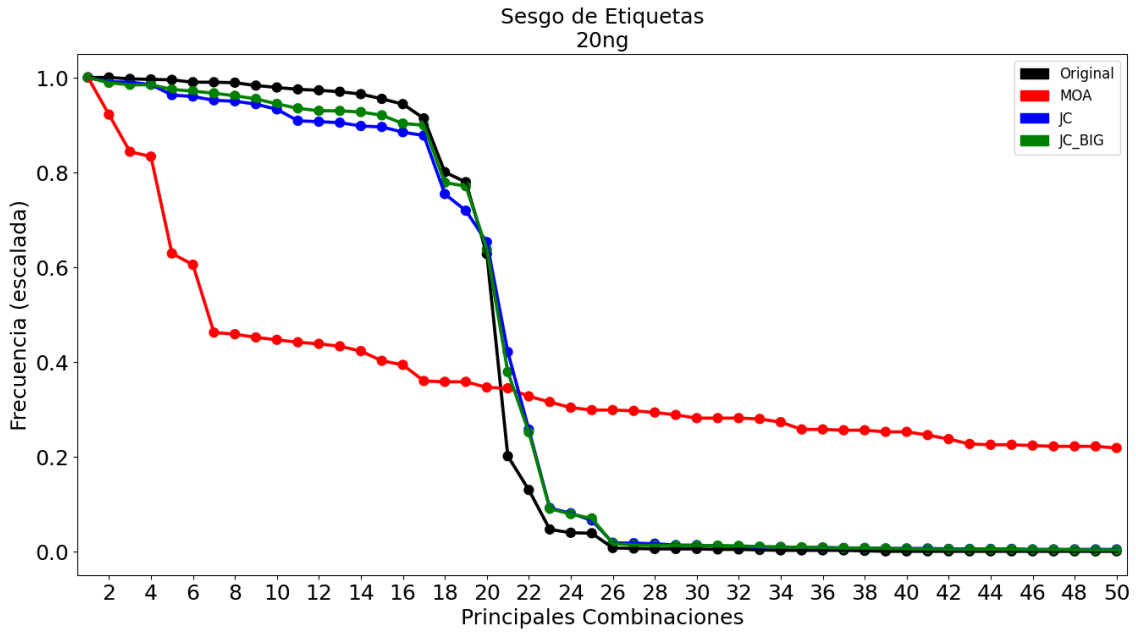
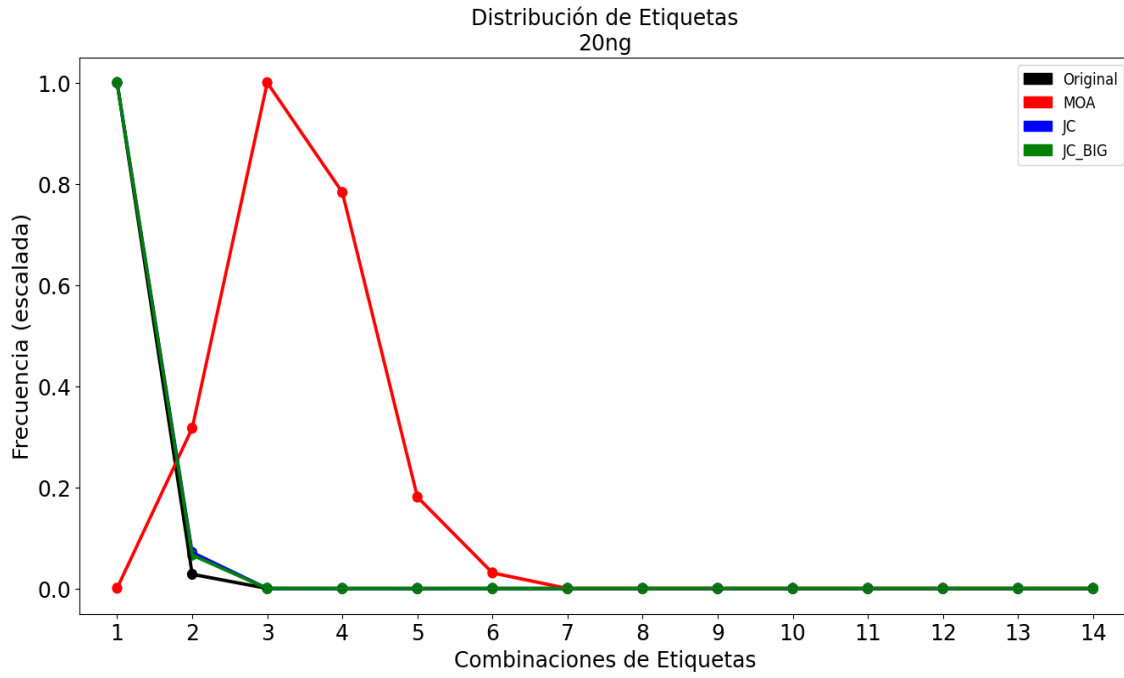


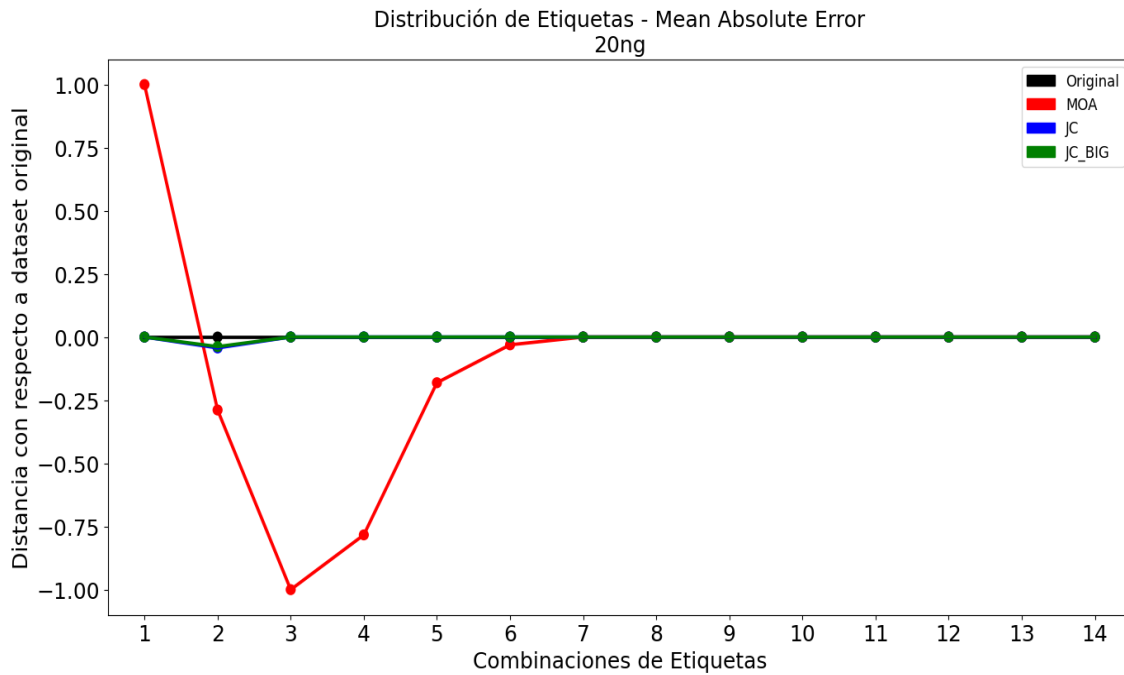
Fig. 4.1: Sesgo de etiquetas de los *streams* generados sobre la colección 20ng.

La tabla 4.2 muestra las principales 5 combinaciones de etiquetas para cada *stream*. Cabe destacar que todas las combinaciones en la tabla para los *streams* JC y JC_BIG son de una etiqueta cada una, tal como el original, pero además JC captura 3 de las 5 combinaciones principales del original: $\{religion.cristian\}$, $\{rec.sport.hockey\}$ y $\{sci.crypt\}$.

La figura 4.2 representa de manera gráfica la distribución de las etiquetas. Allí se observa cómo los *streams* aquí presentados reproducen con eficacia la composición de la cardinalidad a lo largo de los distintos tamaños de conjuntos de etiquetas. El gráfico de *mean absolute error* ayuda a reforzar esta idea. En cuanto al tipo de distribución, del cual se hace mención en el trabajo de referencia, los *streams* JC y JC_BIG, tanto como el



(a) Distribución de etiquetas para 20ng



(b) Distribución de etiquetas para 20ng - MAE

Fig. 4.2: Distribución de etiquetas de los *streams* generados sobre la colección 20ng. Arriba se encuentra el gráfico con las frecuencias escaladas y abajo el *mean absolute error* entre cada *stream* y la colección original.

Rank	Original	JC	JC.BIG	MOA
1	{religion.christian}	{sci.crypt}	{religion.christian}	{comp.os.ms.windows.misc, religion.rmisc, misc.forsale, comp.sys.ibm.pc.hardware}
2	{rec.sport.hockey}	{sci.med}	{rec.motorcycles}	{sci.space, rec.autos, rec.motorcycles, politics.guns, religion.atheism}
3	{sci.crypt}	{religion.christian}	{rec.autos}	{religion.rmisc, sci.space, misc.forsale}
4	{rec.motorcycles}	{sci.electronics}	{sci.med}	{sci.space, rec.motorcycles, politics.guns, religion.atheism}
5	{rec.sport.baseball}	{rec.sport.hockey}	{sci.electronics}	{politics.pmisc, politics.mideast, rec.sport.hockey, sci.crypt}

Tab. 4.2: Sesgo de etiquetas: Principales combinaciones de los *streams* generados sobre la colección 20ng.

original, obedecen al tipo “A”, esto es, la mayoría de los ejemplos tienen un conjunto de etiquetas de cardinalidad uno.

La figura 4.3 es una representación visual de la dependencia entre etiquetas. Ambos ejes del gráfico constan de las etiquetas de la colección y cuánto mayor es la magnitud de color en la celda (en un rango desde amarillo a rojo), mayor es la dependencia entre las dos etiquetas. Para 20ng los gráficos de la colección original, JC y JC_BIG, son casi idénticos entre sí por lo que es posible aseverar que el uso de la matriz de correlaciones en la generación de *streams* sintéticos ha contribuido a reproducir el fenómeno de la dependencia entre etiquetas para esta colección.




Fig. 4.3: Relación entre etiquetas para cada *stream* generado sobre la colección 20ng.

Rank	20ng		JC		JC_BIG		MOA	
	Atributo	Peso	Atributo	Peso	Atributo	Peso	Atributo	Peso
1	writes	10116	source	13590.5	source	56503.2	bad	12178.6
2	article	8715	issue	13267.3	issue	54918	koresh	10388.4
3	don	5654	mouse	13124.9	mouse	54359	mass	9980.54
4	1	4790	site	13037.3	site	53926.3	school	9916.83
5	2	4314	food	12971.7	food	53915.4	widget	9836.48
6	people	4258	model	12888.9	bit	53534.8	btw	9798.25
7	time	4004	bit	12885.9	model	53472.3	smith	9767.02
8	good	3727	muslim	12880.4	decision	53427.4	provide	9765.89
9	make	3231	decision	12858.8	happened	53165.4	issues	9762.76
10	3	3212	happened	12824.2	good	52918.9	faith	9756.81

Tab. 4.3: Espacio de atributos para *streams* 20ng.

Finalmente, la figura 4.3 lista los atributos más frecuentes de cada *stream* y da una idea del espacio de atributos generado. En este caso, JC y JC_BIG producen *features* muy similares y casi en el mismo orden (*model* y *bit* alternando la posición 6 entre *streams*). Los únicos atributos que aparecen en el top y no son compartidos entre estos dos flujos son *muslim* y *good*, este último, a su vez, es el único que aparece también en el top de la colección original.


4.2.1.2. Enron

Nombre	Enron			
	N	L	LC	LD
Enron	1702	53	3,378	0,064
MOA	1702	53	3,707	0,070
JC	1702	53	2,330	0,044
JC_BIG	100000	53	2,321	0,044

Tab. 4.4: Características de los *streams* sintéticos generados sobre la colección Enron. N: número de instancias; L: número de etiquetas; LC: cardinalidad de etiquetas; LD: densidad de etiquetas.

Partiendo de la tabla 4.4 se observa que el *stream* MOA se aproxima más al valor de cardinalidad de la colección original que nuestra propuesta.

Sin embargo, JC Y JC_BIG, describen una curva en el gráfico de la figura 4.4 que, en comparación con MOA, tiene una mayor similitud con la curva de la colección original. Esto es de apreciar principalmente en la forma de la curva en las primeras 6 combinaciones, donde puede verse que MOA mantiene la misma frecuencia escalada, mientras que JC y JC_BIG logran un descenso más cercano al de la curva del *stream* original.

Fig. 4.4: Sesgo de etiquetas de los *streams* generados sobre la colección Enron.

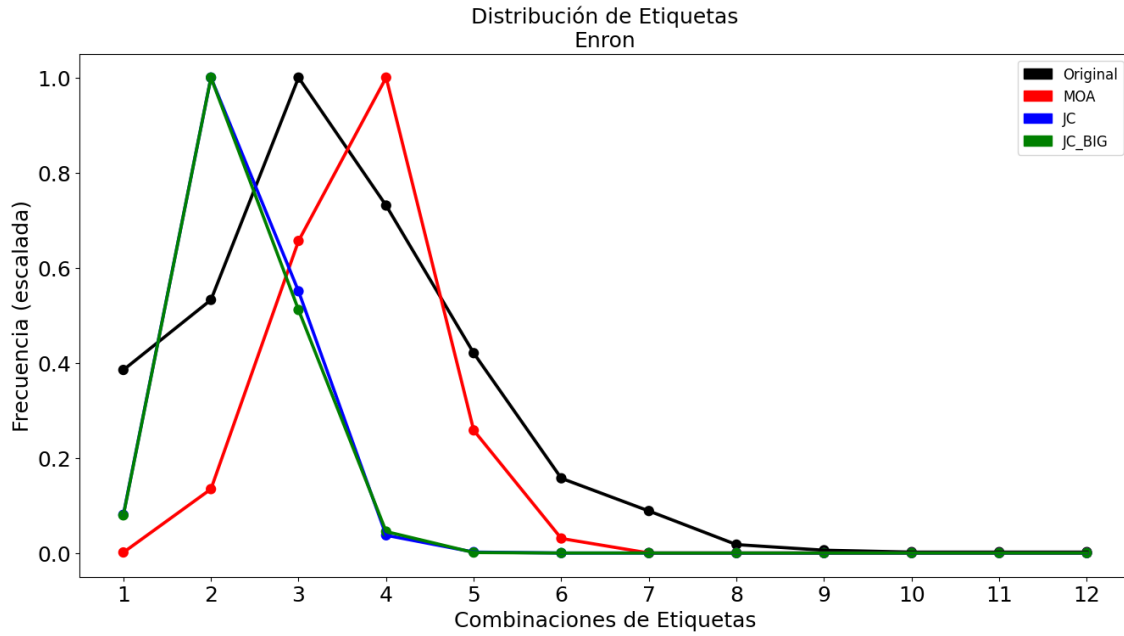
Rank	Original	JC	JC.BIG	MOA
1	{A.A4}	{A.A4, C.C13}	{A.A4, C.C13}	{B.B12, B.B4, D.D10, C.C1}
2	{B.B2, A.A4, B.B1}	{C.C10, D.D18}	{A.A6, D.D18}	{D.D1, A.A5, D.D5, B.B10}
3	{B.B2, A.A4}	{A.A4, D.D4}	{C.C10, D.D18}	{A.A8, B.B3, D.D16, B.B9}
4	{A.A1, B.B4, C.C6}	{A.A7, B.B13}	{A.A7, B.B13}	{C.C7, D.D13, D.D10, D.D18}
5	{B.B2, A.A5, B.B1}	{A.A4, B.B9}	{A.A1, D.D18}	{C.C5, B.B2, A.A6, D.D15}

Tab. 4.5: Sesgo de etiquetas: Principales combinaciones de los *streams* generados sobre la colección Enron.


Se adjunta la tabla 4.5 como complemento al estudio del sesgo. Es de apreciar que todas las combinaciones principales de MOA y JC son de la misma cardinalidad (4 y 2, respectivamente), mientras que el *stream* original muestra conjuntos de tamaño 1, 2 y 3.

Con respecto a la distribución de etiquetas (figura 4.5) no es posible determinar si alguno de los *streams* refleja el fenómeno en mayor grado que otro. Al mismo tiempo, si bien ninguno de ellos logra reproducir con exactitud la composición de la cardinalidad entre conjuntos de etiquetas, hay un grado de similitud entre curvas (ver gráfico de *mean absolute error*) que podría ser aceptable, dependiendo de la tarea a resolver. En cuanto al tipo de distribución, del cual se hace mención en el trabajo de referencia, todos los *streams* sintéticos obedecen al tipo “B”, es decir, la mayoría de los ejemplos tienen una cardinalidad de etiquetas mayor que uno.

Por otro lado, el fenómeno de la dependencia entre etiquetas es representado visualmente por la figura 4.6. Tal como sucedió con la colección 20ng, los gráficos de JC y JC.BIG para Enron reflejan una coloración muy similar al del original, aunque en un menor grado de intensidad, debido a una menor frecuencia de co-ocurrencia de cada par de etiquetas. Este comportamiento podría estar emparentado con la cardinalidad de etiquetas, que en estos *streams* sintéticos es menor. No obstante, se requieren más estudios para arribar a

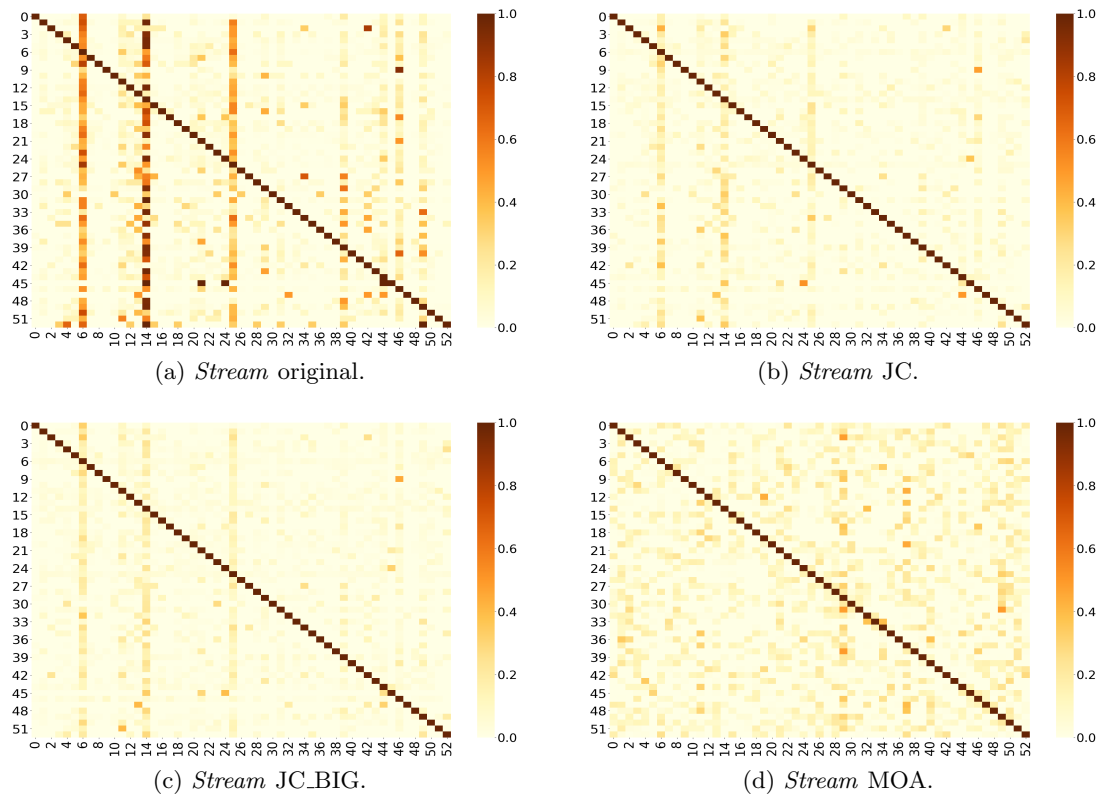


(a) Distribución de etiquetas para Enron



(b) Distribución de etiquetas para Enron - MAE

Fig. 4.5: Distribución de etiquetas de los *streams* generados sobre la colección Enron. Arriba se encuentra el gráfico con las frecuencias escaladas y abajo el *mean absolute error* entre cada *stream* y la colección original.

Fig. 4.6: Relación entre etiquetas para cada *stream* generado sobre la colección Enron.

una conclusión al respecto.

Rank	enron		JC		JC.BIG		MOA	
	Atributo	Peso	Atributo	Peso	Atributo	Peso	Atributo	Peso
1	enron	1186	cut	1238.8	cut	73252.8	past	1086.29
2	subject	1057	capacity	1190.77	capacity	70263.5	real	934.726
3	2001	856	seeking	1189.24	run	69067.8	legislature	893.989
4	steven	776	run	1172.62	bonds	68871.9	calif	892.211
5	kean	772	bonds	1169.24	seeking	68673.9	settlement	887.738
6	forwarded	681	efforts	1169.22	efforts	68102.1	agency	886.591
7	na	659	90	1154.21	90	67915.7	addition	883.931
8	pmtto	580	remains	1150.76	problem	67029.4	10	883.781
9	pm	567	problem	1139.46	remains	66706.4	diego	883.126
10	10	558	big	1135.77	big	66353.7	spent	882.981

Tab. 4.6: Espacio de atributos para *streams* Enron.

Por último, la figura 4.6 lista los atributos más frecuentes de cada *stream*. Esta vez, JC y JC.BIG comparten los 10 atributos del top y solo varía levemente el ordenamiento entre sí. MOA y la colección original comparten un atributo en el top: 10.

4.2.1.3. Mediamill

La tabla 4.7 muestra que el *stream* MOA hace un buen trabajo en aproximar la cardinalidad de la colección original.

Nombre	Mediamill			
	N	L	LC	LD
Mediamill	43907	101	4,376	0,043
MOA	43907	101	4,071	0,040
JC	43907	101	2,435	0,024
JC_BIG	500000	101	2,439	0,024

Tab. 4.7: Características de los *streams* sintéticos generados sobre la colección Mediamill. N: número de instancias; L: número de etiquetas; LC: cardinalidad de etiquetas; LD: densidad de etiquetas.

También presenta la curva de sesgo más cercana a la del flujo continuo original (ver figura 4.7). Se adjunta la tabla 4.2 como complemento al estudio del sesgo.






Fig. 4.7: Sesgo de etiquetas de los *streams* generados sobre la colección Mediamill.

Con respecto a la distribución de etiquetas (figura 4.8) las conclusiones son similares a las realizadas a este efecto para Enron. No es posible determinar con certeza que alguno de los *streams* refleja el fenómeno en mayor grado que otro, e incluso, si se analiza el gráfico de *mean absolute error*, se puede observar que hay 3 puntos donde la curva de JC se aproxima más al del original y 3 donde el más próximo es MOA. En cuanto al tipo de distribución, del cual se hace mención en el trabajo de referencia, todos los *streams* sintéticos obedecen



(a) Distribución de etiquetas para Mediamill



(b) Distribución de etiquetas para Mediamill - MAE

Fig. 4.8: Distribución de etiquetas de los *streams* generados sobre la colección Mediamill. Arriba se encuentra el gráfico con las frecuencias escaladas y abajo el *mean absolute error* entre cada *stream* y la colección original.

Rank	Original	JC	JC.BIG	MOA
1	{Class32, Class34, Class68}	{Class48, Class49, Class68}	{Class3, Class85}	{Class32, Class38, Class50, Class72}
2	{Class34, Class68}	{Class63, Class85}	{Class31, Class85}	{Class3, Class26, Class89}
3	{}	{Class31, Class85}	{Class83, Class85}	{Class18, Class34, Class35, Class89}
4	{Class67}	{Class3, Class85}	{Class63, Class85}	{Class34, Class35, Class42, Class50, Class73}
5	{Class34, Class67, Class68}	{Class34, Class78}	{Class32, Class48, Class49}	{Class34, Class35, Class42, Class50}

Tab. 4.8: Sesgo de etiquetas: Principales combinaciones de los *streams* generados sobre la colección Mediamill.

al tipo “B”, es decir, la mayoría de los ejemplos tienen una cardinalidad de etiquetas mayor que uno.

También sobre el fenómeno de la dependencia entre etiquetas se pueden hacer conclusiones similares a las de Enron (ver figura 4.9). Los gráficos de JC y JC.BIG nuevamente reflejan una coloración muy similar al del original, y con una tonalidad menos intensa que podría ser producto de un menor valor de cardinalidad existente en estos *streams* y con respecto al original.




Fig. 4.9: Relación entre etiquetas para cada *stream* generado sobre la colección Mediamill.

Finalmente, la figura 4.9 lista los atributos más frecuentes de cada *stream* y da una

idea del espacio de atributos generado.

Rank	mediamill		JC		JC_BIG		MOA	
	Atributo	Peso	Atributo	Peso	Atributo	Peso	Atributo	Peso
1	Att46	29202.3	Att49	28806.8	Att49	326968	Att115	27933.5
2	Att47	28783.2	Att10	27033.8	Att10	307780	Att80	23829.8
3	Att49	28317.5	Att57	26862.2	Att57	305180	Att64	22935.4
4	Att109	28158.8	Att70	26786.1	Att70	304988	Att34	22479.1
5	Att53	28090.6	Att104	26707.2	Att104	304122	Att24	22320.1
6	Att106	27304.5	Att26	26393.9	Att26	300480	Att89	22071.3
7	Att51	26977.3	Att75	26133.6	Att75	297402	Att35	22061.5
8	Att48	26939.2	Att45	26087.8	Att45	297152	Att37	22046.7
9	Att59	26936.2	Att108	25858.1	Att43	294576	Att98	22044.9
10	Att107	26546.8	Att64	25853.8	Att64	294074	Att76	22041.5

Tab. 4.9: Espacio de atributos para *streams* Mediamill.

4.2.2. Clasificaciones

La metodología propuesta permitió evaluar los diferentes algoritmos de clasificación multi-etiqueta para los diferentes *streams* utilizando las configuraciones sin ensambles, los ensambles de referencias y los métodos de ensamble propuestos. Los resultados se dividen en métricas de ajustes del modelo basadas en ejemplos (tabla 4.10), métricas basadas en etiquetas (tabla 4.11), y por último las métricas de eficiencia (tabla 4.12) que cuantifican el tiempo de procesamiento y espacio de almacenamiento de los modelos. Se marca en negrita la celda correspondiente al modelo que obtuvo el mejor valor de métrica para la correspondiente colección de datos. Para cerrar la sección se hace una comparativa contra experimentos de la literatura de referencia.

4.2.2.1. Resultados para Métricas Basadas en Ejemplos

Los valores de F1 obtenidos para la evaluación basada en ejemplos (Tabla 4.10) muestra que EFMP y EFMP2 fueron mejores que los *baselines* de ensambles en todos los casos. Además, superó a los que no utilizan ensambles en el *stream* de Enron. En los casos de 20ng, EFMP fue superado en un 0.001% por BR y en Mediamill MLHT superó a EFMP en un 0.015%. Para el caso de *exact-match* el modelo dominante es MLHT, lo cual es un resultado en consonancia con otros estudios de la literatura [37, 29, 50], y los modelos propuestos se ubican en segundo lugar para dos de las tres colecciones. En cuanto al *hamming score* los resultados son muy similares entre colecciones de datos, con los modelos de DWM sacando una leve ventaja para 20ng y Enron pero siendo superado por EFMP y MLHT para Mediamill. También se observan resultados competitivos en la métrica de *accuracy* donde EFMP supera a todos los modelos para Enron, incluyendo al de MLHT que es el dominante para Mediamill y 20ng.

La figura 4.10 muestra la comparativa de rendimientos entre modelos bajo la métrica de *f1*, ordenados desde el menos performante al más performante y con los modelos aquí presentados en color negro. Se puede observar cómo en cada *stream* el modelo EFMP se sitúa entre los dos mejores, siendo el de mejor rendimiento para Enron. De manera similar,

Stream	Exact-match			Accuracy (jaccard index)			Hamming score			Hamming loss		
	20ng	Enron	Mediamill	20ng	Enron	Mediamill	20ng	Enron	Mediamill	20ng	Enron	Mediamill
BR	0.228	0.018	0.001	0.292	0.210	0.091	0.952	0.912	0.711	0.048	0.088	0.289
CC	0.244	0.017	0.005	0.291	0.216	0.190	0.954	0.919	0.905	0.046	0.081	0.095
MLHT	0.315	0.055	0.048	0.321	0.127	0.302	0.934	0.928	0.957	0.066	0.072	0.043
DWM (BR)	0.171	0.021	0.001	0.185	0.152	0.123	0.956	0.938	0.800	0.044	0.062	0.200
DWM (CC)	0.167	0.024	0.014	0.176	0.156	0.259	0.956	0.939	0.936	0.044	0.061	0.064
EBR	0.153	0.012	0.001	0.182	0.193	0.096	0.953	0.928	0.726	0.047	0.072	0.274
ECC	0.115	0.012	0.001	0.133	0.189	0.246	0.952	0.938	0.923	0.048	0.062	0.077
EFMP	0.241	0.032	0.012	0.298	0.239	0.267	0.954	0.928	0.946	0.046	0.072	0.054
EFMP2	0.220	0.039	0.004	0.249	0.234	0.247	0.955	0.936	0.928	0.045	0.064	0.072

Stream	Precision			Recall			F-score (F1)		
	20ng	Enron	Mediamill	20ng	Enron	Mediamill	20ng	Enron	Mediamill
BR	0.295	0.326	0.093	0.373	0.365	0.651	0.329	0.345	0.163
CC	0.294	0.337	0.229	0.339	0.353	0.485	0.315	0.344	0.311
MLHT	0.327	0.269	0.488	0.321	0.127	0.378	0.324	0.172	0.426
DWM (BR)	0.187	0.305	0.129	0.197	0.183	0.623	0.192	0.229	0.214
DWM (CC)	0.178	0.308	0.350	0.183	0.185	0.466	0.181	0.231	0.400
EBR	0.185	0.320	0.099	0.213	0.269	0.649	0.198	0.292	0.171
ECC	0.136	0.375	0.291	0.149	0.227	0.583	0.142	0.283	0.388
EFMP	0.302	0.380	0.404	0.361	0.351	0.418	0.328	0.365	0.411
EFMP2	0.252	0.389	0.303	0.277	0.303	0.516	0.264	0.340	0.382

Tab. 4.10: Resultados de métricas basadas en ejemplos sobre los *streams* seleccionados para cada algoritmo evaluado.

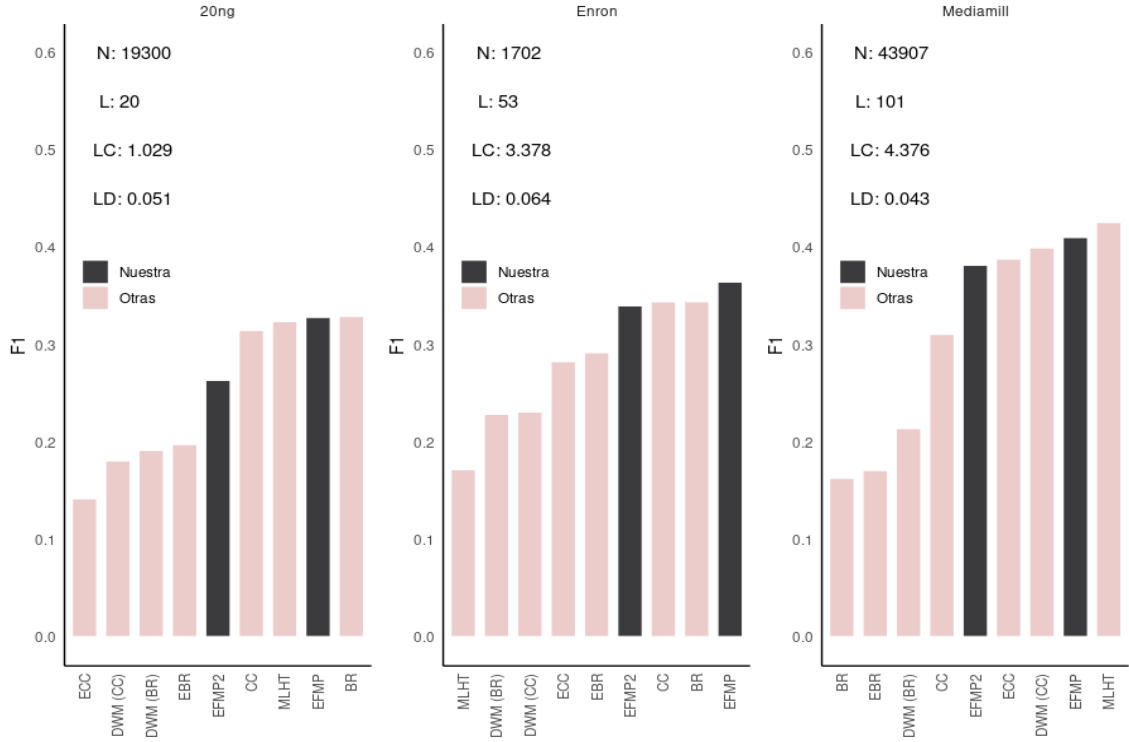


Fig. 4.10: Comparativa de modelos bajo la métrica $f1$ basada en ejemplos.

EFMP2 se sitúa en cuarto puesto para Enron y quinto para los demás. Es de notar que otros modelos no logran emparejar rendimientos entre *streams*, véase el caso de MLHT por ejemplo, que es el mejor para Mediamill, pero cae en el último puesto para Enron. Este resultado es coherente con la idea de que los modelos derivados de Hoeffding Tree requieren de un mayor número de instancias para identificar el mejor punto de corte de un nodo y lograr mejores evaluaciones [37]. Algo similar sucede con los dos modelos de DWM que logran valores altos para Mediamill, pero se ubican entre los tres menos performantes para Enron y 20ng.

4.2.2.2. Resultados para Métricas Basadas en Etiquetas

<i>Stream</i>	<i>Precision</i> (macro)			<i>Recall</i> (macro)			<i>F-score</i> (macro)		
	20ng	Enron	Mediamill	20ng	Enron	Mediamill	20ng	Enron	Mediamill
BR	0.604	0.106	0.062	0.373	0.110	0.553	0.461	0.108	0.111
CC	0.667	0.113	0.065	0.340	0.097	0.150	0.450	0.105	0.091
MLHT	0.546	0.005	0.074	0.318	0.016	0.030	0.402	0.008	0.043
DWM (BR)	0.781	0.121	0.064	0.196	0.031	0.418	0.314	0.049	0.111
DWM (CC)	0.814	0.114	0.068	0.183	0.030	0.111	0.299	0.047	0.084
EBR	0.687	0.100	0.062	0.214	0.068	0.531	0.326	0.081	0.111
ECC	0.753	0.119	0.049	0.150	0.046	0.112	0.250	0.067	0.068
EFMP	0.649	0.114	0.074	0.361	0.082	0.072	0.464	0.096	0.073
EFMP2	0.699	0.143	0.096	0.276	0.059	0.173	0.396	0.083	0.124

<i>Stream</i>	<i>Precision</i> (micro)			<i>Recall</i> (micro)			<i>F-score</i> (micro)		
	20ng	Enron	Mediamill	20ng	Enron	Mediamill	20ng	Enron	Mediamill
BR	0.552	0.330	0.096	0.373	0.364	0.673	0.445	0.347	0.168
CC	0.597	0.364	0.224	0.340	0.353	0.485	0.433	0.358	0.306
MLHT	0.345	0.283	0.509	0.318	0.079	0.342	0.331	0.124	0.410
DWM (BR)	0.773	0.552	0.131	0.197	0.178	0.642	0.313	0.269	0.218
DWM (CC)	0.796	0.569	0.328	0.183	0.179	0.463	0.298	0.272	0.384
EBR	0.633	0.412	0.101	0.214	0.285	0.671	0.320	0.337	0.175
ECC	0.644	0.534	0.299	0.150	0.242	0.579	0.243	0.333	0.395
EFMP	0.586	0.417	0.384	0.361	0.339	0.403	0.447	0.374	0.393
EFMP2	0.644	0.498	0.305	0.276	0.293	0.511	0.387	0.369	0.382

Tab. 4.11: Resultados de métricas basadas en etiquetas sobre los *streams* seleccionados para cada algoritmo evaluado.

La métrica de *f1* macro muestra resultados favorecedores para los modelos presentados. EFMP2 obtuvo un valor superior para Mediamill y EFMP fue el mejor para 20ng y el segundo mejor para Enron, por centésimas de diferencia con respecto al modelo BR. En lo que respecta a la comparativa entre soluciones de ensambles, EFMP y EFMP2 superan a las demás para todas las colecciones evaluadas. Con relación a los modelos de DWM, estos muestran una disparidad entre los valores de precisión y *recall*. Véase por ejemplo el caso de DWM (CC) para 20ng, donde logra más de un 0.8 de precisión (mejor clasificador) pero un *recall* por debajo de 0.2 (segundo peor clasificador). Mismo caso, pero a la inversa con DWM (BR) para Mediamill, el cual consigue alrededor de 0.4 de *recall* (tercer mejor clasificador) pero apenas un 0.06 de precisión (tercer peor clasificador). Esta disparidad logra suavizarse en los modelos de EFMP presentados y se ve reflejado en valores más altos de *f1*.

También son favorecedores los valores de las métricas de *f1* micro para los modelos presentados. EFMP es el mejor para las colecciones 20ng y Enron y es apenas superado por




Fig. 4.11: Comparativa de modelos bajo la métrica $f1$ con promedio macro, basada en etiquetas.

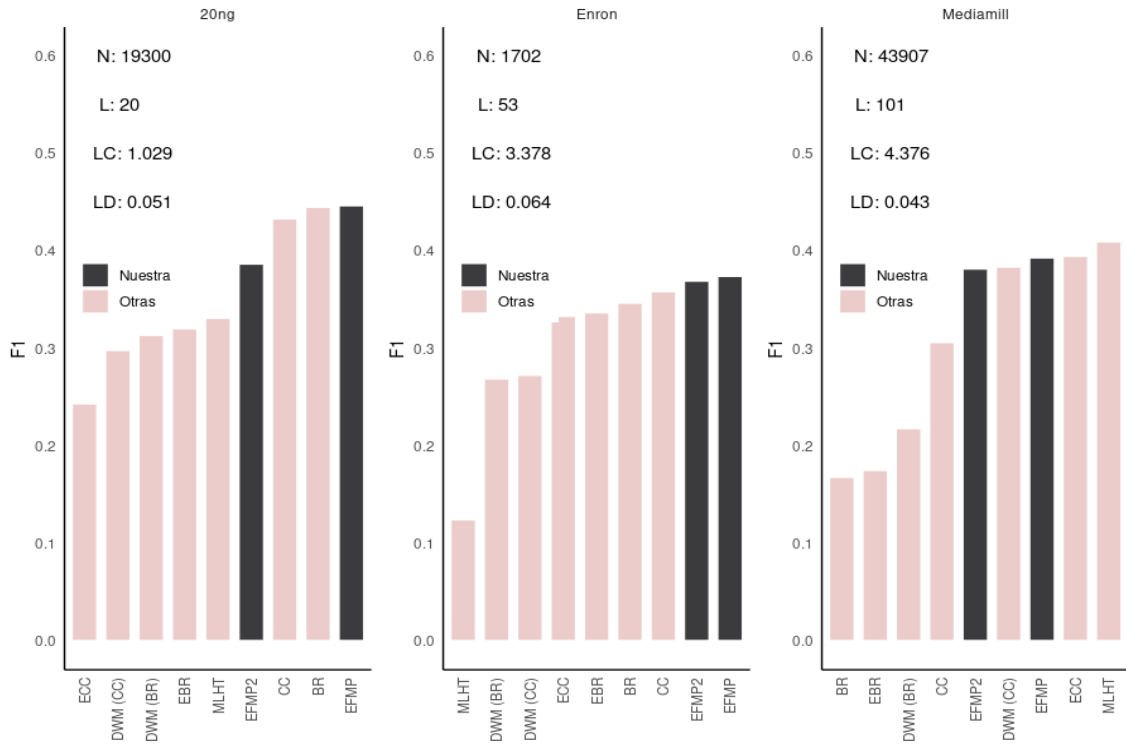


Fig. 4.12: Comparativa de modelos bajo la métrica $f1$ con promedio micro, basada en etiquetas.

MLHT para el *stream* de Mediamill. En la comparativa de métodos de ensambles, EFMP es el mejor modelo para todos las métricas a excepción del caso de *recall* para Mediamill (donde EBR obtiene el mejor valor), y los casos de precisión para Enron y 20ng, donde DWM (CC) logra una clara diferencia. Al respecto de este último modelo se puede hacer las mismas consideraciones en cuanto a la disparidad entre precisión y *recall*.

Las figuras 4.11 y 4.12 muestra la comparativa de rendimientos entre modelos bajo las métricas de *f1* macro y micro, respectivamente, y con los mejores modelos posicionados más a la derecha. Para la métrica macro-promediada se puede observar que al menos uno de los dos modelos de EFMP se posiciona entre los mejores tres para cada colección y como el mejor método de ensambles. Lo mismo sucede con la métrica micro-promediada, donde EFMP supera a los métodos de BR y CC para 20ng y Enron y queda por debajo de MLHT y ECC para Mediamill.

4.2.2.3. Resultados para Métricas de Eficiencia

<i>Stream</i>	Tamaño del modelo (kb)			Tiempo de ejecución (segundos)		
	20ng	Enron	Mediamill	20ng	Enron	Mediamill
BR	31.6	82.9	18.9	1:43:26	0:21:28	2:08:42
CC	31.9	85.1	26.7	1:45:00	0:27:05	2:52:36
MLHT	22.8	284.7	306.0	2:22:30	0:58:16	19:05:49
DWM (BR)	305.5	782.9	185.3	21:23:37	5:15:03	1 día, 4:21:27
DWM (CC)	308.4	802.7	262.4	21:03:02	5:05:56	1 día, 12:49:14
EBR	316.1	826.8	189.2	14:14:56	3:41:00	20:13:01
ECC	319.0	847.6	267.2	14:35:33	4:03:16	1 día, 1:23:01
EFMP	86.4	452.8	351.7	5:41:58	1:45:51	1 día, 0:47:17
EFMP2	84.7	359.2	262.2	5:36:55	2:03:59	1 día, 6:27:51

Tab. 4.12: Resultados de métricas de eficiencia sobre los *streams* seleccionados para cada algoritmo evaluado.

Tal como es de esperar, la tabla 4.12 muestra que los modelos *baselines* que no son soluciones de ensambles hacen un uso de espacio menor que los modelos de ensambles y logran tiempos de ejecución significativamente menores. Sin embargo, en la comparativa entre ensambles, los algoritmos propuestos (EFMP y EFMP2) reducen tanto el espacio de almacenamiento como el tiempo de procesamiento de los *streams* de Enron y 20ng. Mientras que para Mediamill, EBR hace un uso significativamente menor de tiempo que los ensambles presentados. Vale destacar que los modelos de EFMP logran mejorar los tiempos de ejecución de sus predecesores, los ensambles DWM.

4.2.2.4. Comparativa contra Literatura de Referencia

A partir de los resultados obtenidos se realiza una comparativa contra otros estudios del campo. A este fin se seleccionaron los trabajos de Osojnik, Panov y Džeroski (2017) [29], Roseberry y Cano (2018) [38], Büyükcakır, Bonab y Can (2018) [7] y Sousa y Gama (2018) [41]. Si bien las métricas y colecciones utilizadas varían según el estudio, todos los trabajos parten de una configuración experimental similar a la de este trabajo y usan el método *prequential* para evaluar rendimientos.

Osojnik, Panov y Džeroski presentaron experimentos sobre las colecciones de 20ng y Enron bajo métricas basadas en ejemplos (*hamming score*, *f1* y *exact-match*), métricas

basadas en etiquetas (precisión, *recall* y *f1*, todas ellas con promedio micro y macro). Comenzando por las métricas basadas en ejemplos, el modelo *iSOUP-MT* es el que mejor *hamming score* obtiene en sus estudios, con un valor de 0.9523, y es levemente superado por EFMP (0.954) y EFMP2 (0.955). Para el caso de Enron el ganador es *iSOUP-MT* (en su versión de ensambles) con un valor de 0.942 y supera a EFMP2 (0.936). En cuanto al *exact-match* nuestras soluciones superan a la mejor solución de los autores, *iSOUP-RT* (0.117), en un 2.05 % para 20ng y son superadas en un 6.25 % por el modelo *iSOUP-MT* para Enron (0.244). En lo que respecta al *f1*, EFMP supera en un 2.8 % a *iSOUP-RT* (0.118) para 20ng y en poco más de un 1 % a *iSOUP-MT* para Enron (0.329).

Con respecto a las métricas basadas en etiquetas los resultados también favorecen a los métodos aquí presentados. Para el *stream* 20ng EFMP2 supera en un 25.5 % a *iSOUP-RT* bajo la métrica de precisión macro, en un 238 % en *recall* macro a *iSOUP-MT* y en un 142 % en *f1* a ese mismo modelo. Para Enron nuestros modelos superan en un 111 %, 156 % y 164 % a *iSOUP-RT* para las mismas medidas mencionadas, respectivamente. Las métricas de promedio micro también favorecen a nuestros modelos. Para 20ng EFMP es superado en un 41.1 % por *iSOUP-MT* (en versión ensamble) en precisión, supera en un 213.6 % a *iSOUP-MT* en *recall* y en un 125 % en *f1*. Para Enron es superado en 33.3 % por *iSOUP-MT* (en versión ensamble) en precisión, pero consigue superar en un 45.5 % a *iSOUP-RT* en *recall* y en un 10.8 % en *f1*.

Sousa y Gama han presentado experimentos sobre los tres *streams* y bajo métricas basadas en ejemplos, en particular las de *accuracy*, *exact-match*, precisión, *recall* y *f1*. Para la comparativa se toma el mejor modelo de los autores para cada métrica. Comenzando por la métrica de *exact-match* los autores han logrado mejores resultados. Nuestros modelos son superados en un 50.6 % para 20ng, en un 71.7 % para Enron y en un 75.5 % para Mediamill. También para la precisión, *recall* y *f1* Sousa y Gama han logrado mejores resultados en general. En precisión logran superar en un 42.5 % a EFMP para 20ng, en un 25.6 % a EFMP2 para Enron y son superados en un 0.5 % por EFMP para Mediamill. En *recall* superan en un 27.5 % a nuestros modelos para 20ng, en un 29 % para Enron y en un 7 % para Mediamill. Finalmente, en *f1* superan en un 37 % a nuestros modelos para 20ng, en un 23 % para Enron y en un 15 % para Mediamill. No obstante, los autores no presentan resultados bajo métricas basadas en etiquetas.

Roseberry y Cano, por su parte, diseñaron el modelo ML-SAM-kNN y lo pusieron a prueba con las tres colecciones y las métricas de *exact-match* y *f1* basado en ejemplos. En la comparativa obtuvimos que EFMP es superado en un 26 % para 20ng, en un 86 % para Enron y en un 92 % para Mediamill. No obstante, bajo la métrica de *f1*, nuestros modelos superan en un 65 % y 229 % a sus modelos para 20ng y Enron respectivamente y es superado en un 26 % para Mediamill. Los autores no realizaron pruebas sobre métricas basadas en etiquetas.

Finalmente, Büyükçakır, Bonab y Can presentaron el modelo de ensambles *GOOWE-ML* bajo las métricas de *hamming score*, *accuracy* basado en ejemplos, *f1* basado en ejemplos y *f1* micro, basado en etiquetas. Si bien realizaron pruebas sobre varios *streams* el único en común con este trabajo es el de 20ng. Dicho esto, su modelo consigue mejores valores para las métricas de *f1* micro, *accuracy*, y *f1* basado en ejemplos (13 %, 24 % y 26 % de mejora, respectivamente) y peores valores para la métrica de *hamming score* donde nuestros modelos lo superan en un 0.3 %.

En resumen, el resultado de los métodos propuestos muestra que son competitivos respecto a la literatura de referencia. En particular, para las pruebas realizadas con el conjunto de datos 20NG los valores de *f1* basado en ejemplos obtenidos superan a [29] pero no son mejores que otros como [41, 7, 38]. En las pruebas realizadas con Enron,

los métodos propuestos superan a [29], duplican el rendimiento de [38] y son superados por [41]. Finalmente, para el conjunto de datos Mediamill tanto [41] como [38] superan nuestra propuesta.

5. CONCLUSIONES

En este trabajo se estudia la tarea de clasificación multi-etiquetas en ambientes de flujos continuos de datos. Por un lado, se aplican métodos de generación de instancias sintéticas para obtener *streamings* de múltiples etiquetas que sean representativos de escenarios del mundo real. A los parámetros de configuración ya existentes, se le agrega la posibilidad de generar instancias nuevas para una colección dada, teniendo en cuenta la matriz de co-ocurrencia de etiquetas. A su vez, se realiza una comparativa de rendimientos entre algoritmos de MLL bajo un conjunto de métricas de evaluación seleccionadas y siguiendo las metodologías y directivas utilizadas por otros autores del campo de estudio, a fin de conocer la capacidad predictiva de los modelos sobre distintos escenarios de *streamings*. Este análisis derivó en el diseño y desarrollo de una nueva solución de ensambles del tipo de votación por mayoría, llamada EFMP, que toma como clasificadores base a un conjunto fijo de algoritmos clásicos del área y clasifica una instancia de acuerdo a su rendimiento previo, penalizando a aquellos clasificadores que no han acertado la clase correcta de una etiqueta.

Con respecto a la generación de flujos continuos sintéticos, se puede aseverar que los métodos disponibles cuentan con parámetros de configuración que permiten generar datos cercanos a los del mundo real, por lo menos con respecto a los fenómenos aquí analizados, que son los de sesgo de etiquetas, distribución de etiquetas, relación entre etiquetas y espacio de atributos. Además, la inclusión de un parámetro más para indicar la matriz de co-ocurrencia de etiquetas ha dado resultados que vale la pena mencionar. En primer lugar, el uso de la matriz derivada de la colección 20ng ha contribuido a generar un *stream* sintético con mayor cercanía al del método de MOA para todos los fenómenos estudiados. Incluso en el estudio del sesgo de etiquetas para Enron se observa una curva de sesgo más próxima a la de la colección original. De cualquier manera, para esta última colección y para Mediamill no es posible observar una mejoría significativa en cuanto a la distribución de etiquetas con respecto a MOA y, por lo tanto, no es posible determinar con certeza que un método sea mejor que el otro para simular estos datos. En cuanto al análisis de la relación entre etiquetas se observa que el uso de la matriz de co-ocurrencias ha contribuido a aproximar con mayor cercanía la combinación entre pares de etiquetas de los datos originales para las tres colecciones estudiadas. Además, si bien la frecuencia de co-ocurrencia es visiblemente menor a la de las colecciones originales, es de notar que la cercanía es mayor en comparación al método ya conocido de MOA. Por último, es interesante analizar si la mejoría en la generación de instancias sintéticas para 20ng se extiende a otras colecciones de tipo “A”, es decir, colecciones donde la mayoría de las instancias tienen una única etiqueta. En lo que respecta a este estudio es posible observar que la similitud de los flujos continuos sintéticos ha sido mayor para las colecciones de tipo “A” (20ng) que para las de tipo “B” (Enron y Mediamill). No obstante, es necesario realizar más estudios para confirmar este patrón. En definitiva, se puede concluir que los métodos existentes contribuyen a obtener datos que son lo suficientemente representativos de datos del mundo real como para conducir estudios y evaluaciones de algoritmos de MLL en ambientes de *streamings*.

En cuanto a la tarea de clasificación, se llevaron a cabo evaluaciones multi-etiquetas bajo una serie de métricas comúnmente utilizadas en tareas de MLL y sobre colecciones de datos bien conocidas en la literatura. Para ello, se seleccionaron algoritmos clásicos del área, soluciones de ensambles y dos versiones del algoritmo EFMP, que han permitido exa-

minar las fortalezas y debilidades de cada modelo de clasificación. Los resultados muestran que el algoritmo propuesto logra heredar el rendimiento predictivo de métodos *baselines* como MLHT, BR y CC y, a partir de ello, obtener valores en las métricas de evaluación que son competitivos con respecto a los métodos existentes. En la comparativa con otras soluciones de ensambles los resultados son favorecedores para los algoritmos presentados. EFMP y su variante producen mejores valores para buena parte de las métricas basadas en ejemplos y etiquetas (*exact-match*, *accuracy*, precisión, *recall* y *f1*) e incluso mejoran la eficiencia de todos a excepción de EBR para Mediamill. También en varios casos EFMP superó a los *baselines*. Bajo la métrica de *f1* basada en ejemplos, esta propuesta obtiene los valores más altos para 20ng y Enron y es el segundo mejor para Mediamill; bajo la métrica de *f1* macro, EFMP es la mejor para 20ng y EFMP2 para Mediamill; y bajo la métrica de *f1* micro, EFMP supera a todas las demás propuesta para 20ng y Enron.

También en este trabajo se conduce una comparativa entre los resultados aquí presentados y los de otros autores en sus publicaciones. En este sentido, los resultados son mixtos. En algunos escenarios, como por ejemplo Enron, nuestra propuesta logra superar e incluso duplicar el rendimiento de otros algoritmos, tales como iSOUP-RT o ML-SAM-kNN. En otros escenarios, como Mediamill o 20ng, los resultados son menos favorecedores. De cualquier modo, las soluciones propuestas son competitivas en todos los casos.

Una cuestión que vale la pena mencionar con respecto a soluciones de ensambles como las aquí propuestas tiene que ver con el rendimiento bajo métricas de eficiencia como el tiempo de ejecución y el tamaño del modelo. Se puede observar, a partir de los resultados presentados, que el uso de métodos de computabilidad más compleja tienden a lanzar mejores resultados, pero acarrear un mayor costo en cuanto a recursos. Esto debe ser considerado al momento de diseñar aplicaciones del mundo real donde la disponibilidad de recursos puede ser muy limitada y podría ser adecuado optar por un modelo más simple.

En conclusión, la clasificación multi-etiquetas representa un gran desafío en sí mismo, y que se incrementa en un contexto de *streamings* de datos. A esto se suma la baja disponibilidad de colecciones públicas que tengan las dimensiones necesarias para conducir experimentos acordes a escenarios del mundo real. Bajo estas restricciones, todas las mejoras tanto en la generación de instancias sintéticas como en el rendimiento de algoritmos de clasificación son un aporte muy valioso al campo, en vías de incrementar la capacidad de predicción de los modelos.

5.1. Trabajos Futuros

Habiendo alcanzado la etapa final del proyecto, se plantean una serie de interrogantes que podrían derivar en líneas de trabajo futuras:

- Las evaluaciones de algoritmos MLL aquí realizadas pueden ser complementadas con estudios que saquen provecho de datos a gran escala, esto es, usando flujos continuos sintéticos y multi-etiquetados generados con los métodos aquí analizados. Esto permitiría llevar a cabo investigaciones en un contexto de *streaming* más cercano a los del mundo real.
- Una característica preponderante en los ambientes de *streamings* es la existencia de cambios de concepto en los datos, lo que significa que los datos pueden variar de distribución a lo largo del tiempo y de manera impredecible. Es por ello que sería de interés generar escenarios de flujos continuos que produzcan cambios de concepto y realizar evaluaciones de los algoritmos. A su vez, se podrían añadir a las pruebas otros algoritmos ya diseñados a este fin para enriquecer el estudio.

- Con respecto a las variantes de EFMP aquí presentadas, es de interés estudiar su rendimiento en ambientes que presenten cambios de concepto e implementar técnicas que mejoren su performance en dicho contexto. A este fin, una posible línea de investigación es añadir la posibilidad de que el algoritmo de ensambles reemplace de manera dinámica a aquellos clasificadores base menos eficaces durante la fase de entrenamiento, de manera tal que al producirse un cambio de concepto, el modelo pueda adaptarse en una ventana de tiempo deseable. Esta técnica es similar a la aplicada por los modelos de DWM.
- Se ha mencionado anteriormente que el uso de la matriz de co-ocurrencias en la generación de datos sintéticos puede ser más conveniente cuando se trata de aproximar colecciones de tipo “A” como 20ng. Para confirmar esta suposición, un enfoque posible es conducir experimentos con más colecciones de este tipo y comparar los resultados contra otros flujos sintéticos generados con colecciones de tipo “B”.
- El análisis de las evaluaciones realizadas por las variantes de EFMP arrojó resultados sub-óptimos para las métricas de eficiencia, tal como sucedió con otros modelos de ensambles utilizados en este trabajo. Por lo tanto, es de interés buscar caminos que conduzcan a mejorar la velocidad de ejecución en la fase de entrenamiento. En principio, sería viable adaptar la implementación de los algoritmos para que sean ejecutables bajo una arquitectura distribuida y paralela, donde cada clasificador base pueda realizar sus predicciones de manera independiente, es decir, sin esperar que finalice el clasificador anterior en forma secuencial. De esta forma, el tiempo de ejecución en la predicción de los clasificadores base sería igual al tiempo de aquel clasificador más lento, lo que podría derivar en una mejora significativa en la eficiencia.

Apéndice

A. CLASIFICACIÓN TRADICIONAL

A.1. Aprendizaje Automático

El aprendizaje automático, también conocido por su término en inglés “*Machine Learning*”, se enmarca dentro del área de la Inteligencia Artificial (IA) y estudia cómo las computadoras pueden “aprender” o mejorar su rendimiento meramente a partir de datos y sin la intervención de un ser humano. La idea detrás de esta disciplina es lograr reconocer patrones subyacentes en los datos y tomar decisiones basándose en ellos. Por ejemplo, un problema de aprendizaje automático es el de reconocer dígitos escritos a mano a partir de un conjunto de ejemplos (ver figura A.1). Aquí se tienen un conjunto de imágenes, cada una representando un dígito del 0 al 9, y el objetivo es construir un modelo que sea capaz de detectar de qué dígito se trata. Otro ejemplo es el de hallar documentos de texto que son relevantes a una consulta del usuario. En este caso el modelo recibe un conjunto acotado de términos, los cuales describen una necesidad de información del usuario, y el modelo debe ser capaz de retornar los documentos que satisfacen la consulta.

Estos problemas se suelen categorizar en aprendizaje supervisado o no supervisado, de acuerdo a si se conoce o no de antemano el concepto o etiqueta que define a los datos. Se desarrollará más sobre este punto en las próximas secciones. De entre los problemas de aprendizaje supervisado se destaca aquí el de clasificación, el cual será descrito a continuación.

A.2. Clasificación

A.2.1. Definición

La clasificación es una tarea de minería de datos muy popular que consiste en hallar modelos que describen la o las clases intrínsecas de los datos. La clase corresponde a un concepto que representa al dato y es una etiqueta categórica, es decir, un valor discreto de entre un conjunto de valores previamente conocidos. Estos modelos, también llamados clasificadores, son capaces de predecir la clase a la que corresponden datos previamente desconocidos. Por ejemplo, se puede construir un modelo de clasificación para categorizar




Fig. A.1: Dígitos escritos a mano. Fuente: *The Elements of Statistical Learning* (2009).

nuevos correos electrónicos de acuerdo a si se trata de correo basura (también conocido como “spam”) o no. Dicho análisis puede ayudar a obtener un mayor entendimiento de los datos a alto nivel. Las tareas de clasificación han sido aplicadas en áreas tales como las de aprendizaje automático, reconocimiento de patrones o estadística.

En un principio, buena parte de los algoritmos se ejecutaban en memoria, con la limitación de espacio de almacenamiento que eso conlleva. Investigaciones más recientes han desarrollado técnicas para escalar los algoritmos de tal manera que puedan manejar datos de mayor tamaño, alojados en memoria, en disco o procesados bajo demanda. Las aplicaciones para este tipo de tareas son numerosas y entre ellas se encuentran las de detectar fraudes o realizar diagnósticos médicos, entre otras.

La clasificación de datos consta de dos etapas, una de aprendizaje y otra de clasificación o predicción. Durante la tarea de aprendizaje se construye el modelo de clasificación el cual describe un determinado número de clases o conceptos. También se conoce esta etapa como la de entrenamiento, ya que se selecciona un subconjunto de los datos, llamado conjunto de entrenamiento, que consta de instancias o tuplas seleccionadas aleatoriamente y con una o más etiquetas asociadas. Formalmente, el problema de clasificación puede ser formulado de la siguiente manera. Se recibe un conjunto etiquetado de instancias, tupas o ejemplos de la forma (X, y) donde cada tupla es un vector $X = (x_1, x_2, \dots, x_n)$, siendo cada valor una característica distintiva, atributo o *feature* de la instancia. El vector y por su parte toma un valor de entre n clases diferentes.

Este tipo de tareas se engloban dentro del campo de aprendizaje supervisado ya que para cada instancia la etiqueta es conocida de antemano, y es aprovechada para guiar o, siguiendo la metáfora, “supervisar” el aprendizaje del clasificador. Esta es la diferencia principal contra algoritmos de aprendizaje no supervisado, en los cuales la etiqueta no es conocida y se deben aplicar técnicas para salvar esta restricción.

La primera etapa de una clasificación puede ser vista también como el aprendizaje de una función $y = f(X)$ que pueda predecir la clase y para una tupla X . Por ejemplo, X podría ser un mensaje de correo y la etiqueta y la decisión de si se trata de un correo basura o no. Desde esta perspectiva queremos aprender una función que sea capaz de distinguir las clases subyacentes. Usualmente, esta asociación es llevada a cabo por algoritmos de aprendizaje, los cuales internamente usan funciones matemáticas o reglas de decisión que les permiten procesar los atributos de entrada y generar una salida acorde. Algunos ejemplos de este tipo de algoritmos son los árboles de decisión, *naive bayes*, perceptrón, entre otros. Más adelante se retomará sobre este punto para describir en detalle algunos algoritmos representativos del campo.

En la segunda etapa el modelo es usado para clasificar y realizar predicciones sobre datos desconocidos. A este fin, se calcula un valor que refleja la calidad del clasificador y es denominado “métrica de evaluación”. Una de ellas es la exactitud o *accuracy*, pero no es la única. Durante la etapa de entrenamiento esta estimación puede ser imprecisa, tomando un valor que tiende a ser “optimista” o que da un valor de exactitud mayor al rendimiento real. Esto sucede porque el clasificador puede llegar a incorporar anomalías particulares en el conjunto de datos de entrenamiento, las cuales no tienen que ver tanto con el dominio de aplicación en el cual se enmarca la tarea, sino más bien con “ruido”, datos erróneos o simplemente instancias que no reflejan correctamente los objetos del mundo real. Este fenómeno es llamado “sobreajuste” u “*overfit*” y se han diseñado técnicas para reducirlo. Una de ellas consiste en separar de entre los datos de la colección completa, un subconjunto conocido como “conjunto de prueba” o de *testing* que no se usa durante el entrenamiento y a partir del cual se realizan predicciones y se calculan las métricas de evaluación.

Así pues, la tarea de evaluación es fundamental, ya que es la vía a partir de la cual

se determina qué algoritmos o técnicas son más apropiados que otros para un problema en particular. Asimismo, provee la información necesaria para corregir o ajustar los parámetros de los algoritmos y así obtener modelos más robustos.

En definitiva, las etapas de aprendizaje y predicción se aplican consecutivamente con el objetivo de lograr generar un clasificador capaz de predecir con éxito las etiquetas de instancias nuevas y a priori desconocidas por el modelo.

A.2.2. Algoritmos

Como se mencionó en la sección anterior, una de las etapas de la clasificación consiste en generar un modelo capaz de clasificar instancias no observadas. En esta etapa de aprendizaje, se pueden aplicar diversos tipos de algoritmos de clasificación de acuerdo a la naturaleza de la tarea en particular que se desea abordar. A continuación, se describen algunos de estos algoritmos en detalle a fin de ahondar sobre el concepto de clasificación en el aprendizaje automático. Además, más adelante estos algoritmos serán particularmente relevantes para el desarrollo del presente trabajo de investigación.

A.2.2.1. *Naive Bayes*

Naive Bayes es uno de los algoritmos que pertenecen a la familia de clasificadores probabilísticos y se destaca por ser computacionalmente simple, interpretación, y al mismo tiempo brinda un rendimiento competitivo en comparación con otros modelos más complejos. Se dice que es un clasificador estadístico porque se basa en el teorema de Bayes. La idea es computar una probabilidad para cada una de las clases, basada en los atributos de la instancia y seleccionar aquella de mayor probabilidad. El término “*naive*” es el inglés para el término “*ingenuo*” y nace de la presunción que hace el algoritmo de que los atributos son independientes entre sí, o condicionalmente independientes. Esta presunción raramente se cumple en los escenarios donde se aplica, pero contribuye a su simplicidad computacional y a su velocidad durante el entrenamiento.

Para entender cómo funciona este algoritmo, es bueno abordar primero el teorema de Bayes. Formalmente, se define de la siguiente manera:

$$P(H | X) = \frac{P(X | H)P(H)}{P(X)} \quad (\text{A.1})$$

En esta ecuación, el vector X es una tupla definida tal como en la sección anterior y en términos bayesianos representa la “evidencia”. $P(X)$, por lo tanto, es la probabilidad de que la tupla contenga los atributos que efectivamente posee. Por su parte, H es la hipótesis de que la tupla pertenece a una determinada clase y $P(H)$ su probabilidad. Esta es conocida como probabilidad “a priori”. De la misma manera, $P(H|X)$ es la probabilidad de que la hipótesis H sea cierta bajo la evidencia X . A esta se la llama probabilidad “a posteriori” con H condicionada por X y es el valor que se quiere determinar en una tarea de clasificación. Finalmente, $P(X|H)$ indica la probabilidad de que la tupla tenga unos atributos determinados dado que se satisface la hipótesis.

A partir de dicha definición, y de forma similar, se expresa la ecuación de *Naive Bayes* de la siguiente manera:

$$P(C_i | X) = P(X | C_i)P(C_i) \quad (\text{A.2})$$

Aquí el término $P(X)$ es descartado porque se asume constante para todas las clases. La hipótesis H es representada como C_i que es un valor de la tupla $C = (C_1, C_2, \dots, C_q)$,

donde q es el número de clases. La presunción “ingenua” es aplicada para el cálculo del término $P(X | C_i)$ gracias a lo cual se puede definir de la siguiente manera:

$$P(X | C_i) = \prod_{k=1}^n P(x_k | C_i) = P(x_1 | C_i) \times P(x_2 | C_i) \times \dots \times P(x_n | C_i) \quad (\text{A.3})$$

Finalmente, el modelo seleccionará la clase que maximice el valor de probabilidad y esa será la salida final del algoritmo.

Como se ha dicho anteriormente, la simplicidad, velocidad computacional y su competitividad en métricas de exactitud hacen de *Naive Bayes* un algoritmo destacado en el campo de aprendizaje automático [46] y ha sido aplicado para problemas diversos, tales como el de hallar errores en programas de computación [1], predecir enfermedades del corazón [11] o detectar ataques en una red de computadoras [21].

A.2.2.2. Árboles de Decisión

Árboles de decisión es un modelo de clasificación que se destaca por ser de fácil interpretación e intuitivo para el ser humano. De hecho, se puede generar una representación gráfica del árbol generado para asistir a la comprensión del modelo y así entender a más alto nivel cómo se comporta durante una predicción. En cuanto a su estructura, un árbol de decisión contiene nodos, cada uno representando un atributo de la colección. Estos nodos se conectan con otros nodos a partir de enlaces o “ramas” que representan un valor o un rango de valores de ese atributo. Los nodos de menor jerarquía son llamados “hojas” y contienen la clase de la predicción, y el nodo de mayor jerarquía es llamado “raíz”. Al momento de predecir una instancia nueva, la clasificación se realiza de la siguiente manera: se toma la instancia nueva, la cual no tiene una etiqueta asociada, y los valores de sus atributos son comparados contra los del árbol, luego se traza un camino desde el nodo raíz hasta la hoja. Finalmente, la clase que contiene la hoja es seleccionada y será parte de la predicción resultante.

Los árboles de decisión se generan a partir de un algoritmo de inducción. Existen varios de estos algoritmos, pero todos son variantes que han sido diseñadas bajo un mismo principio: construir el árbol de una manera “voraz”¹, comenzando desde el nodo raíz (conocido como enfoque *top-down*) y eligiendo en cada paso el atributo más informativo o que maximice alguna medida de ganancia de información. Entre estos algoritmos de inducción vale destacar los siguientes:

ID3 Son las siglas de “*Iterative Dichotomiser 3*” y fue desarrollado en 1986 por Ross Quinlan. Consiste en crear un árbol de múltiples vías, buscando para cada nodo el atributo categórico que lance la mayor ganancia de información para las clases categóricas. Los árboles crecen en un tamaño máximo y luego se realiza el paso de poda para mejorar el poder de generalización del modelo sobre datos desconocidos.

C4.5 Es la evolución del algoritmo ID3. La principal mejora con respecto a su predecesor es que elimina la restricción de que los atributos deban ser categóricos. Esto lo consigue particionando el valor continuo en rangos o en un conjunto de intervalos discretos. A su vez, C4.5 convierte el árbol entrenado en conjuntos de reglas de decisión.

¹ Se le llama voraz o *greedy* a un algoritmo que busca hallar la opción óptima en cada paso y, de esta manera, alcanzar la solución general óptima para resolver un problema. Esto lo diferencia de algoritmos como los de *backtracking*, los cuales exploran distintas posibilidades y pueden volver al inicio en búsqueda de una mejor solución.

CART Son las siglas de “*Classification and Regression Tree*” y es un algoritmo muy similar al C4.5, pero que soporta clases numéricas, lo cual permite que este algoritmo pueda ser utilizado para resolver problemas de regresión.

Una tarea fundamental en la generación de un árbol es definir un criterio de división. El objetivo del criterio de división es seleccionar el mejor atributo en cada paso y existen diversas técnicas para abordar el problema. Una de ellas es la de “Ganancia de Información”, usada por el algoritmo ID3. La técnica de ganancia de información busca seleccionar el atributo que posee mayor variabilidad o representatividad de los datos y se sustenta en el cálculo de la entropía o medida de desorden. La idea de fondo es hallar el atributo que reduzca la entropía esperada. La entropía en el conjunto de datos D se calcula de la siguiente manera:

$$Entropia(D) = - \sum_{i=1}^q p_i \log_2(p_i) \quad (A.4)$$

Nótese que p_i corresponde a la probabilidad de que una tupla de D corresponda a la clase C_i . A partir de la entropía, se define la ganancia de información como:

$$Ganancia(A) = Entropia(D) - \sum_{j=1}^v \frac{\|D_j\|}{\|D\|} \times Entropia(D_j) \quad (A.5)$$

Aquí el atributo A divide al conjunto de datos en v particiones, siendo v los valores posibles que toma A . D_j es el subconjunto de los datos cuyas tuplas poseen el valor v del atributo A , siendo $\|D_j\|$ su cardinalidad o número de instancias del subconjunto. Al dividir este término por la cardinalidad del conjunto de datos, se obtiene un valor que representa el peso de la partición y que es aplicado sobre la entropía esperada. Este proceso se repite para todos los atributos y, una vez obtenidos los valores de ganancia para cada uno de ellos, se elige aquel que maximiza la ganancia y finalmente el atributo seleccionado será el criterio de separación en el nodo.

El algoritmo C4.5 introdujo una mejora en esta técnica llamada “Razón de Ganancia”. La misma busca disminuir uno de los efectos adversos que provoca la técnica de ganancia de información, esta es, que tiende a favorecer a atributos con un mayor número de valores posibles. La razón de ganancia, en primer lugar, reemplaza la fórmula $Entropia(D)$ por la siguiente expresión:

$$EntropiaRG_A(D) = - \sum_{j=1}^v \frac{\|D_j\|}{\|D\|} \times \log_2\left(\frac{\|D_j\|}{\|D\|}\right) \quad (A.6)$$

A partir de allí, el cálculo de la razón de ganancia hace uso de la ganancia y de la entropía y se formula como:

$$RazonGanancia(A) = \frac{Ganancia(A)}{EntropiaRG_A(D)} \quad (A.7)$$

Finalmente, el atributo de mayor razón de ganancia es seleccionado como criterio de corte y se continúa el cálculo con los siguientes subnodos.

A.2.2.3. Ensamblados

Los ensambles son un conjunto de clasificadores cuyas salidas son combinadas entre sí con el objetivo de realizar mejores predicciones que cualquiera de ellos individualmente.

En pocas palabras, el enfoque de ensambles consiste en generar k clasificadores llamados “clasificadores base”, desde un mismo algoritmo o no, y entrenarlos con distintos subconjuntos de la colección de entrenamiento original. Dada una tupla nueva, cada clasificador devuelve su propia predicción, llamada “voto”, y luego el ensamble combina cada uno de estos votos siguiendo algún método de combinación elegido, de forma tal de producir una predicción final óptima.

La aplicación de ensambles en problemas de clasificación nace de la imposibilidad de generar un único modelo capaz de generalizar lo suficiente como para lograr un rendimiento perfecto. Ante la presencia de datos ruidosos, atípicos o erróneos los clasificadores pueden tender a clasificar mejor para un subconjunto de datos y no tan bien para otros. Este escenario es aprovechado por el enfoque de ensambles, ya que su éxito tiene correlación directa con la existencia de “diversidad” en la clasificación, distinguiendo el concepto de diversidad como la existencia de variabilidad entre los modelos, entre hiperparámetros o entre particiones del conjunto de datos. En definitiva se entiende que, cuanto mayor es esta diversidad, mayor es la probabilidad de aislar los posibles errores particulares de un modelo, y al suceder esto, el error terminará siendo filtrado por el ensamble en la clasificación final. En consecuencia, se espera lograr una disminución del error total de la clasificación así como también una mayor exactitud en la predicción, comparando contra la salida individual de cada clasificador base. Sumado a esto, un enfoque de ensambles abre la posibilidad de distribuir y/o paralelizar el cómputo de la predicción, pudiendo así mejorar los tiempos de ejecución durante el entrenamiento.

En suma, existen distintos tipos de ensamble de acuerdo a su construcción y arquitectura. A continuación se describen tres de ellos: los ensambles de tipo “*bagging*”, los de tipo “*boosting*” y los de tipo “*stacked*”.

Bagging Esta es una de las primeras técnicas de ensambles conocidas y fue introducida por Breiman[6]. La misma se desarrolla de la siguiente manera: dado un conjunto de entrenamiento D con n tuplas, *bagging* genera un número m de nuevos conjuntos de datos de entrenamiento, cada uno con n tuplas. Para esto se toman tuplas del conjunto original de manera aleatoria y con reemplazo, es decir que puede haber tuplas repetidas y otras que no están incluidas en el nuevo conjunto. Luego a partir de cada conjunto nuevo, se entrena un clasificador M_i . Cada clasificador puede ser del mismo tipo porque la diversidad está dada por los datos. En la etapa de clasificación, cada modelo M_i genera una predicción que cuenta como un voto. El ensamble cuenta los votos y elige la clase con mayor cantidad de votos, siendo esta la decisión final del ensamble.

Boosting En la técnica de *boosting* se asigna un peso a cada tupla de entrenamiento y se generan un conjunto de clasificadores, cada uno a partir del anterior. A diferencia del método de *bagging*, *boosting* trabaja siempre sobre el mismo conjunto de datos y la variabilidad está dada por los pesos que son asignados. El proceso es el siguiente: para el primer modelo de clasificación, M_i , los pesos son inicializados en un mismo valor para todas las tuplas. Una vez que se entrena este modelo, los pesos son actualizados de tal manera que el siguiente clasificador $M_i + 1$ trate de manera particular a las tuplas mal clasificadas por M_i . De ese modo se busca llegar a una clasificación correcta en las sucesivas iteraciones. Finalmente, el modelo de ensamble combina los votos de cada clasificador individual. Cabe notar que el peso de cada voto también es ponderado de acuerdo al rendimiento del clasificador base.

Stacking La técnica de *stacking* fue desarrollada por Wolpert[47] y consiste en entrenar un nuevo clasificador de acuerdo a las predicciones realizadas por otros modelos,

tomando la salida de estos modelos como entrada, de tal manera de lograr hallar una combinación que produzca una mejor predicción. Este tipo de ensambles puede ser visto como un conjunto de capas. La primera capa consta de un ensamble de clasificadores que aprenden a partir de los datos de entrenamiento. Esta capa no necesariamente usa clasificadores del mismo tipo, mismos hiperparámetros o particiones de la colección iguales, quedando estos detalles a cargo de quien diseña esta capa. La siguiente capa es el clasificador individual, o meta-clasificador, que se alimenta de las salidas de los clasificadores de la capa inferior y realiza el aprendizaje a partir de las clases producidas por estas salidas y las clases reales.

Una de las tareas a tener en cuenta durante el entrenamiento de un ensamble es la de combinar las salidas de cada modelo en una salida final. La estrategia más común y simple es la de votación por mayoría, la cual normalmente es aplicada por los métodos de *bagging*. No obstante, existen múltiples métodos de combinar los votos, e incluso no siempre un ensamble de tipo *bagging* debe aplicar esta estrategia. Por ejemplo, algunos clasificadores pueden decidir producir una salida solo en el caso de que más de la mitad de ellos coincidan, o incluso ser más restrictivos y obligar a que la coincidencia sea total. El enfoque de *boosting* por su parte, pondera al voto de acuerdo a los pesos que calcula, dando predominio a determinadas instancias. También se suele dar un mayor peso a determinados clasificadores por sobre otros. Este tipo de métodos se los denomina “votación por mayoría ponderada” y pueden llevar a un rendimiento superior si es aplicada en el escenario adecuado.

A.2.3. Evaluación

Llevar a cabo evaluaciones de rendimiento sobre los modelos es un aspecto importante del aprendizaje automático, ya que nos permite conocer en qué medida un algoritmo es superior a otro para resolver una tarea. Particularmente, la tarea de clasificación es un desafío que se presenta en un contexto cambiante y evolutivo, donde nuevas herramientas surgen y se actualizan constantemente. Incluso la composición y estructura de los modelos de clasificación varía según la familia de algoritmos aplicados, y es esperable que los conceptos extraídos de un modelo de tipo árbol tengan particularidades que lo diferencien de modelos de redes neuronales o modelos probabilísticos. Y del mismo modo, es esperable que alguno de estos modelos tenga un mejor rendimiento que otro en un determinado escenario, o incluso que sea mejor que un modelo generado por el mismo algoritmo pero con distintos hiperparámetros. La tarea de evaluación es la que permite detectar estas particularidades y sacar provecho de los algoritmos para obtener aún mejores modelos.

A su vez, es importante estudiar las métricas de evaluación existentes y llevar adelante estrategias que nos permitan obtener medidas de evaluación confiables y que no hayan sido sesgadas por los datos que se usaron durante el entrenamiento. Y del mismo modo, entender los factores que provocaron un valor de métrica puede ser el paso inicial para hallar mejoras al modelo que optimizan su capacidad de predicción en el futuro.

Por consiguiente, a continuación se estudian algunas de las estrategias llevadas a cabo durante la evaluación para evitar sesgos, así como también las métricas que se calculan durante este proceso.

A.2.3.1. Métricas

Las métricas de evaluación se usan para conocer la habilidad predictiva de un modelo de clasificación. Se van a describir aquí las métricas más conocidas del campo y que proveen, a su vez, un primer vistazo de lo que serán las métricas usadas para evaluar algoritmos para datos multi-etiquetados en las futuras secciones del escrito.

Antes de comenzar es importante aclarar algunos términos que serán usados para definir las métricas. Se entiende como “ejemplos positivos” a aquellas instancias cuya etiqueta pertenece a la clase de interés en el problema de estudio y “ejemplos negativos” como aquellas que no pertenecen a dicha clase. Al mismo tiempo, se derivan cuatro conceptos que estarán presentes en las fórmulas para calcular las métricas, los cuales son:

Verdaderos Positivos (VP) Son los ejemplos positivos que fueron correctamente clasificados como positivos.

Verdaderos Negativos (VN) Son los ejemplos negativos que fueron correctamente clasificados como negativos.

Falsos Positivos (FP) Son los ejemplos negativos que fueron incorrectamente clasificados como positivos.

Falsos Negativos (FN) Son los ejemplos positivos que fueron incorrectamente clasificados como negativos.

Una vez obtenidos estos conceptos se pueden calcular una serie de métricas a partir de ellos. Estas métricas son:

Exactitud La exactitud o *accuracy* es la proporción de ejemplos correctamente clasificados sobre el número total de instancias y a mayor el valor de exactitud mejor es el rendimiento del clasificador. Se define como:

$$exactitud = \frac{VP + VN}{VP + VN + FP + FN} \quad (A.8)$$

Tasa de Error A la inversa de la exactitud, la tasa de error es la proporción de ejemplos incorrectamente clasificados sobre el número total de instancias y a menor el valor de la tasa de error mejor es el rendimiento del clasificador. Se define como:

$$tasaError = \frac{FP + FN}{VP + VN + FP + FN} \quad (A.9)$$

Precisión La precisión es la proporción de ejemplos que fueron clasificados como positivos y que efectivamente lo son. Mayor es el valor de precisión mejor es el rendimiento del clasificador. Se dice que es una medida de exactitud y se define como:

$$precision = \frac{VP}{VP + FP} \quad (A.10)$$

Exhaustividad La exhaustividad o *recall* es la proporción de ejemplos positivos que fueron clasificados como positivos. Mayor es el valor de exhaustividad mejor es el rendimiento del clasificador. Se dice que es una medida de completitud y se define como:

$$exhaustividad = \frac{VP}{VP + FN} \quad (A.11)$$

Medida-F1 La medida-F1 o *f1-score* es una medida que integra las métricas de precisión y exhaustividad tomando la media armónica entre ambas. Mayor el valor de esta medida, mejor es el rendimiento del clasificador. Se define como:

$$medidaF1 = \frac{2 \times precision \times exhaustividad}{precision + exhaustividad} \quad (A.12)$$

Por otro lado, existen métricas para evaluar la eficiencia del clasificador en términos de velocidad y consumo de memoria. Estas métricas cobran especial importancia en ambientes de flujos continuos de datos, donde el volumen de datos es grande, la velocidad en la que arriban es alta y los recursos escasean. A continuación se añade una breve descripción de ambas.

Velocidad La velocidad se refiere al costo computacional de generar el modelo y realizar predicciones, en general se deja fuera del cálculo los tiempos invertidos en cargar la colección en memoria, realizar tareas de normalización y preprocesamiento sobre los datos y otras etapas de la clasificación. A menor el tiempo de ejecución, mejor es el rendimiento del algoritmo.

Consumo de Memoria El consumo de memoria es un indicador de los requerimientos de memoria aproximados para almacenar el modelo, así como también un indicador de resguardo para estimar el posible consumo de memoria durante la ejecución y asegurarse que el algoritmo se mantiene en actividad. A menor el consumo de memoria, mayor es la eficiencia del modelo.

A.2.3.2. Estrategias

Una vez que se define la métrica o el conjunto de métricas apropiadas para medir el rendimiento de los clasificadores, el siguiente desafío es seguir un procedimiento de pruebas capaz de lograr resultados de evaluación que puedan ser generalizables a conjunto de datos aún no observados. Las técnicas de “*Holdout*” y “Validación Cruzada” son dos de las técnicas más populares para evaluar la habilidad predictiva de los clasificadores y se describen a continuación.

Holdout En este método un conjunto de instancias es separado de la colección y se reserva para evaluar el rendimiento del clasificador. Este subconjunto es distinto del conjunto de datos de entrenamiento usado para generar el modelo y es llamado “conjunto de pruebas o *testing*”. Una vez entrenado, el clasificador recibe las instancias del conjunto de pruebas, pero sin incluir las etiquetas. La salida del clasificador son las etiquetas de cada instancia. Finalmente, las etiquetas producidas durante la predicción y las etiquetas reales de cada instancia se combinan y se calculan las métricas de evaluación. Esta técnica se basa en la idea de que, separando los datos que se usan durante el entrenamiento de aquellos usados durante la predicción, se logra una independencia en los datos que derivará en un mayor grado de generalización en el modelo.

Por contrapartida, el enfoque de *Holdout* tiene la limitación de que para lograr generalizar requiere de un número de instancias considerable [3]. Esta idea proviene del hecho de que muy pocos datos en el conjunto de entrenamiento puede derivar en predicciones pobres, pero, por el contrario, muy pocos datos en el conjunto de pruebas tampoco es recomendable, ya que podría resultar en medidas de rendimiento poco fiables. A esto se suma una de las dificultades más comunes en el área de aprendizaje automático: la falta de disponibilidad de colecciones grandes de datos del mundo real.

Por estas razones, ha tomado peso el uso de técnicas de muestreos de datos para reutilizar instancias de entrenamiento y de prueba. Una de ellas es la de validación cruzada.

Validación Cruzada de K iteraciones La técnica de validación cruzada, más conocida por el inglés *k-fold cross-validation*, consiste en particionar el conjunto de datos en k subconjuntos de manera aleatoria y en la forma $\{d_1, d_2, \dots, d_k\}$, siendo cada uno de los subconjuntos mutuamente excluyentes entre sí y de igual o similar tamaño. El proceso itera sobre cada uno de los subconjuntos para generar k modelos. En la primera iteración i , se separa el subconjunto d_i y se entrena el modelo con los restantes subconjuntos para luego medir el rendimiento con él. En la segunda iteración, se repite este procedimiento pero usando como pruebas al subconjunto d_{i+1} , y así en cada iteración. Así pues, cada subconjunto es usado una vez para probar el modelo. Finalmente, se toman los k modelos generados y se promedian las métricas.

De esta técnica derivan otras similares como “*leave-one-out*” en donde cada subconjunto es conformado por $n - 1$ instancias, siendo n el tamaño de la colección, dejando un elemento fuera del subconjunto y que será usado para validar el modelo. El proceso se repite n veces y se combinan los modelos tal como en el método de validación cruzada.

Otra técnica similar es la de “Validación Cruzada Estratificada”, la cual consiste en generar subconjuntos de entrenamiento y pruebas que respeten la representación de clases existentes en la colección inicial. Por ejemplo, si una de las clases del problema aparece en el 25 % de las instancias, este método asegura que al generar las particiones esa clase continuará siendo representada por el 25 % de las tuplas. Esta técnica puede ser útil para problemas donde existe una diversidad que es necesario reflejar en las particiones para obtener medidas precisas.

En general, los investigadores recomiendan usar validación cruzada con $k = 10$ ya que se suelen conseguir estimaciones menos sesgadas sin incurrir en costos computacionales demasiado altos.

B. PUBLICACIONES REALIZADAS EN EL MARCO DE LA TESIS

1. Juan Cardona y Santiago Banchero. «Clasificación multi-etiqueta con ensamble fijo por mayoría ponderada». En: *Simposio Argentino de ciencia de datos y GRANdes DATos (AGRANDA, 2021)* - 50 JAIIO. Oct. de 2021

ACRÓNIMOS

- BR* Binary Relevance. 4, 12, 13, 30, 31, 44–46, 48, 52
- CART* Classification and Regression Tree. 59
- CC* Classifier Chains. 4, 12, 13, 30, 31, 45, 46, 48, 52
- CIDETIC* Centro de Investigación, Docencia y Extensión en TIC de la Universidad Nacional de Luján. 30
- DWM* Dynamic Weighted Majority. 14, 26, 30–32, 44–46, 48, 53
- EBR* Ensemble de Binary Relevance. 14, 30–32, 45, 46, 48, 52
- ECC* Ensemble de Classifier Chains. 13, 14, 30–32, 45, 46, 48
- EFMP* Ensemble Fijo por Mayoría Ponderada. 7, 8, 22, 23, 26, 27, 30, 31, 44–46, 48, 49, 51–53
- EFMP2* Ensemble Fijo por Mayoría Ponderada 2. 26, 27, 30, 31, 44–46, 48, 49, 52
- FN* Falsos Negativos. 16, 17, 62
- FP* Falsos Positivos. 16, 17, 62
- GOOWE-ML* GOOWE-ML. 14
- HT* Hoeffding Tree. 13, 31, 46
- IA* Inteligencia Artificial. 55
- ID3* Iterative Dichotomiser 3. 58, 59
- iSoup-Tree* Incremental Structured Output Prediction Tree. 14
- LP* Label Powerset. 12, 13, 30
- MLHT* Multi-label Hoeffding Tree. 14, 30–32, 44–46, 48, 52
- MLL* Clasificación multi-etiquetas. 2–4, 6–8, 12–16, 22, 23, 30, 32, 51, 52
- MOA* Massive Online Analysis. 29, 30
- PS* Pruned Set. 13
- RBF* Generador de Función Radial Base. 19, 20, 32
- RTG* Generador de Árbol Aleatorio. 19, 20
- TI* Tecnología de la Información. 1
- VN* Verdaderos Negativos. 16, 17, 62
- VP* Verdaderos Positivos. 16, 17, 62

BIBLIOGRAFÍA

- [1] Ömer Faruk Arar y Kürşat Ayan. «A feature dependent Naive Bayes approach and its application to the software defect prediction problem». en. En: *Applied Soft Computing* 59 (oct. de 2017), págs. 197-209. ISSN: 1568-4946. DOI: 10.1016/j.asoc.2017.05.043. URL: <http://www.sciencedirect.com/science/article/pii/S1568494617303083>.
- [2] Albert Bifet y Gianmarco De Francisci Morales. «Big Data Stream Learning with SAMOA». En: *2014 IEEE International Conference on Data Mining Workshop*. 2014.
- [3] Albert Bifet y col. *Machine Learning for Data Streams with Practical Examples in MOA*. Mar. de 2018. ISBN: 978-0-262-03779-2.
- [4] Albert Bifet y col. «MOA: massive online analysis». En: *Journal of Machine Learning Research* 11 (mayo de 2010).
- [5] Matthew Boutell y col. «Learning multi-label scene classification». En: *Pattern Recognition* 37 (sep. de 2004), págs. 1757-1771. DOI: 10.1016/j.patcog.2004.03.009.
- [6] Leo Breiman. «Bagging predictors». en. En: *Machine Learning* 24.2 (ago. de 1996), págs. 123-140. ISSN: 1573-0565. DOI: 10.1007/BF00058655. URL: <https://doi.org/10.1007/BF00058655>.
- [7] Alican Büyükçakır, Hamed Bonab y Fazli Can. «A Novel Online Stacked Ensemble for Multi-Label Stream Classification». En: *Proceedings of the 27th ACM International Conference on Information and Knowledge Management* (oct. de 2018). arXiv: 1809.09994, págs. 1063-1072. DOI: 10.1145/3269206.3271774. URL: <http://arxiv.org/abs/1809.09994>.
- [8] Juan Cardona y Santiago Banchero. «Clasificación multi-etiqueta con ensamble fijo por mayoría ponderada». En: *Simposio Argentino de ciencia de datos y GRANdes Datos (AGRANDA, 2021) - 50 JAIIO*. Oct. de 2021.
- [9] Sotiris Diplaris y col. «Protein Classification with Multiple Algorithms». en. En: *Advances in Informatics*. Ed. por Panayiotis Bozanis y Elias N. Houstis. Lecture Notes in Computer Science. Berlin, Heidelberg: Springer, 2005, págs. 448-456. ISBN: 978-3-540-32091-3. DOI: 10.1007/11573036_42.
- [10] Pedro Domingos y Geoff Hulten. «Mining High-Speed Data Streams». En: *Proceeding of the Sixth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (nov. de 2002). DOI: 10.1145/347090.347107.
- [11] Uma Dulhare. «Prediction system for heart disease using Naive Bayes and particle swarm optimization». En: *Biomedical Research* 29 (ene. de 2018). DOI: 10.4066/biomedicalresearch.29-18-620.
- [12] Usama M Fayyad, Gregory Piatetsky-Shapiro y Padhraic Smyth. *Advances in Knowledge Discovery and Data Mining*. Ed. por Fayyad, Usama M. and Piatetsky-Shapiro, Gregory and Smyth, Padhraic and Uthurusamy, Ramasamy. Section: From data mining to knowledge discovery: an overview. Menlo Park, CA, USA: American Association for Artificial Intelligence, 1996.
- [13] João Gama. *Knowledge Discovery from Data Streams*. 2010.

- [14] João Gama, Raquel Sebastião y Pedro Pereira Rodrigues. «On evaluating stream learning algorithms». en. En: *Machine Learning* 90.3 (mar. de 2013), págs. 317-346. ISSN: 1573-0565. DOI: 10.1007/s10994-012-5320-9. URL: <https://doi.org/10.1007/s10994-012-5320-9>.
- [15] Francesco Gargiulo, Stefano Silvestri y Mario Ciampi. «Deep Convolution Neural Network for Extreme Multi-label Text Classification». En: *Proceedings of the 11th International Joint Conference on Biomedical Engineering Systems and Technologies*. 2018.
- [16] Eva Gibaja y Sebastian Ventura. «A Tutorial on Multi-Label Learning». En: *ACM Computing Surveys* 47 (2015).
- [17] *Google Search Statistics - Internet Live Stats*. en. URL: <https://www.internetlivestats.com/google-search-statistics/>.
- [18] Trevor Hastie, Robert Tibshirani y Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction, Second Edition*. en. 2.^a ed. Springer Series in Statistics. New York: Springer-Verlag, 2009. ISBN: 978-0-387-84857-0. DOI: 10.1007/978-0-387-84858-7. URL: <https://www.springer.com/gp/book/9780387848570>.
- [19] Francisco Herrera y col. *Multilabel Classification*. Ene. de 2016. ISBN: 978-3-319-41110-1. DOI: 10.1007/978-3-319-41111-8.
- [20] Geoff Hulten, Laurie Spencer y Pedro Domingos. «Mining Time-changing Data Streams». En: *Proceedings of the Seventh ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. KDD '01. San Francisco, California: ACM, 2001, págs. 97-106.
- [21] Harsha K. Kalutarage y col. «Detecting stealthy attacks: Efficient monitoring of suspicious activities on computer networks». en. En: *Computers & Electrical Engineering* 47 (oct. de 2015), págs. 327-344. ISSN: 0045-7906. DOI: 10.1016/j.compeleceng.2015.07.007. URL: <http://www.sciencedirect.com/science/article/pii/S0045790615002384>.
- [22] Richard Kirkby. *Improving Hoeffding Trees*. en. 2007. URL: </paper/Improving-Hoeffding-Trees-Kirkby/56283855992584581eb9c0eb4413b47be496b94e>.
- [23] Bryan Klimt y Yiming Yang. «The Enron Corpus: A New Dataset for Email Classification Research». en. En: *Machine Learning: ECML 2004*. Ed. por David Hutchison y col. Vol. 3201. Series Title: Lecture Notes in Computer Science. Berlin, Heidelberg: Springer Berlin Heidelberg, 2004, págs. 217-226. ISBN: 978-3-540-30115-8. DOI: 10.1007/978-3-540-30115-8_22. URL: http://link.springer.com/10.1007/978-3-540-30115-8_22.
- [24] J. Zico Kolter y Marcus A. Maloof. «Dynamic Weighted Majority: An Ensemble Method for Drifting Concepts». En: *The Journal of Machine Learning Research* 8 (dic. de 2007), págs. 2755-2790. ISSN: 1532-4435.
- [25] Ken Lang. «NewsWeeder: Learning to Filter Netnews». en. En: *Machine Learning Proceedings 1995*. Ed. por Armand Prieditis y Stuart Russell. San Francisco (CA): Morgan Kaufmann, ene. de 1995, págs. 331-339. ISBN: 978-1-55860-377-6. DOI: 10.1016/B978-1-55860-377-6.50048-7. URL: <http://www.sciencedirect.com/science/article/pii/B9781558603776500487>.

- [26] Gjorgji Madjarov y col. «An extensive experimental comparison of methods for multi-label learning». en. En: *Pattern Recognition* 45.9 (sep. de 2012), págs. 3084-3104. ISSN: 00313203. DOI: 10.1016/j.patcog.2012.03.004. URL: <https://linkinghub.elsevier.com/retrieve/pii/S0031320312001203>.
- [27] V Mayer-Schonberger y K Cukier. *Big Data: A Revolution that Will Transform how We Live, Work, and Think*. An Eamon Dolan book. Houghton Mifflin Harcourt, 2013.
- [28] Jacob Montiel y col. «Scikit-Multiflow: A Multi-output Streaming Framework». En: *arXiv:1807.04662 [cs, stat]* (jul. de 2018). arXiv: 1807.04662. DOI: 10.5555/3291125.3309634. URL: <http://arxiv.org/abs/1807.04662>.
- [29] Aljaž Osojnik, Panče Panov y Sašo Džeroski. «Multi-label classification via multi-target regression on data streams». en. En: *Machine Learning* 106.6 (jun. de 2017), págs. 745-770. ISSN: 1573-0565. DOI: 10.1007/s10994-016-5613-5. URL: <https://doi.org/10.1007/s10994-016-5613-5>.
- [30] N. C. Oza. «Online bagging and boosting». En: *2005 IEEE International Conference on Systems, Man and Cybernetics*. Vol. 3. ISSN: 1062-922X. Oct. de 2005, 2340-2345 Vol. 3. DOI: 10.1109/ICSMC.2005.1571498.
- [31] Fabian Pedregosa y col. «Scikit-learn: Machine Learning in Python». En: *arXiv:1201.0490 [cs]* (jun. de 2018). arXiv: 1201.0490. URL: <http://arxiv.org/abs/1201.0490>.
- [32] Robi Polikar. «Polikar, R.: Ensemble based systems in decision making. IEEE Circuit Syst. Mag. 6, 21-45». En: *Circuits and Systems Magazine, IEEE* 6 (oct. de 2006), págs. 21-45. DOI: 10.1109/MCAS.2006.1688199.
- [33] J. Read, B. Pfahringer y G. Holmes. *Generating Synthetic Multi-label Data Streams*. en. 2009. URL: [/paper/Generating-Synthetic-Multi-label-Data-Streams-Read-Pfahringer/147e3bc5f3c03884a8ba6d5420dc100834424c5d](http://paper/Generating-Synthetic-Multi-label-Data-Streams-Read-Pfahringer/147e3bc5f3c03884a8ba6d5420dc100834424c5d).
- [34] Jesse Read. *MOA: moa.streams.generators.multilabel.MetaMultilabelGenerator Class Reference*. 2012. URL: https://www.cs.waikato.ac.nz/~abifet/MOA/API/classmoa_1_1streams_1_1generators_1_1multilabel_1_1_meta_multilabel_generator.html.
- [35] Jesse Read, Bernhard Pfahringer y Geoff Holmes. «Multi-label Classification Using Ensembles of Pruned Sets». En: *2008 Eighth IEEE International Conference on Data Mining*. 2008.
- [36] Jesse Read y col. «Classifier chains for multi-label classification». En: *Mach. Learn.* 85.3 (2011), págs. 333-359.
- [37] Jesse Read y col. «Scalable and efficient multi-label classification for evolving data streams». en. En: *Machine Learning* 88.1 (jul. de 2012), págs. 243-272. ISSN: 1573-0565. DOI: 10.1007/s10994-012-5279-6. URL: <https://doi.org/10.1007/s10994-012-5279-6>.
- [38] Martha Roseberry y Alberto Cano. «Multi-label kNN Classifier with Self Adjusting Memory for Drifting Data Streams». en. En: *Second International Workshop on Learning with Imbalanced Domains: Theory and Applications*. ISSN: 2640-3498. PMLR, nov. de 2018, págs. 23-37. URL: <http://proceedings.mlr.press/v94/roseberry18a.html>.

- [39] Divya Sehgal y Ambuj Kumar Agarwal. «Sentiment analysis of big data applications using Twitter Data with the help of HADOOP framework». En: *2016 International Conference System Modeling Advancement in Research Trends (SMART)*. Nov. de 2016, págs. 251-255. DOI: 10.1109/SYSMAST.2016.7894530.
- [40] Cees G. M. Snoek y col. «The challenge problem for automated detection of 101 semantic concepts in multimedia». en. En: *Proceedings of the 14th annual ACM international conference on Multimedia - MULTIMEDIA '06*. Santa Barbara, CA, USA: ACM Press, 2006, pág. 421. ISBN: 978-1-59593-447-5. DOI: 10.1145/1180639.1180727. URL: <http://portal.acm.org/citation.cfm?doid=1180639.1180727>.
- [41] Ricardo Sousa y João Gama. «Multi-label classification from high-speed data streams with adaptive model rules and random rules». En: *Progress in Artificial Intelligence* (2018).
- [42] Erica Akemi Tanaka y col. «A multi-label approach using binary relevance and decision trees applied to functional genomics». en. En: *J. Biomed. Inform.* 54 (2015), págs. 85-95.
- [43] Grigorios Tsoumakas y Ioannis Katakis. «Multi-Label Classification». En: *Int. J. Data Warehouse. Min.* 3.3 (2007), págs. 1-13.
- [44] Grigorios Tsoumakas, Ioannis Katakis e I. Vlahavas. «Random k-Labelsets for Multi-Label Classification». En: *IEEE Trans. Knowl. Data Eng.* 23 (jul. de 2011), págs. 1079-1089. DOI: 10.1109/TKDE.2010.164.
- [45] Grigorios Tsoumakas y col. «MULAN: A Java library for multi-label learning». En: *Journal of Machine Learning Research* 12 (jul. de 2011), págs. 2411-2414.
- [46] Indika Wickramasinghe y Harsha Kalutarage. «Naive Bayes: applications, variations and vulnerabilities: a review of literature with code snippets for implementation». en. En: *Soft Computing* (sep. de 2020). ISSN: 1433-7479. DOI: 10.1007/s00500-020-05297-6. URL: <http://link.springer.com/10.1007/s00500-020-05297-6>.
- [47] David H. Wolpert. «Stacked generalization». en. En: *Neural Networks* 5.2 (ene. de 1992), págs. 241-259. ISSN: 0893-6080. DOI: 10.1016/S0893-6080(05)80023-1. URL: <http://www.sciencedirect.com/science/article/pii/S0893608005800231>.
- [48] Min-Ling Zhang y Kun Zhang. «Multi-label learning by exploiting label dependency». En: *Proceedings of the 16th ACM SIGKDD international conference on Knowledge discovery and data mining - KDD '10*. 2010.
- [49] Min-Ling Zhang y Zhi-Hua Zhou. «A Review On Multi-Label Learning Algorithms». En: *IEEE Trans. Knowl. Data Eng.* 26 (2014), págs. 1819-1837.
- [50] X. Zheng y col. «A Survey on Multi-Label Data Stream Classification». En: *IEEE Access* 8 (2020). Conference Name: IEEE Access, págs. 1249-1275. ISSN: 2169-3536. DOI: 10.1109/ACCESS.2019.2962059.